基金及国家重点项目

基于聚焦网络爬虫技术的人才招聘数据采集与分析

蒋泽艳
（长春金融高等专科学校信息技术学院，吉林长春 130028）

摘　要：本文以聚焦网络爬虫技术为重点组织分析，分析了其技术特点以及原理，研究了其在人才招聘数据采集与分析工作中的应用。技术层面包括采集框架建设、数据来源拓展以及采集逻辑的选取等，同时，关注工作流程的稳定性和可靠性，采用物联网工作系统、区块链工作模式，降低爬虫技术在单一节点的工作压力，保证数据分析后的汇总、交互效率，以进一步提升人才招聘数据采集与分析水平，发挥聚焦网络爬虫技术优势。

关键词：聚焦网络爬虫技术；人才招聘；数据采集；数据分析
中图分类号：TP392　　**文献标识码：**A　　**DOI：**10.3969/j.issn.1003-6970.2025.04.002
本文著录格式：蒋泽艳.基于聚焦网络爬虫技术的人才招聘数据采集与分析[J].软件,2025,46(4):004-006

Data Collection and Analysis of Talent Recruitment Based on Focused Web Crawler Technology

JIANG Zeyan
(Information Technology College of Changchun University of Finance, Changchun Jilin 130028)

【Abstract】：This article focuses on the analysis of web crawling technology, analyzing its technical characteristics and principles, and studying its application in talent recruitment data collection and analysis. At the technical level, it includes the construction of the collection framework, expansion of data sources, and selection of collection logic. At the same time, attention is paid to the stability and reliability of the workflow, adopting IoT work systems and blockchain work modes to reduce the work pressure of web crawling technology at a single node, ensuring the efficiency of data analysis and aggregation, and further improving the level of talent recruitment data collection and analysis, and leveraging the advantages of web crawling technology.

【Key words】：focused web crawler technology;talent recruitment;data collection;data analysis

0 引言

现代社会持续发展催生了各类新式技术，从应用、原理等角度出发，不同技术各具特点，适用于不同行业，改善了各行业的工作水平，包括人才招聘数据采集与分析在内。就聚焦网络爬虫技术而言，其具有应用灵活、适用性高、门槛较低的优势，可以为各类组织提供服务，改善其在人才招聘数据采集与分析方面的水平，降低成本压力，优化数据管理效果 [1]。当前，应用聚焦网络爬虫技术的组织仍较少，技术优势不能得到充分彰显。在此背景下，研究该技术的特点、原理、应用方式等，具有一定的现实意义。

1 聚焦网络爬虫技术特点以及原理

1.1 聚焦网络爬虫技术特点

聚焦网络爬虫（Focused Web Crawler）又称主题网络爬虫，该技术具有网络爬虫技术的一般特点，包括应用灵活、适用性高、门槛较低等，与此同时也具有一些个性化优势。与通用网络爬虫技术相比，聚焦网络爬虫可以根据预设目标有针对性地进行信息采集，有选择性地进行资源处理，以减少访问、保存的数据总量，节约网络资源。值得注意的是，聚焦网络爬虫技术能够获取的资源总量较少，虽然改善了工作效率，但也降低了综合价值，适用性不强 [2]。

基金项目：吉林省教育科学“十四五”规划 2023 年度一般课题“‘岗课赛证 + 思政融通’融合育人视域下人才培养模式研究”（GH23791）
作者简介：蒋泽艳（1986—），女，硕士研究生，讲师，研究方向：计算机技术应用及相关教学。

中国知网　https://www.cnki.net

1.2 聚焦网络爬虫技术原理

除共性技术原理外，聚焦网络爬虫技术更多关注以完善的预设程序为依据进行针对性作业。实际工作中，可以根据数据采集需要确定技术作业逻辑，之后增加链接评价模块和内容评价模块，前者对链接模块进行分析，后者对具体内容进行评估。核准链接得当、内容符合采集要求后，可进行后续处理，包括关键信息的收集、保存以及必要的二次加工等（如图 1 所示）。目前，一般需要对聚焦网络爬虫技术进行综合运用，提供增强学习模块、语境图等，进一步提升信息处理分析能力。

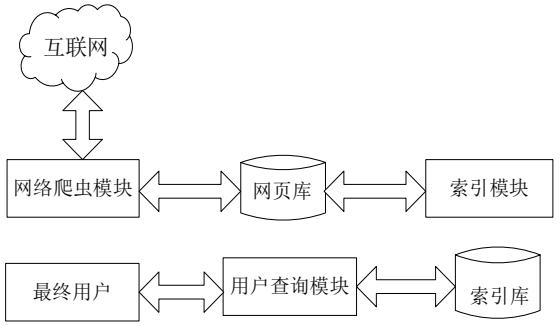

图 1 聚焦网络爬虫技术原理

Fig.1 Focusing on the principle of web crawler technology

2 聚焦网络爬虫技术下的人才招聘数据采集与分析

2.1 建设采集框架

为完成人才招聘数据采集目标，需要首先建设匹配聚焦网络爬虫技术的工作框架。该框架主要考虑三个要素，一是硬件配置，二是数据库，三是作业模块的分布。硬件配置方面，尽管聚焦网络爬虫技术对网络资源的消耗较少，要求较低，但由于人才招聘有关原始数据总量较大，仍主张对硬件进行配置强化，尤其是虚拟内存和磁盘空间。面向公共网络组织人才招聘数据采集时，计算机虚拟内存应达到 32GB 以上，以同步处理海量原始信息，计算机的磁盘空间应不低于 2TB，条件允许的情况下，计算机显存也应达到 16GB 以上 [3]。

数据库设计可以采用分层模式，将人才招聘数据分为若干大类，每个大类分为若干小类，分层分库进行存储。如通过聚焦网络爬虫技术采集招聘对象年龄信息、学历信息、经验信息、预期薪资信息等，均可单独建库进行保存。各大类信息又可拆分为若干小类，如学历信息分为硕士及以上、本科、大专、中专及以下等。数据库设计的要求不是僵化的，可根据人才招聘数据的采集需要、聚焦网络爬虫技术特点具体确定。作业模块即聚焦网络爬虫技术作业模块，其分布主要强调分散化。各类组织采集人才招聘有关数据时，需要确定原始信息的采集来源。面向本地、本企业、全网组织信息采集时，需配置、使用的模块功能和数目有所不同，原始信息来源越丰富、空间范围越广，需要配置的聚焦网络爬虫技术模块越多，分散性越高 [4]。

2.2 确定采集逻辑

完成采集框架建设后，需要结合聚焦网络爬虫技术特点分析、确定数据采集的一般逻辑。通常可以在智能训练、增强学习技术的支持下，采用实时对照、实时采集的方式，以智能化技术为中心完成针对性作业。以关键词采集法为例，在智能技术支持下，可首先对各聚焦网络爬虫技术模块进行管理，统一作业逻辑。默认采集对象为人才招聘岗位及薪资有关数据，可结合本单位的需要，设定关键词集：

[X 行业；岗位；薪资；预期薪资；薪资变化；薪资平均水平]（标准关键词集）

确定关键词后，面向目标网络组织信息采集。为发挥聚焦网络爬虫技术优势，需要选取若干与“人才招聘岗位及薪资”有关的目标，包括各类招聘网站、数字化人才市场等。之后配置聚焦网络爬虫技术模块，感知目标网络内的信息。所有信息被感知后，实时提炼其关键词，与标准关键词集进行对照，当二者相似度达到 60% 以上时，认定其符合“采集”标准，予以采集和保存，反之则予以淘汰。默认某信息的关键词提炼结果如下：

[X 行业；岗位；薪资；预期薪资；薪资变化；薪资最高水平]（实时关键词集 1）

聚焦网络爬虫技术经过爬行、分析，发现实时关键词集 1 与标准关键词集高度相似，满足“二者相似度达到 60% 以上”要求，可予以保存。默认某信息的关键词提炼结果如下：

[X 行业；求职意愿；预期薪资；学历分布；薪资最高水平]（实时关键词集 2）

聚焦网络爬虫技术经过爬行、分析，发现实时关键词集 2 与标准关键词集相似度有限，不满足“二者相似度达到 60% 以上”要求，可予以淘汰。按此逻辑对目标网络内有关信息进行采集，可以提升处理效率和目标性。

2.3 拓展数据来源

与通用爬虫技术不同，聚焦网络爬虫技术组织信息采集时，针对性较强、效率较高。然而，人才招聘数据在任何网络资源内的总量均比较有限，考虑到聚焦网络爬虫技术的特点，可能产生信息采集不全面、不丰富的问题。未来工作中还可考虑对数据来源进行拓展，面向更大范围内的网络数据进行采集，或更改标准，采集关联度相对不高的原始数据再做二次处理。

如组织招聘管理的企业，可以面向本地人才市场进

中国知网 https://www.cnki.net

行信息采集，在此基础上以与人才招聘有关的网站为对象，同步进行数据采集，拓展原始信息来源渠道。面向公共网络组织信息采集的作业成本、压力偏高，也可以对采集标准进行调整。例如，采用上文所述的关键词采集法，进行适当更改；利用聚焦网络爬虫技术进行爬行、采集信息，仍实时提炼目标信息关键词，与标准关键词集进行对照，当二者相似度达到 50% 以上时认定其符合“采集”标准，加以保存。在不改变工作逻辑的情况下，丰富原始信息的采集量 [5]。

3 聚焦网络爬虫技术下的工作系统

3.1 应用区块链工作模式

采用聚焦网络爬虫技术进行人才招聘数据采集与分析时，需要关注规范性。在工作信息总量较大、复杂性较高的情况下，可以采用区块链技术提供支持。该技术主要应用于海量人才招聘数据采集与分析工作中。

默认某企业尝试招聘大量技术人员，本地人才市场相关人才数目比较有限，不能满足招聘要求，企业尝试进行信息来源渠道拓展，并应用聚焦网络爬虫技术开展工作。可在启动招聘计划后，建立若干单独工作的信息中心，每个中心关联至少一个聚焦网络爬虫技术模块，后者在组织人才招聘数据采集、分析时，直接受信息中心的管理和控制，该信息中心即“区块链管理中心”。各区块链管理中心可以按照完全相同的逻辑进行信息采集，组织爬虫进行作业，也可以各自结合目标网络、资源池的特点确定不同的工作逻辑，如单独进行招聘对象学历采集、单独采集招聘对象的经验信息等。各区块链管理中心之间不存在隶属关系，其工作互不干扰，同时同步接受企业人力资源管理部门的统一领导，尤其是聚焦网络爬虫采集的各类信息，均由企业人力资源管理部门进行调取、管理、应用。区块链模式下，即便企业需要采集、处理海量的人才招聘数据，也可以进行工作内容分摊管理，避免单一工作区域、爬虫工作压力过大的情况。

3.2 构建物联网作业系统

区块链技术下，各类组织可以利用聚焦网络爬虫技术提升人才招聘数据采集、分析的效率，但去中心化模式有可能带来信息管理、复用方面的问题，导致组织不能实时调取、查看不同区块链管理中心获取的信息，聚焦网络爬虫技术的优势难以最大化发挥，未来可以利用物联网技术予以应对。

具体工作中，建议采用实时有线关联、非实时灵活关联并行的方式，建设覆盖组织内各关键部门、人员的物联网工作系统。仍以企业为例，企业的人力资源管理部门可以作为物联网中心，该中心利用 CAN 总线技术等开放多个外联渠道，每个单独工作的区块链管理中心均以有线形式接入 CAN 总线系统，与企业人力资源管理部门保持实时关联。后者可根据需要查看前者信息，包括聚焦网络爬虫技术下人才招聘数据采集与分析信息。与此同时，企业的人力资源管理部门也开放授权，向具有管理需求的人员提供权限，允许其随时根据管理需要访问物联网系统以及各区块链管理中心，组织聚焦网络爬虫技术管理，获取人才招聘数据，以改善管理工作的灵活性。

4 聚焦网络爬虫技术应用展望

未来人才招聘数据采集与分析工作仍依赖聚焦网络爬虫技术提供支持，且技术应用的基本趋势在于精准化、联动化。精准化是指爬行过程中的聚焦网络爬虫可以借助现代化的技术手段，精准进行人才招聘数据辨识，提升采集和分析的准确度，以减少各类组织对相关信息进行重复加工、处理的难度，目前，一般认为可通过智能技术实现该目标。联动化则关注以更多关联技术提供辅助，改善聚焦网络爬虫技术应用实效。例如，在应用聚焦网络爬虫技术采集、分析人才招聘数据时，同步启动云技术，通过云计算处理海量的原始信息，通过云储存方式保存海量的有关信息。其他技术也拥有与聚焦网络爬虫技术联动的空间，包括可视化技术、集成技术等，实际工作中也应予以关注。

5 结语

综上所述，应用聚焦网络爬虫技术，人才招聘数据采集与分析工作的效率和质量得到了提升，未来工作中可予以重视。从特点上看，聚焦网络爬虫技术的针对性更高，以人才招聘数据采集、分析为目标，需要做好工作框架建设，适当拓展数据来源，优化采集逻辑，同时采用区块链和物联网技术框架提供分析和数据交互服务。从发展的角度出发，未来人才招聘数据采集与分析工作仍需要聚焦网络爬虫技术的支持，其应用可能更重视联动性和精准性，以改善数据处理能力。

参考文献

[1] 周玮.基于聚焦网络爬虫技术的财务大数据采集系统设计[J].中国新技术新产品,2024(3):37-40.

[2] 张启宁,吴国俊.基于Python聚焦网络爬虫技术的乡村旅游数据采集与分析[J].产业科技创新,2023,5(6):66-68.

[3] 张雁涔.基于聚焦网络爬虫技术的企业大数据采集系统设计[J].信息与电脑(理论版),2023,35(12):154-156.

[4] 吴君胜.基于聚焦网络爬虫技术的开放大学智慧图书馆信息资源系统的设计与研究[J].广州广播电视大学学报,2022,22(6):58-62+110.

[5] 李阳阳.基于大数据技术与网络爬虫的创新创业竞赛服务[J].自动化与仪器仪表,2022(10):150-154.

中国知网　https://www.cnki.net