華南理工大學
South China University of Technology

专业学位硕士学位论文

基于能力导向和岗位匹配的学生就业推荐模型的研究与实现

作 者 姓 名	彭浩伟
学 位 类 别	电子信息硕士（软件工程）
指 导 教 师	左保河
	胡艳胜
所 在 学 院	软件学院
论文提交日期	2023 年 4 月

中国知网 https://www.cnki.net

Research and Implementation of Student Employment Recommendation Model Based on Competency-Oriented and Job Matching

A Dissertation Submitted for the Degree of Master

Candidate：Peng Haowei

Supervisor：Zuo Baohe

South China University of Technology

Guangzhou, China

中国知网 https://www.cnki.net

分类号：TP3 **学校代号：10561**

学　号：202021046349

华南理工大学硕士学位论文

基于能力导向和岗位匹配的学生就业推荐模型的研究与实现

作者姓名：彭浩伟　　指导教师姓名、职称：　左保河　副教授

申请学位级别：电子信息硕士　　学科专业名称：软件工程

研究方向：智能软件与数据挖掘

论文提交日期：2023 年 4 月 19 日　　论文答辩日期：2023 年 6 月 3 日

学位授予单位：华南理工大学　　学位授予日期：　　年　月　日

答辩委员会成员：

主席：宋恒杰

委员：奚建清　朱金辉　彭绍武　张宇

中国知网　https://www.cnki.net

摘　　要

近年来，我国高校毕业生人数逐年递增，大学生就业形势愈发严峻。而对学生就业推荐的研究可以有效缓解就业难的问题。当下，高校虽然设有就业指导中心，但缺乏就业推荐模型的应用；现有研究大部分基于学生兴趣进行推荐，没有考虑学生能力水平和岗位招聘要求的匹配，少部分对学生简历与岗位要求做匹配，但简历属于自我评价，客观性不强，且不易统一收集和处理。因此，本文旨在以能力为导向，深入挖掘高校已有的、相对客观的课程内容与岗位要求的联系，实现学生与岗位的双向匹配推荐，以降低高校就业指导、学生求职和企业人才筛选的成本。本文主要研究工作如下：

针对现有研究忽略了学生能力水平和岗位招聘要求的匹配，进而导致的推荐不准确问题，本文提出了一个基于注意力的课程能力与岗位能力匹配模型，计算学生在课程中收获的能力和企业岗位要求的能力的匹配度，并用于后续推荐。具体地，本文设计了一种能力注意力机制，对两条句子中的能力关键词给予更多关注，并结合其字、句和能力粒度的表示进行多维交互匹配。

针对课程内容与岗位要求因缺乏上下文导致的匹配困难问题，本文引入了预训练主题模型对这两者进行聚类和主题词提取，为它们增添上下文语义和额外信息，从而提高匹配模型的精度。

针对现有研究使用简历等数据评价学生，导致推荐结果存在主观性的问题，本文充分利用工程教育认证背景下的客观教学数据，整合上述两点工作，提出了一个基于能力导向和岗位匹配的学生就业推荐模型，用于学生和岗位的双向推荐。模型先通过主题模型为课程内容和岗位要求添加额外语义，再通过匹配模型计算所有课程内容和岗位要求之间的匹配度，最后结合学生课程评价计算学生与岗位的匹配度，并据此做双向推荐。

在模型验证方面，本文使用高校课程大纲、学生课程评价和企业招聘文本作为原始数据，将基于注意力的课程能力与岗位能力匹配模型、基于能力导向和岗位匹配的学生就业推荐模型分别与领域内先进模型进行了多组对比实验，取得了一定的效果提升，证明了两者的有效性。

关键词：就业推荐；能力导向；文本匹配；注意力机制

中国知网　https://www.cnki.net

Abstract

In recent years, the number of graduates in China has increased year by year, and the employment situation of graduates has become increasingly severe. The research on students' employment recommendation can effectively alleviate the problem of employment difficulty. At present, although universities have employment guidance centers, they lack the application of employment recommendation models; Most of the existing studies make recommendations based on students' interests, without considering the matching of students' ability level and job recruitment requirements, and the rest match students' resumes with job requirements, but resumes are self-evaluation, not strong objectivity, and not easy to collect and process uniformly. Therefore, the purpose of this thesis is to deeply explore the relationship between the existing and relatively objective curriculum content and job requirements in universities with the guidance of ability, and realize the two-way matching and recommendation between students and jobs, so as to reduce the cost of employment guidance in university, students' job hunting and enterprise talent screening. The main research work of this thesis is as follows:

In view of the inaccurate recommendation results caused by the existing research ignoring the matching between students' ability level and job recruitment requirements, this thesis proposes an Attention based Course ability and Job ability Matching model(ACJM), ACJM calculates the matching degree between students' ability gained in the course and the ability required by the job, which is used for subsequent recommendation. Specifically, this thesis designs an ability attention mechanism, which pays more attention to the ability keywords in the two sentences, and carries out multidimensional interactive matching by combining the representation of words, sentences and ability granularity.

In view of the difficulty in matching the course content and job requirements due to the lack of context, this thesis introduces the pre-training topic model to cluster and extract the topic words, adding context semantics and additional information for them, so as to improve the accuracy of ACJM.

In view of the subjectivity of the recommendation results caused by the existing research using resume to evaluate students, this thesis makes full use of the objective teaching data under

中国知网 https://www.cnki.net

the background of engineering education accreditation, integrates the above two works, and proposes a Student Employment Recommendation model based on Competency-oriented and Job Matching(SERCJM), which is used for the two-way recommendation of students and jobs. SERCJM firstly adds additional semantics to the course content and job requirements through topic model, secondly calculates the matching degree between all course content and job requirements through the matching model, and thirdly calculates the matching degree between students and jobs to get two-way recommendation results accordingly.

This thesis uses the university curriculum outline, student curriculum evaluation and enterprise recruitment text to train the models, and conducts multiple groups of comparative experiments with the advanced models in the field to verify the models including ACJM and SERCJM. The result of experiments show that the two models are effective.

Keywords: Employment Recommendation; Competency-Oriented; Text Matching; Attention Mechanism

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....2
1.2.1 推荐算法的研究现状.....2
1.2.2 人岗匹配的研究现状.....3
1.2.3 文本匹配算法的研究现状.....4
1.3 主要研究内容及工作.....7
1.4 论文组织结构.....8
第二章 相关理论概述.....9
2.1 卷积神经网络.....9
2.2 注意力机制.....10
2.3 BERT.....12
2.4 LSTM.....14
2.5 Bi-LSTM.....15
2.6 BERTopic.....16
2.7 本章小结.....17
第三章 基于能力导向和岗位匹配的学生就业推荐模型的构建.....18
3.1 SERCJM 模型的整体流程.....19
3.2 数据预处理.....21
3.2.1 数据来源.....21
3.2.2 原始数据的分析与处理.....21
3.2.3 能力关键词库的构建.....24
3.3 主题词提取.....27
3.3.1 主题词提取的定义.....27
3.3.2 主题词提取的流程.....28
3.3.3 主题模型的效果验证.....30
3.3.4 主题词提取的结果.....33
3.4 本章小结.....35
第四章 基于注意力的课程能力与岗位能力匹配模型.....36
4.1 ACJM 模型的结构.....36
4.1.1 主题填充层.....38
4.1.2 文本嵌入层.....39
4.1.3 句子表示层.....39
4.1.4 能力注意力层.....40

中国知网 https://www.cnki.net

4.1.5 多维匹配层.....42
4.1.6 聚合层.....42
4.1.7 输出层.....43
4.1.8 损失函数.....43
4.2 ACJM 模型的验证.....43
4.2.1 评价指标.....43
4.2.2 数据准备.....44
4.2.3 实验配置.....45
4.2.4 主题词个数对模型效果的影响.....45
4.2.5 与基线模型的对比实验.....47
4.2.6 与领域先进模型的对比实验.....48
4.2.7 消融实验.....50
4.3 本章小结.....52
第五章 基于能力导向和岗位匹配的学生就业推荐模型的验证.....53
5.1 学生与岗位推荐计算.....53
5.2 SERCJM 模型的验证.....55
5.2.1 评价指标.....55
5.2.2 数据准备.....56
5.2.3 有效性实验.....57
5.3 本章小结.....59
总结与展望.....60
参考文献.....62

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景与意义

教育部数据[1]显示，2022 年高校应届毕业生规模达到 1076 万，同比增加 167 万，规模与增量均创历史新高，就业市场存在着“就业难”与“招人难”的现象。严峻的就业形势背后，是高校学生企业三方的信息壁垒、人才培养模式与产业需求脱节、校企对接不充分等诸多问题。而对学生就业推荐的研究有助于校企对接和人才输送，能在一定程度上缓解就业“两难”问题。

目前，高校基本没有针对毕业生的就业推荐模型，一般是通过就业指导中心为学生推送企业的招聘信息，或是对企业公布生源的概况，这不能满足学生的个性化求职需求，也不能为企业提供学生的精细化评价。企业为充分了解学生的能力水平，通常设置许多轮考核，招聘环节愈加冗长，而学生也需要花费大量时间应试性学习，招聘和求职的成本都大大增加。

当下，在学生就业推荐相关的研究中，由于学生不存在与岗位的交互信息，大部分研究都使用学生兴趣、校内行为等数据，结合协同过滤等方法做推荐，这些研究没有考虑学生能力水平和岗位招聘要求的匹配，因为企业更加关注学生能力是否胜任岗位要求；也有少部分研究考虑到这点，使用学生简历和岗位要求进行匹配，但简历是学生的自我评价，客观性不足，同时，学生简历格式不一，难以统一收集处理。因此，为更好地实现学生就业推荐，应当寻找易于获取的数据来客观评价学生能力。

而工程教育专业认证的发展，恰好提供了能精准客观评价学生的教学数据。2016 年，我国成为国际工程教育专业认证协议（《华盛顿协议》[2]）的第 18 个正式成员[3]，到 2019 年底，已有 241 所高校的 1869 个本科专业通过了工程教育认证[4]，未来还将有更多高校需要通过认证。工程教育专业认证体系下的人才培养遵循成果导向教育[5]（Outcome-Based Education，OBE）和能力导向教育（Competency-Oriented Education，COE）的理念，以培养学生综合能力为出发点，在教学过程中加入更多实践实训项目，并产出大量与学生能力表现相关的评价数据（如课程目标、毕业要求的达成度）。这些数据相较学生绩点等粗粒度标准，可以更精细地评价学生，相较个人简历也具备较好的客观性，对学生就业推荐研究、解决毕业生就业问题具有重大意义。

中国知网 https://www.cnki.net

综上所述，现有研究或缺乏对学生能力评价和企业用人需求的考虑，或缺乏客观评价学生能力的标准。因此，本文希望充分挖掘工程教育认证背景下产出的客观教学数据，以能力为引线串联学生、高校、企业三方，构建一个能力导向的学生就业推荐模型，对学生和企业岗位进行双向匹配和推荐，以降低高校就业指导、学生求职和企业人才筛选的成本。

1.2 国内外研究现状

1.2.1 推荐算法的研究现状

推荐算法是指通过一定的算法推测出用户（User）可能感兴趣的项目（Item）。经典的推荐算法[6]有基于内容的推荐（Content-based Recommendation，CR）、协同过滤推荐[7]（Collaborative Filtering Recommendation，CFR）和混合推荐（Hybrid Recommendation，HR）等。其中，CR 根据用户已经评分过的项目，寻找其它内容上相似的项目作为推荐，如 Monney 等[8]提出一种基于内容的图书推荐系统，然而，CR 依赖项目的特征，存在特征提取困难的问题。CFR 认为相似用户拥有相似项目偏好，只需要用户与项目的历史评分矩阵就可以推荐，简单高效，但存在数据稀疏和冷启动的问题。而 HR 算法考虑到单一推荐方法的不足，将不同的推荐方法组合在一起，如 Balabanovic 等[9]提出一种结合 CR 与 CFR 的混合推荐算法来提高性能。

就业推荐是指用推荐算法为求职者推荐岗位或为岗位推荐候选人，目前已有大量研究将上述推荐算法应用于就业推荐领域。如 Diaby 等[10]提出了一个基于内容的岗位推荐系统，将岗位招聘信息推荐给社交网站和招聘网站的用户，但是其需要透彻的岗位描述内容，而且仅仅推荐相似的岗位。Gupta 等[11]根据求职者的个人资料及工作偏好来给出求职建议，Md. Sabir Hossain 等[12]提出了一种基于协同过滤的推荐系统，使用客户的反馈分类和关联规则挖掘技术，帮助求职者寻找合适工作，Zhang 等人[13]比较了基于用户的协同过滤和基于物品的协同过滤在岗位推荐任务中的效果，然而，协同过滤方法依赖于候选人和岗位的历史交互信息，存在冷启动问题。由此，Yang 等[14]提出将基于内容和协同过滤联合起来的岗位推荐系统，徐孟奇等[15]将知识图谱技术引入就业推荐，添加额外知识，用以改善冷启动问题。

高校毕业生的就业问题与上述在线招聘问题有较大差异，因为学生没有完善的职业

中国知网 https://www.cnki.net

资料，往往只有学校提供的基本信息和课程成绩，同时，作为应届生，也不存在与企业或岗位的历史交互信息。现有的研究通常是从学生的偏好或校园行为出发，如 Martinez 等[16]使用随机森林（Random Forest）和支持向量机（Support Vector Machine，SVM）提取学生的个人特征，以此为依据进行推荐，金连旭等[17]通过毕业生的历史就业数据，探究学生的个人偏好，计算企业的敏感度与信任度,并以此为据为学生推荐就业岗位，Zhou 等[18],[19]提出一种结合学生个性化偏好的协同过滤算法，通过校园卡数据、图书馆借阅频次等校园行为数据提取学生特征，并提供职位推荐。但是，这样得到的推荐结果只考虑了学生的个人志趣，并没有考虑学生能力水平和岗位招聘要求的匹配，所以结果往往不能满足企业实际的用人需求。

综上，学生与岗位的历史交互数据难以获得，而已有的个人兴趣、校园行为等数据又没有考虑到学生能力水平和岗位招聘要求的匹配，因此，上述推荐算法并不适合直接用于高校毕业生的就业问题。

1.2.2 人岗匹配的研究现状

人岗匹配也是一种解决就业问题的方法，它是指根据求职者信息和岗位信息来度量两者的匹配度，达到双向匹配的效果。早在上个世纪 90 年代，Edwards 提出的论文[20]就对人岗匹配做了综述，其认为企业或组织需要个人的能力适应职位的要求，强调人对职位的胜任力。早期的人岗匹配与就业推荐方法有较大的相似性，如 Malinowski 等[21]利用应聘者数据与职位信息构建了一个候选人与岗位的双向匹配系统，Shivam 等[22]通过匹配用户的兴趣技能与岗位招聘要求，为用户提供岗位推荐，这些研究实质上仍然具有推荐算法的局限性。伴随着在线招聘服务的发展，人岗匹配也有了新的研究，如 Zhang 等[23]提出一种广义线性混合模型(Generalized Linear Mixed Models，GLMix)，并将其应用于领英的在线招聘服务，提升了候选人 20%-40%的求职机会，Yin 等[24]将双向选择观点引入人岗匹配中，帮助招聘方更好地找到符合要求的候选人。另一种思路是对候选人的历史信息建模，如 Ye 等[25]使用图卷积网络（Graph Convolutional Network，GCN）和长短期记忆网络建模员工在企业内的交流和关系，识别其潜力及与企业的契合度，类似地，Hou 等[26]提出使用搜索历史数据进行时序建模，来提高人岗匹配度。也有研究针对候选人的简历和企业的招聘文本建模，如 Bian 等[27]提出一种多层级表示和领域自适应

中国知网 https://www.cnki.net

的人岗匹配模型，通过领域自适应来解决某些领域就业数据少的问题，Qin 等[28]通过构建多层级注意力机制的能力感知模型，端到端的实现候选人和岗位的匹配，但完全依靠注意力也使其能力感知存在不可控性，可解释性并不好。综上可知，人岗匹配的重点是，寻找能代表求职者与企业岗位的内容（通常是求职者的简历和岗位的招聘描述），再通过各种方式对这两者进行表示和匹配度比较，其优势在于预测时不需要人与岗位的历史交互信息，而缺陷在于非常依赖两者表示的质量。

在高校毕业生就业问题上，也有研究采用人岗匹配的思路，如 Reiter-Haas 等[29]建立了一个学生职业生涯平台，通过学生在不同学习进度下的信息来为他们推荐合适的岗位，Lacic 等[30]考虑到长期的历史信息的隐私限制，基于会话信息来匹配学生与岗位，但这些做法一定程度上依赖于学生与岗位在系统中的交互。而 Mathur 等[31]和 Razak 等[32]都提出了根据学生的个人简历和企业岗位的技能要求，建立起学生与岗位是否匹配的模糊规则，这种做法有三种缺陷，其一是简历往往是学生的自我评价，较为主观，在真实性上有所欠缺，其二是需要简历是否通过岗位筛选的标签，而高校基本没有这项数据，其三是毕业生的简历格式不一，难以统一收集处理。因此，为更好地对学生和岗位进行匹配，应当寻找一种较为客观、易于获取、能综合评价学生能力的标准。

而当下，大部分高校都需要通过工程教育认证，教学过程中产出了大量与学生能力表现相关的数据（如课程目标达成度），这些数据相较传统的课程成绩，可以从更细粒度评价学生的能力表现，相对简历等也具备更高的客观性。因此，本文考虑将使用课程目标达成度等数据刻画学生能力，再与岗位要求进行匹配。

1.2.3 文本匹配算法的研究现状

综合上两节的描述，本文考虑使用工程教育认证背景下的学生评价数据，参照人岗匹配的思路，进行学生与岗位的匹配和推荐研究。由于学生的课程评价数据是课程目标等文本数据，而岗位招聘要求一般也是文本形式，两者的匹配实质上是文本的匹配，因此，本节将阐述文本匹配算法的研究现状。而文本匹配算法又可以大致分类成表征式和交互式两种，下面将分别介绍两者的研究现状。

表征式文本匹配指的是将两条句子文本分别编码成向量，再评估其匹配程度。微软在 2013 年提出了经典的双塔模型 DSSM（Deep Structured Semantic Model）[33]，将句子

中国知网 https://www.cnki.net

映射到相同维度的语义空间，通过衡量两者之间的余弦相似度来达到匹配的目的。Mikolov 等提出 Word2Vec（Word To Vector）[34]，利用词的上下文信息将词转化为向量，再使用余弦距离等方法比较相似度。Pennington 等提出 GloVe（Global Vectors for Word Representation）[35]在 Word2Vec 的思想上再利用了全局词信息，收获了比 Word2Vec 更快的训练速度和效果。但是，Word2Vec 和 GloVe 仅将每个词映射到一个向量，对于多义词效果不佳。2018 年 1 月，Peters 提出了 ELMo（Embeddings from Language Models）[36]，它是一种动态化的词向量表示方法，生成词嵌入时考虑了上下文语境，解决了语法语义、一词多义等问题，其缺点在于采用的双向长短期记忆网络（Bidirectional Long Short-Term Memory，Bi-LSTM）特征抽取能力较弱，不如 2017 年 Google 提出的 Transformer[37]。

由于有标注的、领域内的语料非常有限，伴随着 BERT（Bidirectional Encoder Representations from Transformers）[38]的诞生，后续研究大多转向了先预训练后迁移的方向。2019 年，Reimer 等基于 BERT 修改，提出了 SBERT（Sentence-BERT）[39]，从 BERT 中得到了合适的句向量用于相似度匹配。但是，直接使用 BERT 得到的向量具有各向异性且分布不均匀，无法很好的衡量句子相似度。针对此问题，Li 等人提出一种 BERT-flow 流式变换模型[40]，将向量空间映射到标准高斯分布向量空间，将向量分布调整。同样的问题在 Su 等人[41]的论文中也得到了考虑，他使用简单快速的白化（Whitening）操作得到了与 flow 相近的效果。经过 flow 或 whitening 操作的向量，大大改善了 BERT 原本向量的均匀性（Uniformity），但也使其对齐性（Alignment）变差，由此 Gao 等人[42]在论文 SimCSE（Simple Contrastive Learning of Sentence Embeddings）中引入对比学习的思想，统筹兼顾了向量的均匀性和对齐性。此后也有学者提出基于 SimCSE 的改进版，ArcCSE（Additive Angular Margin Contrastive learning of Sentence Embeddings）[43]针对 SimCSE 无法建模多个句子间语义顺序的缺陷做了改进。2022 年，Lee 等人则基于最优传输理论和对比学习，提出了一种度量方法和对比学习框架[44]，以解决增强 SimCSE 等方法可解释性不足的问题。同年，Jiang 等人提出 PromptBERT[45]，提出一种新颖的提示学习思路，充分利用了 BERT 等预训练模型的训练模式，将句子嵌入设计的模板中，让模型直接预测其表示，取得了比无监督版 SimCSE 更好的效果。

交互式方法认为表征式方法过于依赖文本表征的质量，且可能丢失句子本身的词法、语法等特征，因此其思路是尽早地将两个句子进行各种层面的交互。2016 年，Google 提

中国知网 https://www.cnki.net

出了轻量级的交互模型 DecAtt（Decomposable Attention）[46]，让句子中的各个单词相互对比，找出 Word-Level 的语义交互。同年发表的 MatchPyramid 模型[47]借鉴了计算机视觉领域的做法，将卷积神经网络（Convolutional Neural Network，CNN）应用于句子交互得到的词匹配二维矩阵，获得了数个百分点的提升。Chen 等人提出了基于 DecAtt 改动的 ESIM（Enhanced Sequential Inference Model）模型[48]，在句子交互融合后增加一层 Bi-LSTM。Facebook 提出的 HCAN（Hybrid Co-Attention Network）模型[49]在编码层堆叠了 CNN，在交互层结合 Attention、TF-IDF（Term Frequency-Inverse Document Frequency）和 Bi-LSTM 进行两次交互,收获了最佳效果。阿里巴巴在 2019 年提出的 RE2（Residual vectors，Embedding vectors，Encoded vectors）[50]则是将两个句子交互多次，并将最初的嵌入拼接进每个阶段，提升了效率而保留了较好精度。

交互式模型相较于表征式模型，其优点是匹配精度很高，但是计算速度非常慢，而表征式方法虽然计算快，但需要大量的数据去训练以提高精度。基于兼顾模型精度与性能的目标，有研究将两者融合在一起，常见做法有延迟交互和知识蒸馏。延迟交互即在表征式模型中增加弱交互环节，2020 年，Cao 等提出 DeFormer（Decomposing pre-trained transFormers）[51]拆解了 Transfomer，移除了低层的 Attention 计算并加入特定优化，在问答任务上取得了 4.3 倍的匹配速度，而精度上只有 1%的下降；同年，Khattab 等提出了一个基于上下文的后期交互排序模型 ColBERT（Contextualized Late Interaction over BERT）[52]，兼顾了匹配的效率和语料中的上下文信息。知识蒸馏即将交互式模型蒸馏到双塔形式，以此获得交互式方法的精度和表征式方法的速度，2021 年，Li 等提出了 VIRT（Virtual InteRacTion）[53]，即虚拟交互机制，分别训练交互模型和双塔模型，让后者学习到如何交互，该模型在几个任务上逼近了交互式模型的精度；2022 年，百度发布了旗下中文预训练模型 ERNIE 的 ERNIE-Search[54]版本，提出了交互蒸馏（Interaction Disitllation）策略和级联蒸馏（Cascade Distillation）策略，有效了避免模型表示知识的方式不一致的问题。

综合来看，表征式文本匹配追求如何构造更合适的文本表达，往往在最后才进行两个句子的交互，损失了一定的匹配精度，而交互式文本匹配需要大量的交互计算，速度相对较慢，因此本文考虑将两种方法结合起来，以兼顾精度与速度。另外，现有的上游研究大部分只考虑了原始句子的语义，没有考虑其它维度的特征，要应用在本文场景中，

中国知网 https://www.cnki.net

还需针对性的改进。

1.3 主要研究内容及工作

综合研究现状来看，在高校毕业生的就业推荐研究中，由于学生与岗位交互数据的缺失，协同过滤等推荐算法并不适合直接用于此；而基于校园历史行为和个人偏好的推荐则忽略了学生能力水平和岗位招聘要求的匹配，导致推荐结果不能实际满足企业的用人需求；相对地，人岗匹配的一些方法不依赖历史交互，而是使用学生简历与岗位要求做匹配，具备一定的可行性，但是，与招聘网站上用户统一填写简历不同，学生的简历格式不一，难以统一收集处理，并且，简历作为个人评价，在客观性和真实性上有所缺失。而当下工程教育认证的发展使得大部分高校已经具备、或未来将要具备课程目标达成度等教学数据，这些数据可以精准而综合地评价学生，也相对客观。由此，本文希望深入挖掘工程教育认证背景下的教学数据与真实的企业岗位招聘要求，来对学生和岗位做匹配和推荐。本文主要研究内容及工作如下：

针对现有研究忽略了学生能力水平和岗位招聘要求的匹配，进而导致推荐不准确的问题，本文提出了一个基于注意力的课程能力与岗位能力匹配模型（Attention based Course ability and Job ability Matching model，ACJM），以教学数据中的课程目标代表学生在校期间已经具备的能力，以岗位招聘要求代表学生未来任职时应当具备的能力，计算一对课程目标和岗位要求的匹配度，用于后续的推荐。具体地，本文在 ACJM 中设计了一种能力注意力机制，对句子中的能力相关词汇显式地给予更多关注，并结合了表征式和交互式文本匹配的方法，综合考虑句子的字粒度、句粒度和能力粒度表示进行多维度交互匹配。

由于课程目标与岗位要求匹配的实质是短文本匹配，针对短文本缺乏上下文和外部知识带来的匹配困难问题，本文引入了预训练主题模型来提取文本主题词，为课程目标和岗位要求增添上下文语义和额外信息，帮助 ACJM 更好地匹配。

针对现有研究没有使用客观数据评价学生，导致推荐结果存在主观性的问题，本文充分利用工程教育认证背景下的客观教学数据，构建了一个能力关键词库用于 ACJM 的匹配，并整合上述工作，提出了一个基于能力导向和岗位匹配的学生就业推荐模型（Student Employment Recommendation model based on Competency-oriented and Job Ma

中国知网 https://www.cnki.net

tching，SERCJM），用于实现学生和岗位的双向推荐。SERCJM 是一个端到端的整体方案，其输入是一批课程、岗位和学生成绩，输出是学生与岗位的双向推荐结果。具体地，SERCJM 首先通过预训练主题模型为课程目标和岗位要求增加额外语义，然后通过 ACJM 模型计算所有课程目标和岗位要求之间的匹配度集合，最后通过匹配度集合与学生的课程目标得分计算学生与岗位之间的匹配度，并据此对学生和岗位做双向推荐。

1.4 论文组织结构

本文总共包含了六个章节，各章节的具体内容和章节间的结构如下所示：

第一章，绪论。本章首先介绍了本文的研究背景和意义，然后介绍了推荐算法、人岗匹配和文本匹配技术的国内外研究现状，期间分析了各个算法应用于本文场景的可行性，最后对本文的研究工作和组织结构进行了概要描述。

第二章，相关理论概述。本章对本文后续所使用到的自然语言处理相关技术的基本原理和相关方法进行了简要的介绍。

第三章，基于能力导向和岗位匹配的学生就业推荐模型的设计。本章首先详细描述了基于能力导向和岗位匹配的学生就业推荐模型（SERCJM）的整体结构和流程，并简要介绍了 SERCJM 每个部分的作用、输入和输出；其次，对 SERCJM 所用到的数据进行了预处理，其中还构建了一个能力关键词库，为第四章的匹配模型作铺垫；最后，详细介绍了 SERCJM 的第一个部分，即主题词提取，描述了实现流程，验证了其有效性，并展示和分析了主题词提取的结果。

第四章，基于注意力的课程能力与岗位能力匹配模型（ACJM）。这是 SERCJM 的第二个部分，本章首先详细阐述了 ACJM 的整体结构和流程，模型中每一层的输入、输出和作用，然后设计了一系列实验来验证 ACJM，包括主题词个数对模型的影响，与基线模型与领域先进模型的对比，能力注意力和主题填充模块的消融实验等。

第五章，基于能力导向和岗位匹配的学生就业推荐模型的验证。本章首先详细介绍了 SERCJM 的最后一部分，即学生与岗位推荐计算，描述了其流程和算法；然后通过与基线方案和领域先进方案的对比实验，验证了 SERCJM 的有效性。

总结与展望。本章回顾了前文所有的工作内容，分析和总结了本文所提出的 ACJM 和 SERCJM 的成果和表现，最后对本文的不足以及未来的研究工作方向进行了展望。

中国知网 https://www.cnki.net

第二章 相关理论概述

为对课程目标和岗位需求的文本数据进行分析处理，本文所提的基于能力导向和岗位匹配的学生就业推荐模型使用了许多自然语言处理技术，本章将对这些后续使用到的技术进行简要介绍。

2.1 卷积神经网络

卷积神经网络[55]是一种前馈神经网络，它具有深度结构，核心是卷积和池化计算，是深度学习的代表算法之一。卷积神经网络常用于提取输入数据的特征。其中，前馈神经网络指的是信号量在网络中向前传递，具体来说，信号在每一层的网络，都会经过其所有神经元，得到这层网络的输出，再输入到下一层网络，最终从输出层输出网络的结果。

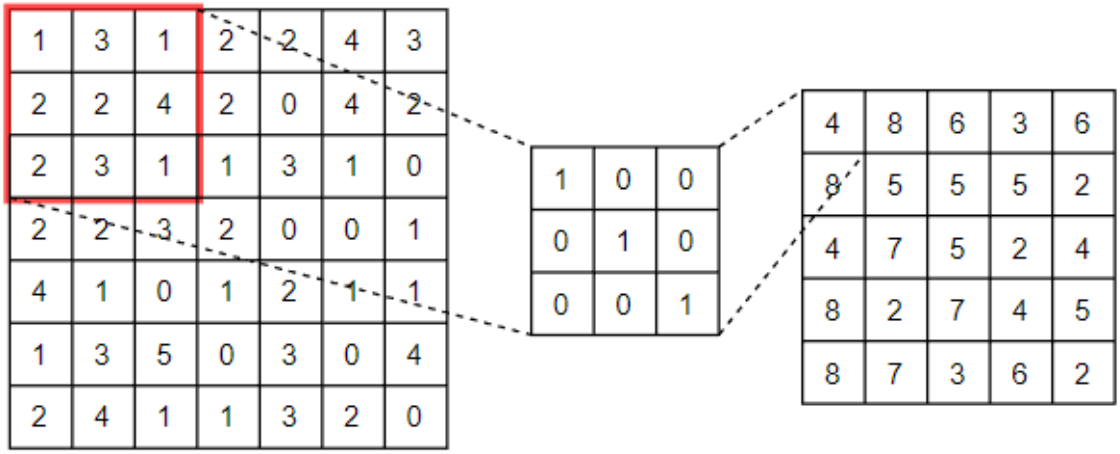

图 2-1 卷积操作示意图

卷积神经网络的核心部分在于卷积层和池化层，这两个部分用于提取输入数据的特征。卷积层的操作过程如图 2-1 所示，卷积层拥有一个卷积核，通过卷积核对输入的矩阵进行滑动式卷积，所谓卷积，就是将卷积核的值与输入数据对应位置的值相乘再相加，如图中第一个窗口经卷积后获得的值为 4。池化层用于从更高维度抽取特征，常见的做法有平均池化和最大池化，其中：平均池化指的是选择窗口中所有值的平均值来代表这个窗口特征，而最大池化指的是选择窗口中的最大值来代表这个窗口特征，池化层的两种方法如图 2-2 和 2-3 所示。

中国知网 https://www.cnki.net

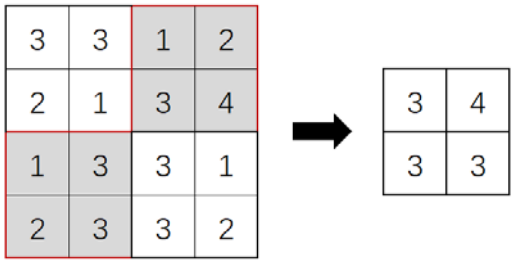

图 2-2 最大池化操作

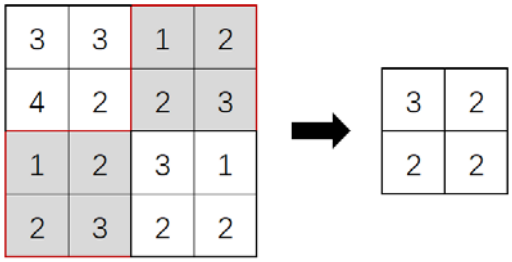

图 2-3 平均池化操作

卷积神经网络常用于图像处理和研究，其优点在于其局部连接和权重共享的结构：局部连接指的是它只关注输入的局部特征，因为图像的像素点之间的联系是局部的，网络没有必要感知整体和全局的图像，只需要在更高层维度把网络获得的不同局部特征合并起来，就可以获得全局的特征信息；而权值共享指的是不同神经元之间的参数共享，以减少网络需要计算的参数，权值共享实际上是使用相同的卷积核做卷积，这意味着第一个隐藏层的所有神经元，就能检测到处于图像不同位置的类型一致的特征，正因为具备了这种感知不同位置同类特征的能力，卷积神经网络可以很好地适应图像小范围的平移性。综上所示，局部连接和权重共享这两种结构减少了网络权重的数量，让网络更容易收敛，同时也降低了网络的复杂度，减少过拟合。

2.2 注意力机制

注意力（Attention）机制[37]的说法来源于对人类视觉的研究，其含义是，人眼在看到一个物体时，会有选择性地对物体的某一部分予以更多的关注，而对其他的部分予以较少的关注。在神经网络中也是如此，当模型接收的输入变的更多时，模型效果可能会变得更差，因为过载的信息分散了模型的注意力。因此，有研究引入注意力机制这一概念，让模型在众多的输入中，聚焦于对任务更重要的信息，并降低对其他输入的关注，以此提高模型的准确度和性能。

中国知网 https://www.cnki.net

注意力机制可以分为软性注意力、硬性注意力和自注意力三种模式。软性注意力（Soft Attention）指的是模型在选择有效信息时对所有的输入进行注意力的加权平均，而硬性注意力（Hard Attention）指的是模型将注意力关注到一个位置上，常见的实现方式有选择最高概率的信息和随机采样。这两种注意力的计算可以分成以下两步：第一步是计算所有输入信息的注意力分布，第二步是根据注意力分布去对输入信息加权平均，具体流程图如图 2-4 所示。

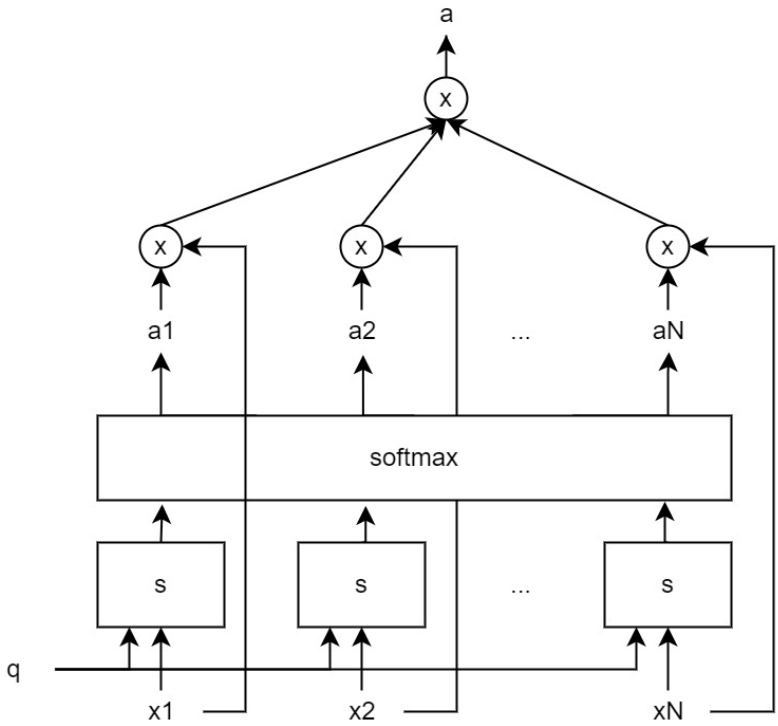

图 2-4 注意力值计算过程

在计算输入数据的注意力分布时，给定一个输入向量x和$Query$向量q，其中$Query$向量q的目的是用来从输入向量x中查询一些内容，并定义注意力变量$z \epsilon [1, N]$用于表示被查询内容的索引位置，即$z = i$表示第i个输入数据，具体流程如公式 2-1 所示。

$$a_i = p(z = i|X, q) = softmax\big(s(x_i, q)\big) = \frac{\exp\big(s(x_i, q)\big)}{\sum_{j=1}^{N} \exp\left(s\big(x_j, q\big)\right)} \qquad (2-1)$$

其中，a_i表示在给定q和x的条件下，第i个输入信息的概率，由a_i构成的概率向量称为注意力分布，$s(x_i, q)$表示注意力的打分函数，存在以下几种表示形式，其中W，U和v是可训练的参数，d为输入信息的维度：

$$s(x_i, q) = v^T \tanh(Wx_i + Uq) \qquad (2-2)$$

$$s(x_i, q) = x_i^T q \qquad (2-3)$$

中国知网 https://www.cnki.net

$$s(x_i, q) = \frac{x_i^T q}{\sqrt{d}} \tag{2-4}$$

$$s(x_i, q) = x_i^T W q \tag{2-5}$$

对于根据注意力分布计算输入信息的加权平均而言，在得到对应的注意力分布后，采用加权平均的方式对所有输入信息进行汇总，得到注意力值，具体公式如 2-6 所示。

$$Attention(X, q) = \sum_{i=1}^{N} a_i x_i \tag{2-6}$$

自注意力机制则是在同一层网络的输入和输出之间动态生成不同连接的权重，相比全连接神经网络，自注意力机制有着动态的连接边数，因此可以用于处理变长序列，当输入更长的序列时，只需要生成更多连接边即可。对于给定的输入序列$X = [x_1, x_2, \cdots, x_N]$，我们定义三组矩阵序列$Q = w_Q X \in \mathbb{R}^{d\times N}$，$K = w_K X \in \mathbb{R}^{d\times N}$，$V = w_V X \in \mathbb{R}^{d\times N}$分别为查询矩阵、键矩阵和值矩阵，$w_Q$，$w_K$，$w_V$为可训练的参数矩阵，对于自注意力值结果，输出向量$H = [h_1, h_2, \cdots, h_N]$的计算过程如公式 2-7 所示，其中$i, j \epsilon [1, N]$为输入序列和输出序列的位置，$a_{ij}$表示位置$ij$上的注意力权重。

$$h_i = Attention\big((K, V), q_i\big) = \sum_{j=1}^{N} a_{ij} v_j = \sum_{j=1}^{N} softmax\Big(s\big(k_j, q_i\big)\Big) v_j \tag{2-7}$$

注意力机制相比卷积神经网络 CNN，具有更大的感受野，能获得更多的上下文信息，建立全局的依赖关系。但是，由于其中的自注意力机制是通过筛选重要信息，过滤不重要信息实现的，无法利用图像本身具有的尺度，平移不变性，以及图像的特征局部性，只能通过大量的数据进行学习，因此，这导致自注意力机制只有在大数据的基础上才能有效地建立准确的全局关系，而在小数据的情况下，其抓取有效信息的整体效果可能不如卷积神经网络。

2.3 BERT

BERT[38]是谷歌提出的一个预训练语言模型，广泛应用于自然语言处理领域的各个任务中，如文本匹配、语义分析等。在 BERT 之前，传统的 Word2Vec 等编码无法处理多义词，为静态编码，而谷歌提出的 BERT 模型能动态的表达同一单词在不同上下文情境下的编码结果。

BERT 模型的结构是双向的、堆叠了多个 Transformer 的 Encoder，其结构如图 2-5 所示。BERT 的本质是学习输入序列的特征表示，其采用的双向结构能够解决单向结构

中国知网 https://www.cnki.net

无法获取完整上下文信息的问题，并通过计算句子中词与词之间的相互关系来调整每个词的权重以获取新的句子表达。在输入表示时，模型会在每个序列的开始位置添加一个特殊的类别标记[CLS]，使用 WordPiece Embedding 对序列中的单词进行编码，并额外添加了用于区分句子对的 Segment Embedding 和区分位置信息的 Position Embedding。

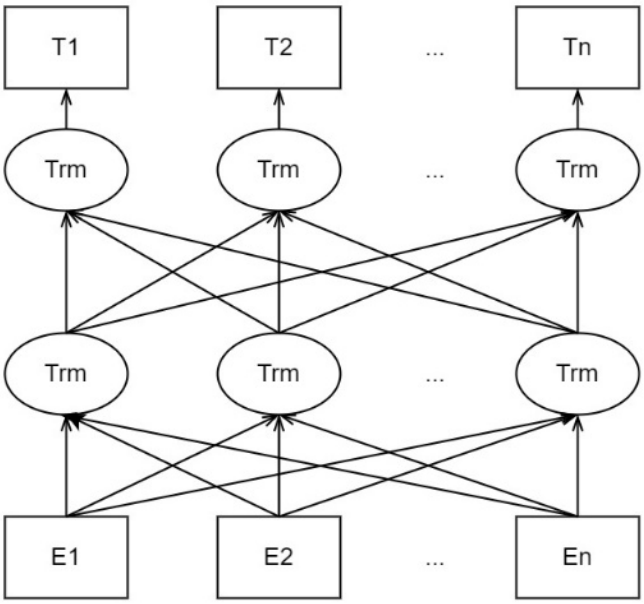

图 2-5 BERT 模型结构图

在 BERT 模型整个处理流程中，包括遮掩语言模型（Mask Language Model，MLM）和下一步预测（Next Sentence Prediction，NSP）这两种创新的预训练内容训练模型。遮掩语言模型用于学习句子中单词层级的特征表示，所谓遮掩，就是在模型的训练过程中随机地遮住输入序列一部分的 token。如果模型选定了某个 token，BERT 将以 0.8 的概率把它替换成[MASK]标记，以 0.1 的概率将其替换成一个随机的 token，还有 0.1 的概率保持原来的 token 不变，最后，再让模型根据保留的其他 token，去预测这些被遮掩掉的 token。由于 BERT 模型并不知道输入序列中有些 tokens 被 mask，所以其被迫的在对序列中每个时间步的 token 编码时，会利用当前 token 的信息，还能够捕获并充分利用全局上下文的语义信息。而 NSP 任务的目的是学习句子维度的特征表示，具体做法是将两条句子拼接上[CLS]和[SEP]标记，然后让模型预测两条句子是否构成上下文的先后关系。而根据 Transformer Encoder 的结构，输入模型的句子中特殊字符[CLS]的隐层状态是由句子中各个 token 的信息综合加权得到的，因此[CLS]最后能够用来表示整个句子的语义信息，所以在 BERT 中，一般使用[CLS]的状态作为预测分类的结果。

中国知网 https://www.cnki.net

2.4 LSTM

在自然语言处理的任务中，一般需要使用句子层面的表达强化文本的表示信息。句子层面的表达是指通过非线性变换将原始文本的词向量嵌入到另外一个句子层面的向量空间中。LSTM(Long short-term memory)[56]是主流的句子表示模型，相比循环神经网络 RNN（Recurrent Neural Networks）[57]，LSTM 添加了遗忘控制门，输入控制门，输出控制门三个门控机制用于解决 RNN 存在的长期依赖的局限性和梯度消失或梯度爆炸等问题，其单元结构图如图 2-6 所示，其中h_{t-1}表示上一个隐层的输出，x_t表示当前时刻的输入，c_t表示当前时刻的记忆输出。

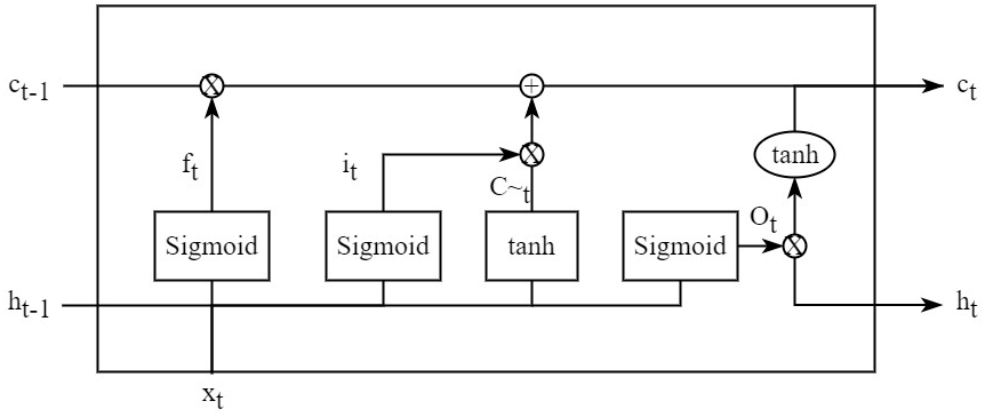

图 2-6 LSTM 神经元结构

在 LSTM 的神经元结构中，遗忘控制门的目的是确定在上一个隐藏层状态中，哪些信息是重要的，而输入控制门的目的是确定在当前状态下，哪些信息是重要的，至于输出控制门，其目的是确定下一个隐藏层的状态。遗忘控制门是模型工作的第一步，该步骤的公式如公式 2-8 所示，其中W^f和U^f表示可训练的权重，σ代表 Sigmoid 函数。在该公式中，h_{t-1}和x_t通过函数得到 0-1 之间的结果f_t，其中 1 表示保留所有信息，而 0 则表示摒弃所有信息。

$$f_t = \sigma(W^f x_t + U^f h_{t-1}) \tag{2-8}$$

接着，模型使用输入控制门用来更新重要信息，即确定什么信息需要保留在神经元的状态c_t中，该步骤的具体公式如 2-9 和 2-10 所示，其中W^i, U^i, W^n, U^n为可训练的权重矩阵。在该步骤中，模型首先使用 Sigmoid 函数来获取当前输入单元的更新程度，再使用 Tanh 函数更新内容向量$\tilde{C}_t$，最后通过公式 2-11 确定对记忆内容c_t的更新。

$$i_t = \sigma\left(W^i x_t + U^i h_{t-1}\right) \tag{2-9}$$

中国知网 https://www.cnki.net

$$\tilde{C}_t = \tanh(W^n x_t + U^n h_{t-1}) \quad (2-10)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (2-11)$$

最后，模型使用输出控制门确定输出值，该过程如公式 2-12 和公式 2-13 所示，其中W^o和U^o为可训练的权重矩阵，h_{t-1}为最终的隐藏层输出。在该公式中，模型使用 Sigmoid 函数计算得到被输出的信息，然后通过 tanh 函数计算最后的输出h_t。

$$o_t = \sigma(W^o x_t + U^o h_{t-1}) \quad (2-12)$$

$$h_t = o_t * \tanh(C_t) \quad (2-13)$$

总而言之，LSTM 在整体序列建模上具有长期记忆的优势，能解决梯度消失和梯度爆炸的问题。但是，由于 LSTM 为单向建模，没有考虑前后双向的语义信息，容易丢失重要信息。

2.5 Bi-LSTM

双向长短期记忆网络 Bi-LSTM[58]是一种单向 LSTM 模型的升级版。该模型采用双向循环神经网络，能解决 LSTM 的前时刻无法获取到后时刻的语义信息的问题。Bi-LSTM 的模型结构如图 2-7 所示。

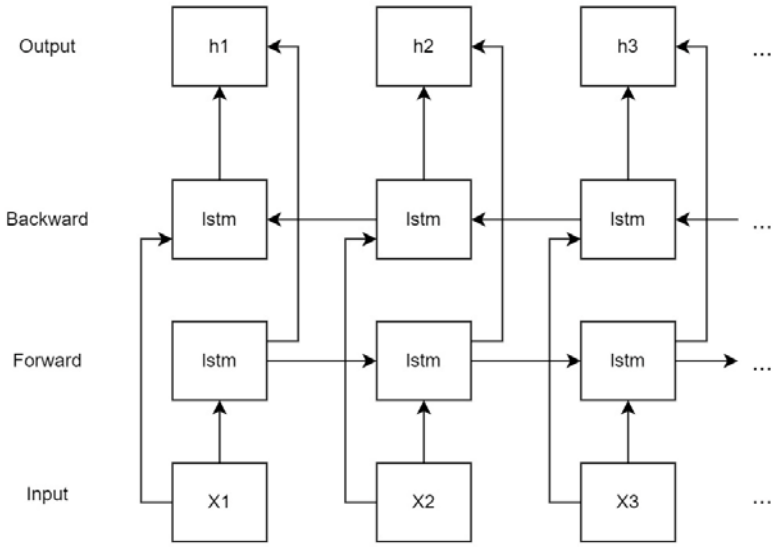

图 2-7 Bi-LSTM 的模型结构

在 Bi-LSTM 的模型结构中，包含 Forward 层和 Backward 层，其中：Forward 层的作用是正向计算 1 时刻到 t 时刻的内容，并得到每个时刻隐藏层的输出。Backward 层的作用是反向计算时刻 t 到时刻 1 的内容，并得到每个时刻隐藏层的输出。然后，模型再将每个时刻 Forward 层和 Backward 层的隐藏层输出的结果相结合。该过程的公式表达

中国知网 https://www.cnki.net

如下，其中w_1，w_2，w_3，w_4，w_5和w_6为可训练的权重矩阵，h_t为正向时刻的隐层输出，h_t'为反向时刻的隐层输出：

$$h_t = f(w_1 x_t + w_2 h_{t-1}) \tag{2-14}$$

$$h_t' = f(w_3 x_t + w_4 h_{t+1}') \tag{2-15}$$

$$o_t = g(w_5 h_t + w_6 h_t') \tag{2-16}$$

总而言之，Bi-LSTM 通过双向学习句子的信息，并结合前向输出和反向输出的结果得到最终表示，这个表示不仅能更好的捕捉文中过去和未来的信息，还能增强句子表达能力。但是，模型要想计算下一时刻的结果，依赖于前一时刻的结果，因此 Bi-LSTM 无法并行计算，存在效率问题。

2.6 BERTopic

BERTopic[59]是 2022 年由 Grootendorst 等提出的文本主题模型，其结构如图 2-8 所示。

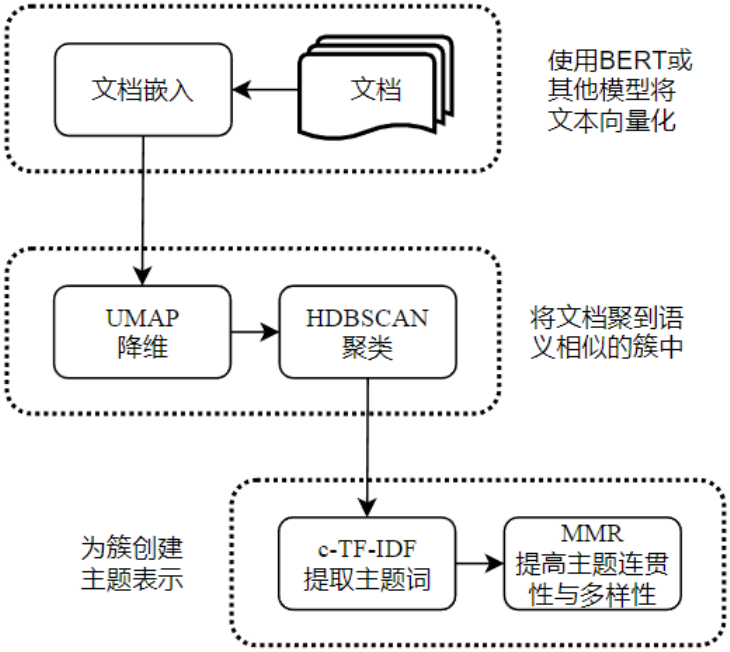

图 2-8 BERTopic 的结构

BERTopic 基于 Sentence-Transformer 模型计算文档的嵌入，由于预训练模型的嵌入维数过高，直接聚类并不容易，所以 BERTopic 使用了 UMAP[60]（Uniform Manifold Approximation and Projection）来对嵌入进行降维，再使用 HDBSCAN[61]（Hierarchical Density-Based Spatial Clustering of Applications with Noise）算法对文档嵌入做聚类。在聚

中国知网 https://www.cnki.net

类完成后，获得了若干个类簇，此时再使用 c-TF-IDF（class based Term Frequency–Inverse Document Frequency）算法来提取簇内文本的主题词，c-TF-IDF 是一种基于 TF-IDF（Term Frequency–Inverse Document Frequency）算法改动的算法。TF-IDF 用于评估一个单词对一份文档的重要程度，其原则是单词的重要性随着它在文档中出现的次数上升而上升，但同时随着它在语料库中出现的次数上升而下降，TF-IDF 分数的计算方法如公式 2-17 所示，其中t代表单词，d代表文档，$tf_{t,d}$表示单词t在文档d中出现的频次，N代表语料库中文档的总数，df_t表示语料库中包含单词t的文档个数。

$$W_{t,d} = tf_{t,d} \cdot \log(\frac{N}{df_t}) \tag{2-17}$$

$$W_{t,c} = tf_{t,c} \cdot \log(1 + \frac{A}{cf_t}) \tag{2-18}$$

而 c-TF-IDF 相比于 TF-IDF 改动的地方在于，在聚类后语料库中，把每个类簇中所有的文档组合在一起，视为一个大文档，然后评估这个大文档中每个词的重要性，以此获取这个类簇的主题词。c-TF-IDF 分数的计算方法如公式 2-18 所示，其中t代表单词，c代表类簇，$tf_{t,c}$表示单词t在类簇c中出现的频次，A代表每个类簇的平均单词数量，cf_t表示所有类簇中单词t的出现频次。这样，每个类簇中，c-TF-IDF 分数越高的词语，就越能代表这个类簇的主题内容。最后，BERTopic 使用最大边界相关法(Maximal Marginal Relevance coherence，MMR)来对筛选的主题词进行平滑处理，提高主题词的连贯性和多样性。

BERTopic 解决了过去的主题模型在基于密度聚类和基于质心采样之间的不兼容问题，同时支持组合不同的预训练嵌入模型和聚类算法，但是其主题的质量非常依赖于预训练嵌入模型的表示质量。

2.7 本章小结

本章详细描述了本文模型后续所用到的卷积神经网络、注意力机制、词语表示模型 BERT、句子表示模型 LSTM 和 Bi-LSTM、预训练主题模型 BERTopic 的相关理论和技术，分析了它们的优点和缺陷，并进行了总结，为后文提出基于能力导向和岗位匹配的学生就业推荐模型做铺垫。

中国知网 https://www.cnki.net

第三章 基于能力导向和岗位匹配的学生就业推荐模型的构建

如第一章所述，目前高校一般通过就业指导中心为学生推送企业招聘信息、为企业公布生源概况，这既不能满足学生的个性化求职需求，也不能为企业提供学生的精细化评价。企业为充分了解学生的能力水平，通常设置许多轮考核，招聘环节愈加冗长，而学生也需要花费大量时间应试性学习，招聘和求职的成本都大大增加。在这种背景下，学生就业推荐研究对解决企业招聘和学生求职的“两难”问题具有重要意义。

当下，大部分学生就业推荐的研究对学生兴趣或校内行为建模，没有考虑学生能力水平和岗位招聘要求的匹配，导致模型推荐的学生无法满足企业的实际用人需求；少部分研究对学生简历和岗位要求建模，但学生简历格式不一，难以统一收集处理，并且，简历内容大部分是学生的自我评价，具有主观性，使得推荐结果的准确性和客观性不足。

因而，本文提出了一个基于能力导向和岗位匹配的学生就业推荐模型（SERCJM），为企业和学生提供双向推荐，以降低高校就业指导、企业招聘和学生求职的成本。针对当下研究大部分没有考虑学生能力水平和岗位招聘要求的匹配而带来的推荐不准确问题，本文在 SERCJM 中设计了一个基于注意力的课程能力与岗位能力匹配模型（ACJM），来着重关注学生的能力水平。针对当下研究的推荐结果不够准确和客观的问题，本文在 SERCJM 中充分利用了工程教育专业认证实践中产出的相对客观的教学数据和真实的企业岗位招聘数据，以此对学生能力水平进行客观评价，并用于后续推荐。具体地，SERCJM 以教学数据中的课程目标代表学生在校期间已经具备的能力，以岗位需求代表学生未来任职时应当具备的能力，先通过 ACJM 计算两者的匹配度，再以此为依据计算学生与岗位的匹配度并做推荐。

SERCJM 共包含主题词提取、ACJM、学生与岗位推荐计算三个部分。为更清晰地对其进行描述，本章首先在 3.1 节对 SERCJM 的整体流程进行了介绍，阐述三个部分的输入、输出与作用，为后续章节介绍三个部分的实现做铺垫；其次，在 3.2 节介绍了对 SERCJM 所需的数据进行预处理的过程；最后，在 3.3 节详细介绍了 SERCJM 的第一个部分，即主题词提取的实现，并展示了主题词提取的结果。后续，本文将在第四章介绍 SERCJM 的第二个部分，在第五章介绍 SERCJM 的第三个部分，并对 SERCJM 整体的

中国知网 https://www.cnki.net

有效性进行验证。

3.1 SERCJM 模型的整体流程

SERCJM 模型的目标是从学生能力和企业需求角度，利用工程教育认证背景下的教学数据和企业的岗位招聘数据，计算学生与岗位的匹配度，并对学生和岗位进行双向推荐。模型的整体结构和流程如图 3-1 所示。

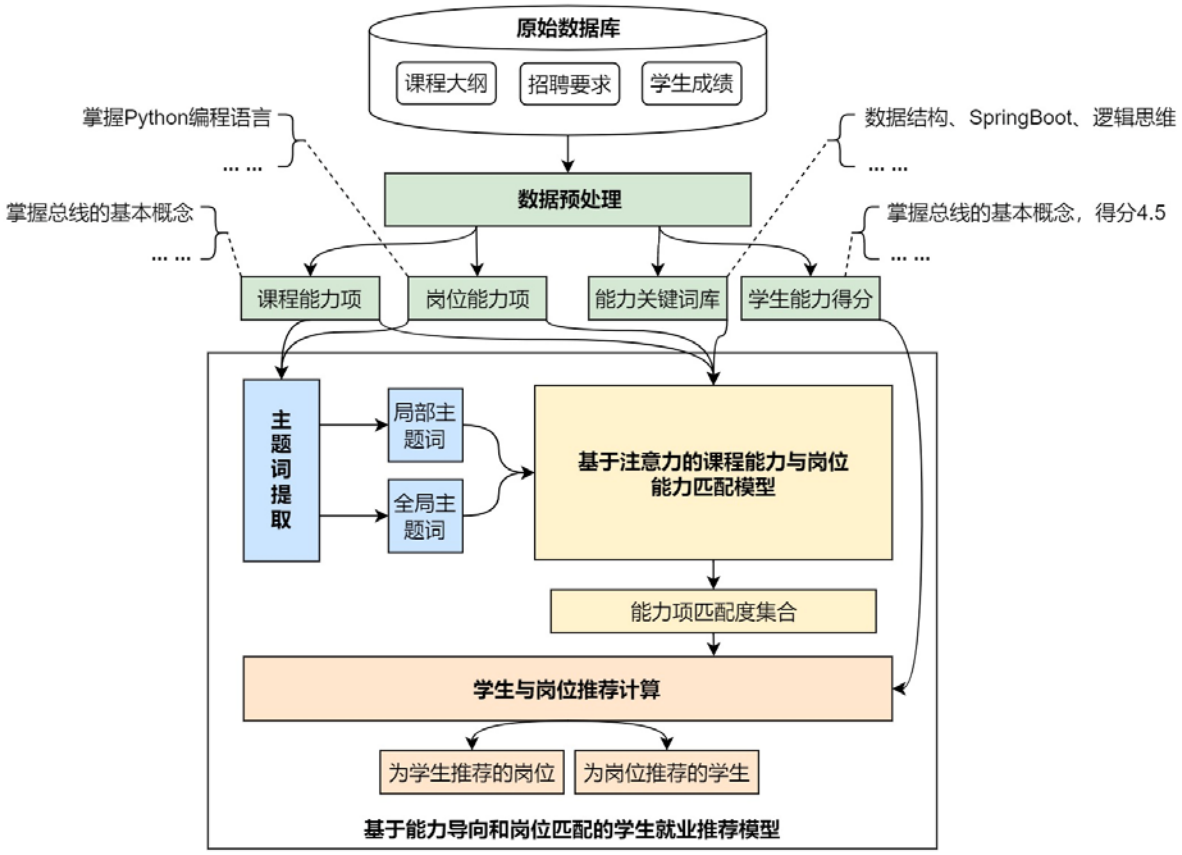

图 3-1 基于能力导向和岗位匹配的学生就业推荐模型的整体流程

SERCJM 的输入是由课程大纲、招聘要求、学生成绩等原始数据经预处理后得来，包括课程能力项、岗位能力项、学生能力得分和能力关键词库，其中：课程能力项指的是课程大纲中的一条课程目标，例如“掌握总线的基本概念”。岗位能力项指的是岗位的一条招聘要求，例如“掌握 Python 编程语言”。学生能力得分是指学生在课程目标上的得分，例如学生 A 在“掌握总线的基本概念”上的得分是 4.5。而能力关键词库中包含与学生职业能力有关的词汇，如“数据结构、SpringBoot、逻辑思维”等。数据预处理的过程将在本章的 3.2 节介绍。

中国知网 https://www.cnki.net

SERCJM 的输出是为两个推荐列表，其中包括模型为每个学生推荐的岗位列表，表示这些岗位与其能力水平相契合，还包括模型为每个岗位推荐的学生列表，表示这些学生符合这些岗位的能力要求，且表现得较好。

SERCJM 的第一个部分是主题词提取，其主要针对两个问题：一是课程能力项与岗位能力项的描述粒度和重点不同，前者贴近课程内容，一般不涉及其他领域，且知识点粒度较细，而后者则以岗位职责为中心，一般会涉及多个领域交叉的知识和技能，两者直接匹配较为困难；二是单个课程能力项与岗位能力项的文本长度短，缺乏上下文信息，在后续匹配时会忽略潜在语义。为此，本文引入预训练主题模型，对课程和岗位能力项进行主题词提取，主题词提取的输入是预处理后的课程能力项和岗位能力项，输出是各个能力项的局部主题词和全局主题词，这两种主题词可以为能力项添加上下文信息、外部语义和上下位词。主题词提取的具体实现将在本章的 3.3 节详细介绍。

SERCJM 的第二个部分是 ACJM 模型，其输入是一对课程和岗位能力项、局部和全局主题词、能力关键词库，输出是一对课程和岗位能力项之间的匹配度。针对现有的文本匹配模型只从语义出发，较少关注其他维度的问题，本文在 ACJM 中设计了一种能力注意力机制，通过能力关键词库遮罩了句子中的非能力词，获得句子在能力粒度的新表示。另外，针对短文本携带语义较少，缺乏上下文信息的问题，ACJM 结合局部和全局主题词，为能力项增添额外信息。最后，ACJM 结合字粒度、句粒度和能力粒度表示进行多维交互匹配，再经卷积池化、全连接和 softmax 层，输出匹配度。按照以上步骤，SERCJM 使用 ACJM 对所有的能力项都两两计算匹配度后，就可以获得课程和岗位能力项的匹配度集合。ACJM 模型的具体实现将在第四章详细介绍。

SERCJM 的第三个部分是学生与岗位推荐计算，其输入是课程能力项-岗位能力项匹配度集合、学生能力得分，输出是为每个学生推荐的岗位列表以及为每个岗位推荐的学生列表。在这部分，本文分三步计算，首先计算出每个学生与一条岗位能力项的匹配度得分，然后累加获得每个学生与一个岗位的匹配度得分，最后计算出每个学生与每个岗位的匹配度得分，组成学生-岗位匹配度矩阵，并以此为依据做出推荐。学生与岗位计算的具体实现将在第五章的 5.1 节详细介绍。

中国知网 https://www.cnki.net

3.2 数据预处理

3.2.1 数据来源

本文研究所用到的数据主要有岗位信息数据、课程信息数据和学生成绩数据，三者都是数据库中的结构化数据，其中课程信息数据和岗位信息数据主要是文本类数据，学生成绩数据主要是数值类数据。

岗位信息数据来源于互联网教育领域的 Z 公司，包括 Z 公司在 2020 年到 2022 年间合作企业的招聘岗位数据，每个岗位包含基本信息、能力需求描述和岗位职责描述等。

课程信息数据和学生成绩数据来源于使用 Z 公司研发的系统 E 辅助工程教育专业认证的 H 大学等十余所高校。原始数据包括各高校的软件工程本科专业在 2020 年到 2022 年间的培养方案及课程体系、学生的课程目标评价，其中每门课程有一个课程大纲，大纲中包含课程基本信息、课程目标、支撑的毕业要求和考核评价指标等，每条课程目标评价包括学生信息、课程目标内容、得分和来源的课程等。

以上数据均为脱敏数据，已取得相关方的授权，并承诺仅用于系统 E 中学生就业推荐模型的研究与迭代。

3.2.2 原始数据的分析与处理

岗位原始数据在数据库中由企业岗位表和招聘需求表两张表组成，企业岗位表中存储着所有的岗位基础信息，招聘需求表中存储着所有岗位的招聘需求。表 3-1 展示了企业岗位表中，本文使用到的字段及其含义。

表 3-1 企业岗位表中使用到的字段及含义

字段	含义	类型
job_id	岗位全局唯一编码	varchar
job_name	岗位名称	varchar
company_name	发布岗位的公司	varchar
domain	岗位所属行业领域	varchar

其中，job_id 是该岗位在数据库中的全局唯一编码，后续用于联表；company_name 包含公司的真实名称，job_name 字段存在着以公司产品名称做前缀的情况，本节对这部分数据采取脱敏处理；domain 代表岗位所属的行业领域，如“计算机软件”类。

中国知网 https://www.cnki.net

表 3-2 招聘需求表中使用到的字段及含义

字段	含义	类型
job_req_id	岗位要求全局唯一编码	varchar
job_id	岗位全局唯一编码	varchar
no	岗位要求序号	int
content	岗位要求具体内容	varchar

表 3-2 展示了招聘需求表中，本文使用到的字段及其含义。招聘需求表的一行数据代表某个岗位的一项招聘要求。其中：job_req_id 是岗位要求的全局唯一编码；job_id 是指该岗位要求所属的岗位的编码；no 是该岗位要求在所属岗位中的顺序编号，即第几条岗位要求；content 是该岗位要求的具体描述（如“掌握 C++、Java、Go 当中至少一门语言”）。凭借 job_id 字段，本文将企业岗位表与招聘需求表连接在一起，就可以获得本文所需的岗位能力要求数据。表 3-3 展示了一个预处理后的示例岗位。

表 3-3 岗位数据示例表

企业	岗位	领域	序号	要求内容
企业 A	IT 运维工程师	计算机软件	1	掌握 Python、Java、Go 其中一种及以上编程语言;
			2	了解 MySQL/PostgreSQL 其中一种数据库的原理，有使用和优化经验者优先;
			3	熟悉 Linux 操作系统，了解虚拟化环境，有实操和使用公有云环境经验者优先;
			4	有激情、愿意分享，自驱能力强，良好的结果导向和抗压能力。

课程信息数据由主要由课程表和课程目标表两张表得到，表 3-4 展示了课程表中，本文使用到的字段及含义。

表 3-4 课程表中使用到的字段及含义

字段	含义	类型
course_id	课程的编码	varchar
course_name	课程的名称	varchar
status	课程的进行状态	int

其中，course_id 是课程的唯一 id，后续用于和课程目标表联表；course_name 是课程名称，后续用于溯源课程目标所属的课程；status 代表课程的进行状态是未开课、进行中、结课中还是已结课，对于还未结课的课程，学生的课程目标评分还不全，不能用于后续的岗位匹配计算。

表 3-5 展示了课程目标表中，本文所使用到的字段及含义。

中国知网 https://www.cnki.net

表 3-5 课程目标表中使用到的字段及含义

字段	含义	类型
course_obj_id	课程目标的编码	varchar
course_id	目标所属的课程编码	varchar
no	课程目标序号	int
content	课程目标的具体内容	varchar

课程目标表每一行数据表示一条课程目标。其中，course_obj_id 是课程目标的唯一 id；course_id 是该课程目标所属的课程 id；no 是该课程目标在课程中的序号，即是第几条课程目标；content 字段则描述了课程目标的具体内容。通过 course_id 字段将课程表与课程目标表联接起来，再使用课程表中的 status 字段加以筛选，就可以获得本文研究所需的课程目标数据。表 3-6 中展示了一门课的课程目标作为示例。

表 3-6 课程数据示例表

课程	序号	课程目标内容
计算机组成原理	1	理解计算机硬件系统的组织和层次结构、理解运算器、存储器、外围设备和接口的基本结构和工作原理。
	2	掌握数的编码表示，能够完成机器码与真值的相互转换，掌握定点数和浮点数的加减乘除计算法则。
	3	理解 CPU 基本组成、工作原理，理解不同的寻址方式对操作数寻址范围的影响。
	4	掌握总线的基本概念、分类和控制；了解总线特性、性能指标、结构。

学生在课程目标上的得分数据保存于学生达成度表，如表 3-7 所示。

表 3-7 学生达成度表部分字段及含义

字段	含义	类型
student_id	学生编码	varchar
course_obj_id	课程目标编码	varchar
student_name	学生姓名	varchar
score	课程目标得分	double

其中：course_obj_id 与 student_id 共同确定了唯一的一条学生-课程目标得分数据，score 是学生在这个课程目标上的总得分，该分数是由学生在不同考核作业中的得分结合作业对课程目标的支撑强度得到的，是 0 至 5 之间的一个数字，且都是 0.5 的倍数，如 1.5、3、4.5。

在对原始数据库的所有相关数据进行联表、筛选字段、去除空值等一系列操作之后，获得的数据统计结果如表 3-8 所示。

中国知网 https://www.cnki.net

表 3-8 预处理后的数据统计结果

数据属性	数量
课程	663
课程目标	3098
岗位	2945
岗位要求	14592
学生	2120
课程目标分词后的词语	91354
岗位要求分词后的词语	262533
一条课程目标的平均字符	79
一条岗位要求的平均字符	46
学生-课程目标得分	3312425

在数据集中，平均每门课有 4.67 个课程能力项，平均每个岗位有 4.95 个岗位能力项；平均每个课程能力项的字符数有 79，而岗位能力项只有 46，因为课程目标一般包含很多个细微的知识点，而岗位能力要求往往简短精练；课程目标得分中的课程目标和学生都是存在重复的，因为不同的学生可能修读相同的课程，也就具备了同样几条课程目标的得分。对于预处理后得到的课程能力项、岗位能力项、学生能力得分，为方便后续章节的描述，本节将它们抽象成集合J、集合C、集合S。其中：

$J = \{j_1, j_2, \dots, j_l\}$代表岗位集，$j_l$表示第$l$个岗位；而$j_l = \{ja_{l,1}, ja_{l,2}, \dots, ja_{l,m}\}$，$ja_{l,m}$代表岗位$j_l$的第$m$条岗位能力项，例如“掌握 Python 编程语言”。

$C = \{c_1, c_2, \dots, c_i\}$代表课程集，$c_i$表示第$i$门课程；而$c_i = \{ca_{i,1}, ca_{i,2}, \dots, ca_{i,j}\}$，$ca_{i,j}$代表课程$c_i$的第$j$条课程能力项，例如“掌握总线的基本概念”。

$S = \{s_1, s_1, \dots, s_p\}$代表学生集，$s_p$表示第$p$位学生；而$s_p = \{ss_{p,1}, ss_{p,2}, \dots, ss_{p,q}\}$，$ss_{p,q}$表示第$p$位学生的第$q$个课程能力项得分，例如学生 1 在“掌握总线的基本概念”上的得分是 4.5。

此外，本节还从中筛选出了一部分岗位能力和课程能力，并依据两者描述的能力契合度，人工标注了 3772 组语义相似的课程能力项和岗位能力项，用于第四章的能力项匹配，详细内容将在第四章描述。

3.2.3 能力关键词库的构建

在第四章基于注意力的课程能力与岗位能力匹配模型中，本文希望模型的关注点尽

中国知网 https://www.cnki.net

可能聚焦在课程能力项和岗位能力项中的能力关键词上，以更好的适配学生岗位匹配场景。而能力关键词的获取仅仅依靠工具是无法精准识别的，必须要经过人类知识的验证，为此，本节将结合词法分析工具与人工标注，去抽取数据样本中的能力关键词。

（1） 能力关键词的定义

能力关键词的抽取并非完全主观，而是需要一定理论和依据的支撑，在抽取之前，本节先讨论某个词是否属于能力关键词的标准。

从高校角度看，学生的能力体现在其收获的教学成果，因此工程类专业一般使用毕业要求来评判学生在毕业时应当具备的能力。我国的《工程教育认证标准》（下简称《标准》）中提到，毕业要求是“对学生毕业时应该掌握的知识和能力的具体描述，包括学生通过本专业学习所掌握的知识、技能和素养”[62]。同时，《标准》将毕业要求分为十二个方面，图 3-2 清晰地展示了某学生在不同毕业要求上达到的水平高低。

图 3-2 某学生的毕业要求雷达图

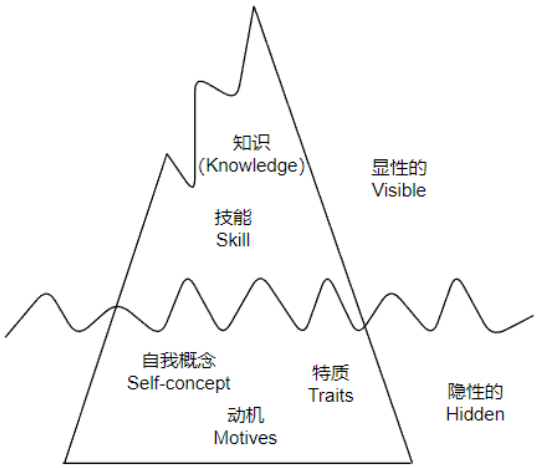

图 3-3 冰山模型

从企业角度看，学生的能力体现在其能否履行岗位职责。针对企业招聘相关的研究

中国知网 https://www.cnki.net

层出不穷，其中最经典、最具代表性的是胜任力理论。胜任力概念最早由哈佛大学的心理学教授麦克利兰[63]提出，他认为胜任力是与工作相关的动机、特质、价值观、态度、知识和能力，并提出了“冰山模型”（图 3-3）。冰山模型大致将个人的能力划分为了知识、技能、自我概念、动机、特质等类别，其中知识、技能是显性的，动机、特质、价值观等是隐性的。方便起见，本节将自我概念、动机、特质等统称为个人素质。

综上所述，本节将《标准》规定的毕业要求与胜任力理论结合在一起，给出本文中能力关键词的定义：能力关键词是，在课程能力项和岗位能力项中出现的、与十二个毕业要求方向有紧密联系、且可以归类到知识、技能、个人素质这三个类别中的词语。

（2） 能力关键词的抽取

基于上文提到的工程教育毕业要求和胜任力理论，本节将对数据集中的岗位能力项和课程能力项进行提取能力关键词的操作，为后续将其用于文本匹配模型做准备。

首先，本节使用 LAC（Lexical Analysis of Chinese）工具根据词性抽取关键词。LAC 是百度于 2020 年开源的词法分析工具[64]，其提供了中文分词、词性标注、专名识别等功能，可以精确和高效地对文本数据进行分词和词性标注。图 3-4 展示了三个分词后的数据样本。

```
[['建设', 'toB Saas', '系统', '基础引擎', ',  ', '包括', '租户', '、', '组织', '、', '权限', '等', ',  ', '为', '上层', '
的', 'CRM', '、', '供应链', '等', '系统', '提供', '高', '配置', '、', '可', '扩展', '的', '基础', '能力', '\n'], ['v',
'n', 'n', 'n', 'w', 'v', 'n', 'w', 'n', 'w', 'n', 'u', 'w', 'v', 'n', 'u', 'nz', 'w', 'n', 'u', 'n', 'v', 'a', 'vn', 'w', 'v', 'v',
'u', 'n', 'n', 'n']]
[['具有', '分析', '和解决', '复杂', '问题', '的', '能力', ',  ', '负责', '攻克', '技术', '方案', '中', '的', '技术', '难
点', ',  ', '快速', '解决', '线上', '问题', '。', '\n'], ['v', 'vn', 'c', 'a', 'n', 'u', 'n', 'w', 'v', 'v', 'n', 'n', 'f', 'u',
'n', 'n', 'w', 'ad', 'v', 's', 'n', 'w', 'n']]
[['JAVA', '基础', '技术', '扎实', ',  ', '熟悉', 'JAVA', '并发', '编程', '、', 'JVM', '垃圾', '回收', '、', '类', '加
载', '策略', '等', '技术', ',  ', '\n'], ['nz', 'n', 'n', 'a', 'w', 'v', 'nz', 'c', 'vn', 'w', 'n', 'n', 'vn', 'w', 'n', 'vn',
'n', 'u', 'n', 'w', 'n']]
```

图 3-4 分词后的部分数据样本

其中，每条句子在分词后得到一个二维数组，第一个数组代表原句的分词结果，第二个数组代表对应位置的词语的词性，如‘n’代表名词，‘v’代表动词。而在高校培养过程和企业岗位招聘中，绝大多数与能力有关的词汇都是名词或动名词，例如图 3-4 中的第三条句子，‘JAVA’是专有名词（‘nz’），‘编程’是名动词（‘vn’），‘JVM’是名词（‘n’）。因此，这里将所有句子中的名词、专有名词、名动词提取出来，作为备选。提取后的部分内容如图 3-5 所示。

中国知网 https://www.cnki.net

```
['Spring', 'Springboot', 'SpringCloud', 'MyBatis', 'Nginx', 'Redis', 'RocketMQ', 'Elasticsearch', '库', '
分表', '中间件']
['Linux', '服务器', '命令', 'Docker', 'k8s', '技术']
['数据库', '技术', 'MySQL/PostgreSQL', '数据库', '优化', 'SQL', '优化']
['基础', '监控', '调用链', '业务', '监控', '网络', '监控', '系统', '开发']
['检测', '根', '分析', '故障', '收敛', '策略', '研究', '落地']
['中间件', '项目', 'rabbitmq', 'activemq', 'kafka', 'redis']
['系统', '分析', '能力', '抽象思维能力', '业务', '场景', '业务', '模型', '问题']
['讨论', '项目', '需求', '分析', '系统', '设计']
['功能', '模块', '设计', '编码', '相关', '文档', '编写']
['前端', '技术', '框架']
['MySql', 'SQLserver', 'Oracle数据库', '增', '删', '改', '技术']
['JAVA', 'PHP', 'C#', '开发', '语言']
['H5', '前端', '开发', '浏览器', '移动端', 'PC端', 'H5', '开发', '认识']
['业务', '风控', '运营', '相关', '系统', '开发']
['编写', '软件', '功能', '规格', '说明书', '设计', '开发', '过程', '系列', '文档']
['系统', '架构', '设计', '核心', '代码', '编写']
['网站', '性能', '优化', '产品', '体验', '优化', '产品', '功能', '迭代', '前端', '开发', '团队', '代码', '前端', '性能']
```

图 3-5 词性抽取后的部分数据样本

可以看到，经过 LAC 词性抽取后的分词结果大部分可以归类为能力类词汇，但也存在一些词性标注错误、语意模糊或与能力评价无关的词汇，如图 3-5 中的‘业务’、‘相关’等词。因此，本节以上一节提及的工程教育认证标准和胜任力理论为支撑依据，对 LAC 词性抽取后的词库进行进一步人工校正，将不符合能力定义的词语筛除，最终获得包含 4530 个词语的能力关键词库。

为方便后续章节表述，这里将能力关键词库表示为集合$ability$，$ability = \{a_1, a_2, \dots, a_k\}$，$a_k$代表第$k$个能力关键词。

3.3 主题词提取

3.3.1 主题词提取的定义

主题词提取的目的是对课程能力项和岗位能力项进行语义增强，原因有二：一是课程能力项紧密贴合课程，一般不涉及其他领域且知识点粒度较细，而岗位能力项则以岗位职责为中心，一般会涉及多个领域交叉的知识、技能，这两者的描述范围和重点是不同的，直接匹配的效果较差；二是后续参与匹配的是一对课程能力项-岗位能力项，它们是两条单独的句子，本身携带的语义较少，缺乏上下文信息，直接匹配容易忽略潜在语义和上下位语义（如“深度学习框架”是“tensorflow”的上位词）。因此，本文在 SERCJM 模型中加入了主题词提取步骤，基于 BERTopic 和领域词库提取能力项的局部和全局主题词，用于刻画一条能力项的上下文信息或增加额外的语义。

中国知网 https://www.cnki.net

其中，能力项、课程、岗位、主题、主题词之间的关系如下：能力项是一条课程目标或岗位需求文本，每条能力项都归属于一门课或一个岗位。而主题是指能用于表示、刻画一段文本内容的一组词语，主题中的每个词语都是主题词。

局部主题的含义如下：由于一条能力项必然归属于一门课程或一个岗位，本节将该课程或岗位下的所有能力项视为一段长文本，对这段长文本进行主题词提取，所得到的一组代表性词语，就是该课程或岗位的主题。而对于一条能力项来说，它所属课程或岗位的主题就是它的局部主题，换言之，同一门课程或岗位下的所有能力项都具有相同的局部主题。

全局主题的含义如下：将所有的能力项合并在一起，进行相似性聚类，获得若干个类簇，此时，每个能力项有且仅有一个归属的类簇，本节将这个类簇包含的所有能力项视为一段长文本，对这段长文本进行主题词提取，所得到的一组代表性词语，就是这个类簇的主题。而对于一条能力项来说，它所属类簇的主题就是它的全局主题，换言之，同一个类簇下的所有能力项具有相同的全局主题。

3.3.2 主题词提取的流程

主题词提取模块的流程如图 3-6 所示。

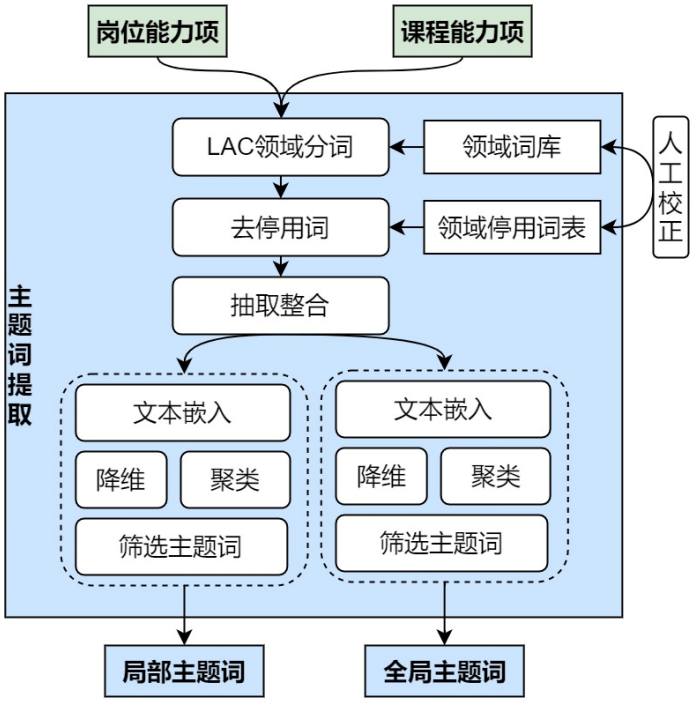

图 3-6 主题词提取的流程

中国知网 https://www.cnki.net

由于后续用于提取主题的预训练主题模型是为英文任务设计的，不能直接用于中文任务，因此第一步是使用 LAC 工具对能力项进行分词。本文的数据集来源于计算机/软件类的高校专业与企业，所以本节选择了一个 IT 行业领域词库作为 LAC 的外部加载词库，这个 IT 领域词库由清华大学开源于 THUOCL（THU Open Chinese Lexicon）[65]数据集，包含了从技术博客、新闻热点、输入法中获得的 IT 领域词语。此外，本节还进行了多轮分词试验，对不准确的分词（如 “direct3d”、“s3c2410”、“TD-SCDMA” 等专有名词）进行了人工校正，重新加入词表，最终获得了 16121 条领域词汇。表 3-9 展示了领域词表的示例。

表 3-9 领域词示例

领域词
Ajax、html5、jetty、Jboss、GUI、算法开销、direct3d、MATLAB、s3c2410、TD-SCDMA

然后，本节对分词后的能力项文本进行去停用词的操作。本节选用的停用词表是由百度、哈尔滨工业大学和四川大学开源的三个中文停用词表合并而来，同时本节基于多轮分词试验的效果，加入了一些频繁出现于课程知识和岗位内容的词，如“概念”、“常见”、“典型”等，最终包含 3750 条停用词。表 3-10 展示了一部分停用词表的内容。

表 3-10 停用词示例

停用词
介绍、涉及、通过、典型、概念、基本、大都、常见、特点、要点、常见、之一、有关、相关

之后，本节将课程能力项和岗位能力项抽取、整合，分为两份数据：一份以能力项为最小单位，将所有能力项合并成一个大集合，用于全局主题词提取；另一份以课程或岗位为最小单位，将所有能力项划分成多个小集合，每个小集合代表一门课程或一个岗位，一门课包含了若干条课程能力项，一个岗位包含了若干条岗位能力项，用于局部主题词提取。

最后，本节通过主题模型 BERTopic 来提取能力项的局部主题词和全局主题词。如第二章所述，BERTopic 先通过预训练文本嵌入模型来获取所有文本的表示，再使用聚类算法对文本嵌入进行聚类，获取类簇，最后使用 c-TF-IDF 算法从类簇的词语中抽取具有代表性的主题词。本节选择的预训练嵌入模型是将能力项输入句子嵌入模型 Sentence-BERT，为适配中文任务，此处选择了多语言版本“paraphrase-multilingual-MiniLM-L12-v2”。本节选择的聚类算法是 K-Means 而不是默认的 HDBSCAN，因为

中国知网 https://www.cnki.net

HDBSCAN 会出现某个异常类簇包含的样本非常多，而其他类簇的样本非常少的情况。

对于全局主题词提取，本节将所有的课程能力项和岗位能力项输入 BERTopic，聚类成若干个簇，并提取出每个簇的 5 个主题词，作为各能力项的全局主题词。对于局部主题词提取，由于 BERTopic 并不能直接对单独一段长文本提取主题词，此处利用其在特定类别中抽取主题（topics_per_class）的特性，将同一课程或岗位下的所有能力项组合成一段长文本，然后以课程名或岗位名作为这段文本的类别标签，以课程或岗位为最小单位，输入到 BERTopic 训练，最后获得每门课或岗位的 5 个主题词，作为各能力项的局部主题词。

获得主题词后，本节将局部主题词、全局主题词组成集合$local_twords$和$global_twords$，用于后续模型的主题词填充。在第四章的 4.2.4 节，本文还将分析选取的主题词的个数对匹配模型效果的影响。

3.3.3 主题模型的效果验证

文本主题模型有多种类别，常见的有概率生成模型（如 Latent Dirichlet Allocation，LDA）、神经主题模型（如 Neural Variational Document Model，NVDM）和 BERTopic 这类预训练主题模型，本节将验证 BERTopic 相比其他两类模型在本文任务上的有效性。

（1） 数据准备

本节实验所用到的原始数据是经 3.2 节预处理后的课程信息集合C和岗位信息集合J，两者分别包含课程能力项和岗位能力项，表 3-11 展示了这两类数据的样例。

表 3-11 课程能力项和岗位能力项的数据样例

课程能力项	岗位能力项
掌握计算机网络体系结构，掌握 TCP/IP 五层模型的基本概念、原理和方法；	熟练掌握 Java 核心技术，掌握 JVM 原理；深入理解常用算法、数据结构和设计模式；

本节从所有的课程能力项和岗位能力项中各抽取了 3000 条数据，合计 6000 条能力项合并在一起，作为后续实验的基础数据。

（2） 评价指标

本节使用主题模型常用的评价指标主题连贯性（Topic Coherence, TC）和主题多样性（Topic Diversity, TD）来评价主题模型。

主题连贯性（Topic Coherence, TC）指的是主题内词的连贯程度。如果一个主题中

中国知网 https://www.cnki.net

的各个词具备相互支撑、相互印证的关系，那么这组词是连贯的。本节使用C_{NPMI}来衡量主题连贯性，C_{NPMI}基于滑动窗口，对给定主题词中的所有单词对的归一化逐点互信息（Normalized Pointwise Mutual Information, NPMI）进行计算，如式 3-1 所示。其中$NPMI(w_i, w_j)$的计算方法如式 3-2 所示。$P(w_i)$表示包含词w_i的文档数除以文档总数，$P(w_i, w_j)$表示包含词w_i和w_j的文档除以文档总数。C_{NPMI}的取值范围是-1 到 1，分数越高，说明主题连贯性越好。

$$C_{NPMI} = \frac{2}{N \cdot (N-1)} \sum_{i=1}^{N-1} \sum_{j=i+1}^{N} NPMI(w_i, w_j) \tag{3-1}$$

$$NPMI(w_i, w_j) = \frac{\log \frac{P(w_i, w_j)}{P(w_i) \cdot P(w_j)}}{-\log P(w_i, w_j)} \tag{3-2}$$

主题多样性（Topic Diversity, TD）指的是主题内词的多样程度。多样性是针对所有主题而言的，若某个主题的主题词中包含更多独有而其他主题没有的词汇，说明这个主题多样性更高。主题多样性的计算公式如式 3-3 所示，其中N代表主题的总数，d_i代表第i个主题相较其他主题独有的主题词个数除以每个主题拥有的主题词数。

$$TD = \frac{1}{N} \sum_{i=1}^{N} d_i \tag{3-3}$$

（3） 实验结果

本节将主题词提取中的 BERTopic 替换成两个具有代表性的其他类别的主题模型，并与原先效果作对比，以证明选择 BERTopic 在本文任务上的有效性。这两个模型分别是传统主题模型 LDA 与神经主题模型 NVDM-GSM（Gaussian-Softmax）。

LDA[66]是基于概率模型的无监督主题模型，常用于提取大规模文档集（document collection）或语料库（corpus）中潜在的主题信息。LDA 认为文档的词语的生成过程是，先通过文章产生话题，再通过话题产生词语，而得到主题就是从具体的文档词语反过来估计文档的主题。在 LDA 算法中，一篇文档代表了若干主题组成的概率分布,而一个主题又代表了若干单词组成的概率分布，其模型拟合的结果就是每个主题的核心关键词和具体概率。

NVDM-GSM[67]是一种神经主题模型，基于变分自编码器实现，GSM 是 NVDM 的一个变种。NVDM-GSM 隐空间的先验采用了高斯分布，而输入输出仍然是词袋模型。它相对于过去模型有着两点优化：一是对词袋表示的重构，二是对隐空间的约束（以 KL

中国知网 https://www.cnki.net

散度度量）。从变分分布$Q_{\varphi}(z|x)$中采样出隐变量z后，模型会通过 Softmax 层将z规范化，并将规范后的向量作为文档-主题分布θ，当训练完成时，以 one-hot 向量输入解码器，则可提取到对应得主题-词分布。LDA 与 NVDM-GSM 主要的一个区别在于先验分布的选择，LDA 以 Dirichlet 分布作为文档-主题分布的先验，而 NVDM 以多元高斯分布作为文档-主题分布的先验。

本节将主题词提取的主题模型替换成 LDA 与 NVDM-GSM，其他结构和操作不变，其中：LDA 的主题数量 num_topics 设置为 80，主题和词的分布的先验参数均设置为训练中自动学习（auto），迭代次数 passes 设置为 10；NVDM-GSM 的主题数量 n_topic 设置为 80，训练轮次 num_epochs 设置为 10；BERTopic 的嵌入模型设置为“paraphrase-multilingual-MiniLM-L12-v2”，每个主题提取的词数 top_n_words 设置为 5 个，主题个数 nr_topics 设置为 80；其余参数对模型效果的影响不大，此处不再赘述。本节进行了 5 轮对比实验并取平均作为结果，如表 3-12 所示。

表 3-12 主题模型的效果对比

模型	评价指标	
	$TC(c_npmi)$	TD
LDA	-0.061	0.643
NVDM-GSM	-0.077	0.679
BERTopic	**0.152**	**0.748**

可以看到，在主题连贯性方面，NVDM-GSM 的评分最低，但与 LDA 的表现差别不大，仅相差 0.016，而 BERTopic 的效果最好，较 LDA 高出 0.213；主题多样性方面，LDA 与 NVDM-GSM 表现都一般，意味着提取出的词重复度比较高，两者都低于 BERTopic，说明 BERTopic 提取出的主题的区分度比较高。分析原因，LDA 基于词袋表示文本，忽略了词的顺序与深层次语义，NVDM-GSM 虽然引入了神经网络，但输入仍然是文本词袋表示，这两者应用在短文本上的效果差强人意，BERTopic 则使用语言预训练模型来学习文本与上下文特征。本节的实验结果充分说明了 BERTopic 相比另外两种类型的主题模型，在本文的数据集和任务上更加有效，因此本节选用 BERTopic 来做主题词提取是合理的。

中国知网 https://www.cnki.net

3.3.4 主题词提取的结果

将原始数据集进行主题词提取后，获得的是能力项的全局主题词和局部主题词，本节将分别展示分析这两个结果。

对于全局主题，本节将能力项单独抽出、合并，输入模型。当超参数中不限制主题个数时，模型通过聚类，获得了 123 个类簇，同时，模型从每个类簇包含的能力项分词中选出了 c-TF-IDF 分数最高的 5 个主题词来作为这个类簇的主题。经过对结果的分析，发现其中仍然有较为相似的主题，如“游戏、游戏开发、游戏客户端、游戏制作、引擎开发”与“unity3d、unreal、ue4、游戏引擎、3d 引擎”等，因此本节将相似的主题做了合并，将全局主题数减少到 80 个，也就是最终结果包含 80 个类簇及其主题，图 3-7 展示了其中四个主题的主题词及其 c-TF-IDF 分数。

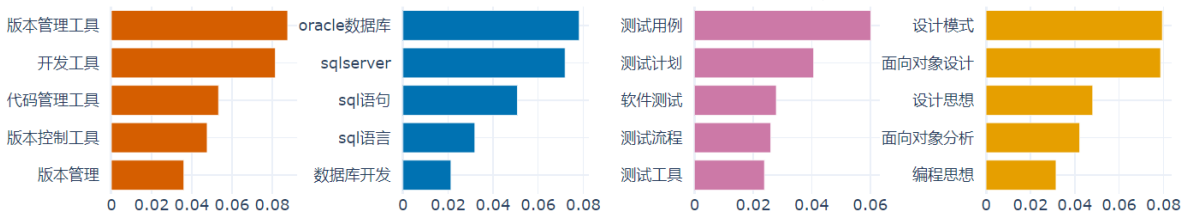

图 3-7 样例主题的主题词及其 c-TF-IDF 分数

由图容易看出各主题的分类原则，如第一个主题与 git、svn 等代码版本管理工具有关，第二个主题与数据库有关，第三个主题与软件测试相关，第四个主题与面向对象设计有关。各主题之间的区分度较高，说明引入全局主题词有助于增强不同类簇的能力项之间的差异性，让匹配过程更加精细化。同时，同一个主题内的主题词存在一定的语义重复，因此，在后续的匹配模型中，本文考虑只截取部分主题词，来尽量避免重复词汇带来的影响，获得最优的效果。

表 3-13 样例能力项及其全局主题

能力项	全局主题
熟悉主流关系型数据库，对于数据库结构、SQL 优化有一定经验	oracle 数据库、sqlserver、sql 语句、sql 语言、数据库开发
掌握 UML 语言的基础知识和面向对象的基本概念，具备使用面向对象思想分析、推演、解决软件工程问题的能力。	设计模式，面向对象设计，设计思想，面向对象分析，编程思想

表 3-13 展示了两个样例，它们是两个能力项及其所属的全局主题。可以看到，第一个能力项是一个岗位能力项，其内容描述了关系型数据库和 SQL 等技能，而全局主题

中国知网 https://www.cnki.net

包含了 oracle、sqlserver 等更具体的关系型数据库；第二个能力项是一个课程能力项，其主要描述了 UML 及面向对象思想，而全局主题则包含了设计模式等相关词汇。这说明了全局主题词确实为原有能力项提供了额外语义信息，并且这部分信息与原有能力项的关联较为密切。

对于局部主题词，本节将数据集按课程或岗位为单位输入模型，最终对每一个课程或岗位，提取出 5 个主题词。表 3-14 是对部分课程进行局部主题词提取后得到的结果。可以看到，不同课程间的主题词同样区分较为明显，说明局部主题词的加入有利于相似的能力项更接近，而不相似的能力项更容易区分，从而使得匹配效率和精确度更高。

表 3-14 部分课程提取出的局部主题词

课程	局部主题词
《数据库技术》	数据库，关系型数据库，sql 语句，工程应用，模式
《数据结构》	算法，数据结构，分析，综合应用，基本数据结构
《计算机网络》	网络，计算机网络，密码体制，网络安全，分析
《软件质量保证与测试》	测试，软件测试，测试数据，软件开发过程，需求
《操作系统》	操作系统，计算机系统，处理机，功能，分析
《软件项目管理》	软件，管理，经济，项目管理，过程

为验证局部主题词提取的必要性，本节还将以上课程的能力项全部抽出，放到全局主题提取模型中进行预测。如表 3-15 所示，此处以《数据库技术》的一条能力项为例。

表 3-15 一条课程能力项的全局主题词和局部主题词

能力项	全局主题词	局部主题词
熟练掌握 SQL 语句，能利用基本查询语句来检索数据库中满足条件的数据记录，能熟练使用 SQL 语句对数据库进行数据维护	oracle 数据库、sqlserver、sql 语句、sql 语言、数据库开发	数据库、关系型数据库、sql 语句、工程应用、模式

其描述为“熟练掌握 SQL 语句，能利用基本查询语句来检索数据库中满足条件的数据记录，能熟练使用 SQL 语句对数据库进行数据维护”，其预测得到的全局主题词是“oracle 数据库、sqlserver、sql 语句、sql 语言、数据库开发”，都是比较偏向工程实践的词汇，而其局部主题词为“数据库、关系型数据库、sql 语句、工程应用、模式”，是比较偏向理论的词汇，原因在于全局主题模型不但包含了课程信息，也包含了岗位信息，因此会更联系业界实践和工作岗位内容。由此说明，全局主题模型和局部主题模型得到的主题词并不完全等同，甚至在描述粒度和范围上有一定差异，因此，在主题词提取模块中，分别提取全局和局部主题词是有必要的。

中国知网 https://www.cnki.net

3.4 本章小结

本章首先对 SERCJM 模型的整体结构和流程做了概述，并分别描述了其三个部分的输入、输出和作用；其次，对 SERCJM 模型所用到的数据进行了预处理，包括原始数据的分析处理和能力关键词库的构建；最后详细介绍了 SERCJM 模型中主题词提取部分的设计和实现，通过实验验证了其中所选择的主题模型的有效性，并对主题词提取的结果做了展示和分析。

在下一章，本文将紧接着介绍 SERCJM 模型的第二个部分，即基于注意力的课程能力与岗位能力匹配模型。

中国知网 https://www.cnki.net

第四章 基于注意力的课程能力与岗位能力匹配模型

上一章提到，现有学生与岗位的匹配推荐方法缺乏评价客观性与可行性，因此本章旨在利用相对客观的专业认证教学数据，将学生与岗位的匹配细化成课程能力与岗位能力的匹配。具体地，以教学数据中的课程目标代表学生在课程收获的能力，即课程能力，以岗位招聘描述代表岗位期望学生具备的能力，即岗位能力。

另外，课程能力与岗位能力的匹配实质上是两条短文本之间的匹配，当下有类似研究将求职者简历和岗位需求作为两段文本，进行人岗匹配，但它们在学生就业推荐场景下，存在两个问题：一是往往只从往往只从原始文本出发，没有对能力相关词汇给予显式关注，导致匹配结果不准确；二是忽略了外部信息的引入，无法解决短文本缺乏上下文的问题，导致部分句子匹配困难。

由此，本章提出了一个基于注意力的课程能力与岗位能力匹配模型（ACJM）。针对第一个问题，在 ACJM 中设计了一种能力注意力机制，对句子中的能力相关词汇显式的给予更多关注；针对第二个问题，通过主题词提取模型在 ACJM 中引入了局部和全局主题词，为短文本提供额外信息；最后，ACJM 还结合了表征式和交互式文本匹配的方法，综合考虑句子的字粒度、句粒度和能力粒度语义进行多维交互匹配。

第三章的 3.3 节已经介绍了 SERCJM 模型的第一部分的实现，ACJM 作为 SERCJM 模型的第二部分，本章将在 4.1 节详细介绍它的结构和流程，然后在 4.2 节设计一系列的实验，对其有效性进行验证。

4.1 ACJM 模型的结构

ACJM 模型的任务是计算一条课程能力和一条岗位能力之间的匹配度，其首先通过表征式技术构建两个句子的表示，再通过交互式技术对两者进行交互匹配，以获得更深层的匹配特征，最后计算匹配度结果。ACJM 模型由七个部分组成，包括主题填充层、文本嵌入层、句子表示层、能力注意力层、多维匹配层、聚合层和输出层，其具体结构图如图 4-1 所示。

图中横向的矩形代表原始文本，纵向的矩形代表文本中一个字的嵌入向量；图中的蓝色代表主题词，绿色代表原始能力项，黑色代表被遮罩的非能力词。以课程能力项c和岗位能力项j的匹配度计算为例，ACJM 模型的输入是c、j、经主题词提取得到的局部和

中国知网 https://www.cnki.net

全局主题词、经数据预处理得到的能力关键词库，ACJM 模型的输出是c和j的匹配度，取值范围是 0 到 1。

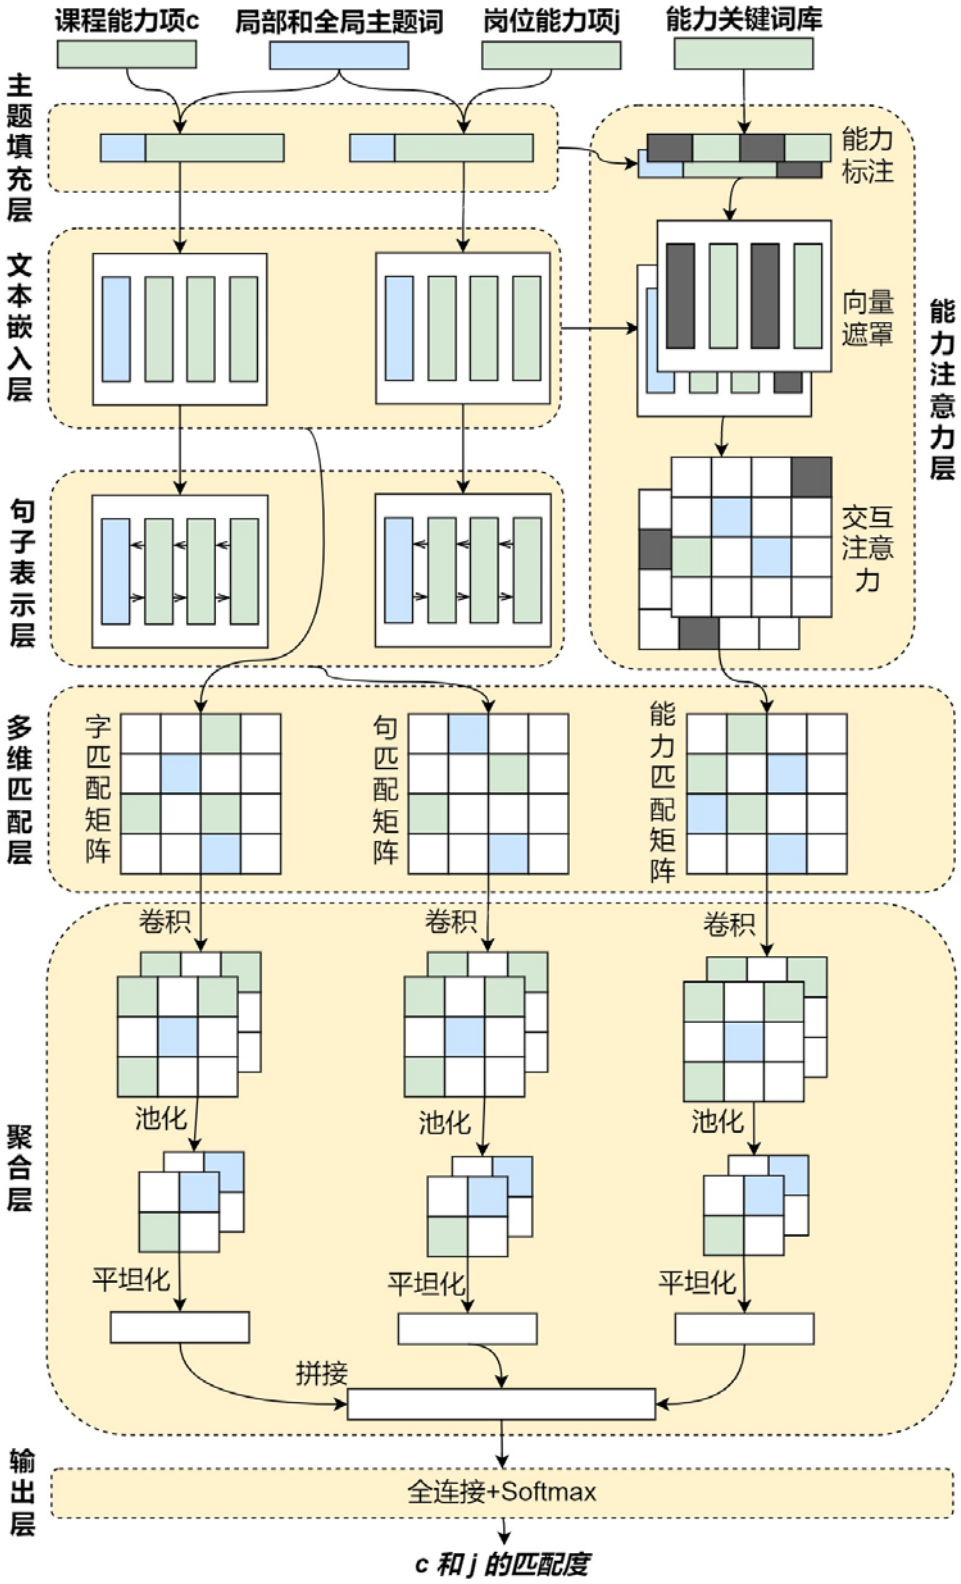

图 4-1 基于注意力的课程能力与岗位能力匹配模型结构图

ACJM 中每一层的功能及流程如下：

中国知网 https://www.cnki.net

（1） 主题填充层：模型从输入的局部和全局主题词中找到课程能力项c和岗位能力项j的局部和全局主题词，并选择一定数量的主题词拼接到原句，得到拼接了主题词的能力项c'和j'；

（2） 文本嵌入层：在文本嵌入层，模型将c'和j'输入 BERT，获得c'和j'的字粒度表示矩阵；

（3） 句子表示层：在句子表示层，模型将得到的字粒度矩阵输入 Bi-LSTM，获取c'和j'的句粒度表示矩阵；

（4） 能力注意力层：模型结合能力关键词库，获得c'和j'的非能力词遮罩序列，再根据遮罩序列和 BERT 的c'和j'的字粒度表示矩阵，获得遮罩非能力词后的字粒度表示矩阵，最后通过交互注意力机制获得c'和j'的能力粒度表示矩阵；

（5） 多维匹配层：模型将c'和j'的字、句、能力粒度的表示矩阵分别相乘，获得三个交互匹配矩阵；

（6） 聚合层：在聚合层，模型通过卷积、池化提取交互匹配矩阵的特征，再将其压缩成一维向量；

（7） 输出层：在输出层，模型将压缩后的向量拼接在一起，经全连接和 Softmax 输出两条能力项的匹配度。

将所有的能力项都经由上述操作两两计算匹配度后，最终可以获得课程能力项-岗位能力项的匹配度集合$Sim = \{(ca, ja, sim)_i\}_{i=1}^{N}$，其中$(ca, ja, sim)_i$由课程能力项$ca$和岗位能力项$ja$及它们之间的匹配度$sim$组成。下面将分节详细说明 ACJM 中每一层的具体操作。

4.1.1 主题填充层

针对短文本能力项缺乏上下文带来的匹配困难问题，本文在 ACJM 中添加了主题填充层来为课程能力项和岗位能力项拼接主题词，引入外部信息和上下文语义。

主题词填充层利用上一章主题词提取模型输出的全局主题词集合$global_twords$和局部主题词集合$local_twords$，对岗位能力项j和课程能力项c进行主题词填充，最终输出包含主题词的岗位能力项j'和课程能力项c'。以岗位能力项j为例，主题填充层从主题模型输出的 80 个主题中找到j所属的类簇，然后获取这个类簇的主题词作为j的全局主

中国知网 https://www.cnki.net

题，再找到j所属的岗位，获取这个岗位的主题词作为j的局部主题，换言之，属于同一个类簇的能力项具有相同的全局主题，属于同一个岗位的能力项具有相同的局部主题。课程能力项c同理。

另外，由于本层同时填充了全局主题和局部主题，为原句新增的字符较多，有可能影响原始文本的表示，所以本节采用一个参数 T 来定义主题填充层从全局和局部主题中选择的主题词个数，以岗位能力项j为例，选取j的全局主题的前 T 个词，拼接在一起，得到全局主题文本j_G，同时，选取j的局部主题的前 T 个词，得到局部主题文本j_L，最后将j_G和j_L与原始的j拼接，得到填充后的岗位能力项j'。课程能力项c同理。如公式 4-1 和 4-2 所示。

$$j' = [j_L; j_G; j] \tag{4-1}$$

$$c' = [c_L; c_G; c] \tag{4-2}$$

4.1.2 文本嵌入层

为完成后续的文本匹配，需要将文本向量化，因此，本文在 ACJM 中添加了文本嵌入层来对主题词填充后的岗位能力项j'和课程能力项c'进行嵌入式编码。

文本嵌入层将扩充后的单个岗位能力项j'和课程能力项c'的各个字（Token）转化为字向量。本节使用预训练语言模型 BERT 进行文本 Token 的向量化，如下所示：

$$E_{c'} = BERT(c') \tag{4-3}$$

$$E_{j'} = BERT(j') \tag{4-4}$$

其中，$E_{c'} = \{e_1, e_2, \dots, e_{m'}\} \in \mathbb{R}^{m' \times d}$表示课程能力项$c'$经过 BERT 模型之后得到的表示矩阵，$E_{j'} \in \mathbb{R}^{n' \times d}$表示岗位能力项$j'$经过 BERT 模型之后得到的表示矩阵。

4.1.3 句子表示层

文本嵌入层输出的表示矩阵仅仅是字粒度的，没有考虑句子的序列信息，因此，本文在 ACJM 中添加了句子表示层来从句子序列维度对课程能力项c'和岗位能力项j'进行进一步表示。

句子表示层通过双向长短期记忆网络（Bi-LSTM）从两个方向捕捉句子的语义特征，增强模型对文本序列语义的表示能力。在 Bi-LSTM 中，每个时刻都存在由正向 LSTM

中国知网 https://www.cnki.net

和反向 LSTM 计算得到的隐层输出$\vec{h}_t$和$\overleftarrow{h}_t$，其中$\vec{h}_t$由当前时刻的输入e_t和前一时刻的正向输出$\vec{h}_{t-1}$共同决定，$\overleftarrow{h}_t$由当前时刻的输入e_t和前一时刻的反向输出$\overleftarrow{h}_{t-1}$共同决定。为结合前向与后向的文本信息，句子表示层将每一时刻正向 LSTM 和反向 LSTM 的隐层输出$\vec{h}_t$和$\overleftarrow{h}_t$进行拼接。以课程能力项c'为例，其在句子表示层 t 时刻的具体过程如下：

$$\vec{h}_t = LSTM(e_t, \vec{h}_{t-1}) \tag{4-5}$$

$$\overleftarrow{h}_t = LSTM(e_t, \overleftarrow{h}_{t-1}) \tag{4-6}$$

$$h_t = \vec{h}_t \oplus \overleftarrow{h}_t \tag{4-7}$$

最后，句子表示层将各个时刻的 Bi-LSTM 输出拼接，如式 4-8，获得课程能力项c'的句粒度表示矩阵$H_{c'} \in \mathbb{R}^{m' \times d}$和岗位能力项$j'$的句粒度表示矩阵$H_{j'} \in \mathbb{R}^{n' \times d}$。

$$H = [h_1, h_2, \cdots, h_{\mathrm{m}}] \tag{4-8}$$

4.1.4 能力注意力层

针对以往的就业匹配模型没有显式考虑学生能力的问题，为提高模型的准确率，本文在 ACJM 中添加了能力注意力层来对句子中的能力类词汇予以额外关注，并获得句子在能力粒度的表示矩阵。

能力注意力层首先通过能力关键词库来对主题词扩充后的岗位能力项j'和课程能力项c'进行能力关键词标注，获得它们在能力关键词上的标注序列。本节以扩充后的课程能力项$c' = \{cw_1, cw_2, \dots, cw_{m+G+L}\}$为例，描述其能力关键词标注过程，为下文表述简便，令$m + G + L = m'$，G和L分别是c'的全局主题词和局部主题词的长度。

首先，本节使用 LAC 工具对课程能力项c'进行分词，如公式 4-9：

$$c_{words}, c_t = LAC(c') \tag{4-9}$$

$c_{words} = [c_1, c_2, \cdots, c_s]$表示能力项的分词序列，$c_t = \{cw_1{:}1, cw_2{:}1, \cdots, cw_{m'}{:}s]$表示对应的分词映射表。其中，$c_s$表示课程能力项$c'$经过 LAC 工具分词之后得到的第$s$个词语，分词映射表$c_t$包含了原文本序列中每个字 Token 所属的词语的序号，$cw_{m'}{:}s$表示课程能力项c'中最后一个字 Token 属于分词序列c_{words}中的第s个词语。

接着，对能力关键词词库$ability = \{a_1, a_2, \dots, a_k\}$进行遍历，判断分词序列$c_{words}$中

中国知网 https://www.cnki.net

的各个词是否为能力关键词，并进行标注，如公式 4-10，其中$m(c_s)$表示分词c_s对应的标注结果。

$$m(c_s)=\begin{cases}1, if\ c_s \in ability\\ 0, if\ c_s \notin ability\end{cases} \tag{4-10}$$

最后，根据分词映射表c_t和分词标注结果$m(c_s)$得到各个字 Token 的能力关键词标注结果$c_mask=\{m(c'_{c_t[cw_i]})\}_{i=0}^{m'}$。同理，可得到岗位能力项$j'$的能力关键词标注结果$j_mask=\{m(j'_{j_t[jw_i]})\}_{i=0}^{n'}$，其中$n'=n+G+L$，$G$和$L$分别是$j'$的全局主题词和局部主题词的长度。

在获得能力关键词标注结果后，能力注意力层通过交互注意力机制来获取两条能力项的能力粒度表示矩阵。这步操作的目的是让课程能力项c'重点关注岗位能力项j'中能力关键词，让岗位能力项j'重点关注课程能力项c'中的能力关键词。注意力机制使用$Q\in\mathbb{R}^{q\times d}$代表查询嵌入矩阵，$K\in\mathbb{R}^{k\times d}$代表键嵌入矩阵，$V\in\mathbb{R}^{v\times d}$代表值嵌入矩阵，其具体做法是让查询语句$Q$中的每个词去关注键语句$K$中的每个词，获得相关重要性权重，再将权重结果作用在值V语句，如公式 4-11 所示，本文使用$Attention(\cdot)$表示注意力机制。

$$Attention(Q,K,V)=softmax\left(\frac{QK^T}{\sqrt{d}}\right)V \tag{4-11}$$

能力注意力层将课程能力项c'的表示矩阵$E_{c'}$与课程能力项c'的能力关键词标注结果c_mask进行点乘得到课程能力项c'的能力表示矩阵$E_{ca}\in\mathbb{R}^{m'\times d}$，同理可得岗位能力项$j'$的能力表示矩阵$E_{ja}\in\mathbb{R}^{n'\times d}$。具体公式如下：

$$E_{ca}=c_mask\ E_{c'} \tag{4-12}$$

$$E_{ja}=j_mask\ E_{j'} \tag{4-13}$$

接着，使用交互注意力机制得到课程能力项c'和岗位能力项j'在额外关注对方的能力关键词后的表示矩阵，具体公式如下：

$$E'_{c'}=Attention(E_{c'},E_{ja},E_{ja}) \tag{4-14}$$

$$E'_{j'}=Attention(E_{j'},E_{ca},E_{ca}) \tag{4-15}$$

其中，$E'_c\in\mathbb{R}^{m'\times d}$表示课程能力项在关注岗位能力项关键词后的能力粒度表示矩阵，$E'_j\in\mathbb{R}^{n'\times d}$表示岗位能力项在关注课程能力项关键词后的能力粒度表示矩阵。

中国知网 https://www.cnki.net

4.1.5 多维匹配层

在获得课程能力项c'和岗位能力项j'的字粒度、句粒度和能力粒度的表示矩阵后，为获得不同维度的匹配特征，进一步提高匹配模型的准确率，本文在 ACJM 中添加了多维匹配层，对两者进行充分交互。

多维匹配层对课程能力项c'和岗位能力项j'的表示从字、句和能力三个粒度进行交互匹配，获得三个粒度的匹配矩阵M_w、M_s和M_a，具体地，包括词粒度交互匹配、句粒度交互匹配和能力粒度交互匹配。

词粒度交互匹配指的是对文本嵌入层输出的两个能力项的字粒度表示矩阵进行交互，即将两个表示矩阵相乘，获得字粒度匹配矩阵$M_{\mathrm{w}} \in \mathbb{R}^{m' \times n'}$，如公式 4-16 所示。

$$M_w = {E_{c'}}^T E_{j'} \tag{4-16}$$

句粒度交互匹配指的是对句子表示层输出的两个能力项的句粒度表示矩阵进行交互，即将两个表示矩阵相乘，获得句粒度匹配矩阵$M_{\mathrm{s}} \in \mathbb{R}^{m' \times n'}$，如公式 4-17 所示。

$$M_s = {H_{c'}}^T H_{j'} \tag{4-17}$$

能力粒度交互匹配指的是对能力注意力层输出的两个能力项的能力粒度表示矩阵进行交互，即将两个表示矩阵相乘，获得能力粒度匹配矩阵$M_a \in \mathbb{R}^{m' \times n'}$，如公式 4-18 所示。

$$M_a = {E'_{c'}}^T E'_{j'} \tag{4-18}$$

4.1.6 聚合层

聚合层旨在融合匹配层得到的词粒度匹配矩阵M_w、句粒度匹配矩阵M_s和能力粒度匹配矩阵M_a。该层采用二维卷积神经网络和最大池化操作挖掘三个匹配中含有的各个匹配特征，并对它们平坦化，得到词粒度匹配特征${M_w}' \in \mathbb{R}^d$、句粒度匹配特征${M_s}' \in \mathbb{R}^d$和能力粒度匹配特征${M_a}' \in \mathbb{R}^d$。最终，该层将得到的三个匹配特征进行拼接，得到最终匹配向量x，如公式 4-19 所示。

$$x = [M'_{\mathrm{w}}; M'_{\mathrm{s}}; M'_{\mathrm{a}}] \tag{4-19}$$

中国知网 https://www.cnki.net

4.1.7 输出层

输出层的目的是通过全连接层，将最终的匹配向量x映射到对应分类中，以得到最终的匹配分数的概率分布y，如公式 4-20 所示，其中W和b为可训练的参数。

$$y = softmax(Wx + b) \tag{4-20}$$

4.1.8 损失函数

本章采用交叉熵作为基于注意力的课程能力与岗位能力匹配模型的损失函数，具体公式如 4-21 所示，其中y为目标结果，p和$1-p$分别是模型将两条能力项预测为相关或不相关的概率。该模型的目标是通过不断地训练，缩小所有课程能力项和岗位能力项中目标结果y和预测结果p和$1-p$之间的交叉熵错误率。

$$loss = -[y\log(p) + (1-y)\log(1-p)] \tag{4-21}$$

4.2 ACJM 模型的验证

本节将通过阶段性实验来验证本章所提出的 ACJM 模型的有效性。本节将首先介绍 ACJM 模型的评价指标，其次介绍用于训练和验证 ACJM 模型的数据准备工作，最后对各阶段的实验结果进行分析。本节主要包括四个方面的实验：主题词个数 T 对模型效果的影响实验、与基线模型的对比实验、与人岗匹配领域先进模型的对比实验、消融实验。

4.2.1 评价指标

本节介绍用于验证 ACJM 模型的评价指标。为验证 ACJM 模型在文本匹配任务上的有效性，本节选取了精确率(Precision)、召回率(Recall)、F1 值(F1-score)作为模型的评价指标。精确率是指以模型预测结果为依据，对于每个分类类别的测试数据，计算预测为该类类别的样本中预测正确的比例，具体公式如 4-22 所示，其中TP表示正样本被预测对的数量，FP表示预测为正样本，但实际是负样本的样本数量。

$$Precision = \frac{TP}{TP + FP} \times 100 \tag{4-22}$$

而召回率以实际样本为依据，对于正负样本，计算预测为该类的样本占实际为该类的样本的比例，具体公式如 4-23 所示，其中FN表示预测为负样本但实际为正样本的样

中国知网 https://www.cnki.net

本数量。

$$Recall = \frac{TP}{TP + FN} \times 100 \tag{4-23}$$

由于单独使用精确率和召回率无法准确的评估本模型的表现好坏，所以本文使用 F1 值(F1-score)调和精确率和召回率的评价结果，F1 值的公式表示如式 4-24 所示。

$$F1 - score = \frac{2 \times Recall \times Precision}{Precision + Recall} \tag{4-24}$$

4.2.2 数据准备

本节介绍训练和验证 ACJM 模型所用到的数据。原始数据有来自 3.2.2 节的“课程能力-岗位能力-是否相关”标注数据（D）、来自 3.2.3 节的能力关键词库$ability$、来自 3.3 节的全局主题词集合$global_twords$和局部主题词集合$local_twords$。其中，数据集D包含 3772 组数据，每组数据由一条课程能力项、一条岗位能力项和一个是否相关的标签组成，数据样例如表 4-1 所示。

表 4-1 数据集D的样例

课程能力项	岗位能力项	标签
熟练掌握 SQL 语句，能利用基本查询语句来检索数据库中满足条件的数据记录，能熟练使用 SQL 语句对数据库进行数据维护；	掌握 Mysql/Oracle，精通 sql 语句、存储过程等 sql 知识，了解数据库性能优化原理;	1
能够对操作系统的工作机制进行分析、研究，能够搭建适合的实验环境对操作系统中处理机调度、存储管理等功能模拟实现；	负责软件系统架构设计、概要设计、详细设计、编码实施、测试和文档编写；	0

其中，标签为 1 代表课程能力项与岗位能力项具有相关性，标签为 0 代表课程能力项与岗位能力项不具有相关性，从表 4-1 的样例可以看出，第一组的两个能力项描述的都是与 SQL、数据库相关的能力，因此标签为 1；而第二组的两个能力项分别描述了操作系统和系统设计相关的能力，虽然都包含“系统”二字，但前者指的是计算机操作系统，而后者指的是应用开发中的软件系统，因此标签为 0。数据集D中标签为 1 的数据有 1860 条，标签为 0 的数据有 1912 条，两者比例接近。本节选出 3000 条数据作为训练集，剩余的 772 条数据用作测试集，训练集和测试集的比例约为 8:2。

对这 3772 组数据来说，每一条课程能力或岗位能力，都具备 5 个全局主题词和 5 个局部主题词。以表 4-1 的两个课程能力项为例，它们的全局主题词和局部主题词如表 4-2 所示。可以看到，全局主题词和局部主题词的字符数与能力项相近，并且有重复内容，

中国知网 https://www.cnki.net

因此后续在实验中将从中选择一部分拼接到能力项。

表 4-2 样例数据的全局和局部主题词

能力项	全局主题词	局部主题词
熟练掌握 SQL 语句，能利用基本查询语句来检索数据库中满足条件的数据记录，能熟练使用 SQL 语句对数据库进行数据维护；	oracle 数据库、sqlserver、sql 语句、sql 语言、数据库开发	数据库，关系型数据库，sql 语句，工程应用，模式
能对操作系统的工作机制进行分析、研究，通过搭建适合的实验环境对操作系统中处理机的调度、存储管理等功能模拟实现；	Linux，linux 操作系统，Unix 系统，windows，操作系统	操作系统，计算机系统，处理机，功能，分析

而来自 3.2.3 节的能力关键词库包含 4530 个能力关键词，能力关键词样例如表 4-3 所示。其中，数据结构、计算机网络是知识类能力，Word、MyBatis、PyTorch 是技能类能力，逻辑思维、想象力是个人素质类能力。

表 4-3 能力关键词样例

能力关键词
数据结构，计算机网络，Word，MyBatis，PyTorch，逻辑思维，想象力

4.2.3 实验配置

在本实验中，ACJM 模型中的课程能力项和岗位能力项在进行主题词扩充之后的最大长度定义为 120，若文本的长度大于该参数值，则对文本从前往后截取字符，若文本的长度小于该参数值，则使用 PADDING 操作对文本进行补全。模型中的 BERT 模型使用 bert-base-chinese 版本进行权重初始化，Bi-LSTM 模型的权重使用随机初始化；dropout 概率定义为 0.2，初始学习率设置为 1e-5，优化器采用 AdamW，batch 数为 32，epoch 数量为 15。实验硬件环境包括两张 NVIDIA Quadro K6000 显卡，共 24G 显存，软件环境包括 Python 3.6，Pytorch 1.2，Cuda10.0。

4.2.4 主题词个数对模型效果的影响

本节设置实验探究超参数主题词数 T 为不同的取值时，对 ACJM 模型的匹配效果影响。由于主题词的排序是由 c-TF-IDF 分数决定的，意味着排序越靠前的主题词，越能代表这个主题，而越靠后的则越具体越细节，因此，本节在为一条能力项填充主题词时，按从前往后的顺序，分别选取 T 个局部主题词和 T 个全局主题词，拼接在该能力项的句首，再对拼接后的整句进行长度截断或补充。本节选取 1、2、3、4 和 5 作为超参数主

中国知网 https://www.cnki.net

题词数 T 的取值，实验结果如表 4-4 所示。

表 4-4 主题词个数 T 对 ACJM 模型的效果影响(%)

T 取值	精确率(Precision)	召回率(Recall)	F1 值(F1-score)
1	81.35	80.10	80.72
2	**84.46**	**82.43**	**83.43**
3	81.99	80.23	81.10
4	77.98	74.23	76.06
5	70.47	65.31	67.79

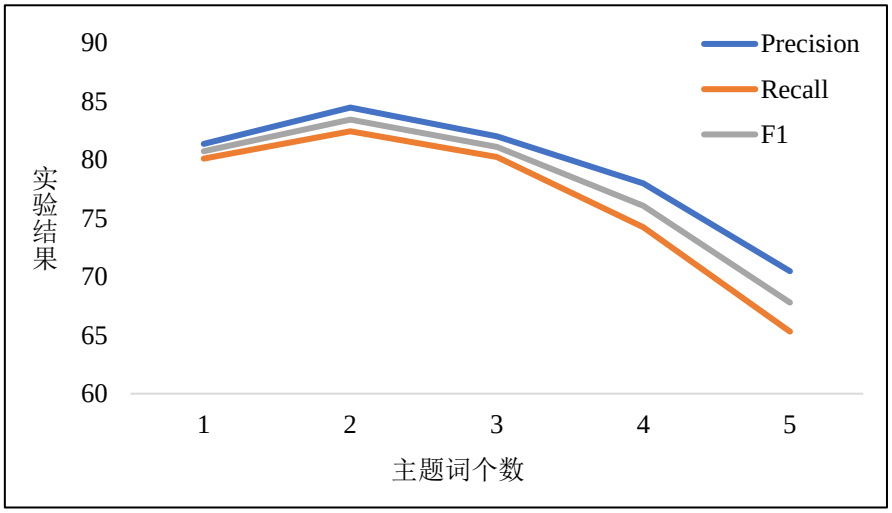

图 4-2 主题词个数对模型效果的影响

图 4-2 展示了 ACJM 模型在不同主题词个数时的匹配实验结果。从图中可以看出，模型在各个评价指标上的结果随着主题词个数的增大，先升高再下降，在主题词个数为 2 时取得最优表现，精确率为 84.46、召回率为 82.43、F1 值为 83.43，在主题词个数为 5 时表现最差，精确率为 70.47，召回率为 65.31，F1 值为 67.79。观测数据分析可知，主题词个数从 1 到 2 时，模型的整体匹配表现变优，说明添加一定主题词的有利于为模型引入额外的匹配信息，提升模型的匹配效果；而从主题词个数从 2 变化到 5 时，模型的整体匹配表现逐渐下降，这可能是因为主题词数过多时，输入模型的句子引入了过多额外文本，降低了原始文本在总文本中的比例，使得模型在字粒度匹配特征和句粒度匹配特征中忽视了原本文本的匹配信息，错误地将一些不匹配的文本识别为匹配。

基于以上实验结果和分析，文本最终选取 2 作为主题词数 T 的取值，并将该取值情况下的模型在各个评价指标上的结果作为模型的最终表现。

中国知网 https://www.cnki.net

4.2.5 与基线模型的对比实验

本节设置对比实验探究 ACJM 模型的整体匹配表现。ACJM 模型主要用于计算课程能力项和岗位能力项的匹配程度，为验证模型在该文本匹配任务上的有效性，本节选取两个经典的文本匹配模型以及它们对应的改进模型作为基线模型，并在 4.2.2 节描述的数据集上进行实验。这四个作为基线模型的文本匹配模型分别是：

BERT[38]：由于预训练语言模型 BERT 的预训练任务“预测下一句”(NSP)在自然语言处理的文本匹配任务上具有优秀表现，本节也将其作为一个基线模型。NSP 任务的做法是将两条文本拼在一起，并在句首加一个“[CLS]”标记，在两句中间和句子尾部分别加一个“[SEP]”标记，最后组成输入的句子“[CLS]文本一[SEP]文本二[SEP]”，最后再训练模型，令其预测这两个句子是否存在上下文连续关系。仿照该任务设计，本实验中将课程能力项c和岗位能力项j拼接起来，得到输入序列“[CLS]课程能力项c[SEP]岗位能力项j[SEP]”输入至 BERT 模型中。在本节实验中，采用与 ACJM 模型相同的 bert-base-chinese 版本进行权重初始化。

BERT-Topic：由于 ACJM 模型的输入包含了额外的主题词，为确保公平性，同时验证这部分文本对模型效果的影响，这里在上文 BERT 模型的基础上，添加主题填充层，对输入的课程能力项和岗位能力项，添加与 ACJM 相同数量的主题词，构成“[CLS][课程能力主题词][课程能力项c][SEP][岗位能力主题词][岗位能力项j][SEP]”格式的输入序列，输入至 BERT 模型中。

MV-LSTM(with BERT)[68]：MV-LSTM 是非常经典的多视角文本匹配模型，常作为文本匹配任务的基线模型。该模型通过双向的 LSTM 编码整个句子的信息编码，然后对并各个位置的信息使用三种方式进行对齐交互匹配，包括余弦 cosine，双线性 bilinear 和张量层匹配，并使用卷积池化对得到的匹配矩阵进行特征抽取，最后接入全连接层获得文本之间匹配的结果。由于 ACJM 模型使用 BERT 做文本嵌入，为排除影响，本节也使用 BERT 初始化文本嵌入。

MV-LSTM-Topic(with BERT)：由于 ACJM 模型的输入包含了额外的主题词，为确保公平性，同时验证这部分文本对模型效果的影响，这里在上文 MV-LSTM 模型的基础上，添加主题填充层，对输入的课程能力项和岗位能力项，添加与 ACJM 相同数量的主题词，再输入至模型中。

中国知网 https://www.cnki.net

表 4-5 与基线模型的对比实验结果(%)

模型	精确率(Precision)	召回率(Recall)	F1 值(F1-score)
BERT	79.53	73.71	76.51
BERT-Topic	80.82	75.91	78.29
MV-LSTM(with BERT)	80.05	74.37	77.11
MV-LSTM-Topic(with BERT)	81.35	76.12	78.65
ACJM	**84.46**	**82.43**	**83.43**

表 4-5 展示了 ACJM 与各基线模型的对比实验结果，实验数据表明，ACJM 在各个评价指标上的整体表现最优。对数据分析如下：

此处的 MV-LSTM 使用了 BERT 做文本嵌入，但 F1 值相比 BERT 提升了 0.6%，说明其使用双向 LSTM 来编码句子序列信息对匹配有一定帮助，而同样采用双向 LSTM 的 ACJM，在 F1 值上比 MV-LSTM 提升了 6.32%，说明 ACJM 所引入的主题词和能力注意力机制对模型效果有较大帮助。

BERT-Topic 和 MV-LSTM-Topic 相较于 BERT 和 MV-LSTM，在 F1 值上分别提升 1.78%和 1.54%，说明本文所提出的主题词扩充为匹配提供了额外信息，对模型效果有一定帮助。而 ACJM 模型相比 BERT-Topic 和 MV-LSTM-Topic，在 F1 值上分别提升了 5.14%和 4.78%，说明即使三者输入相同，ACJM 的能力注意力机制仍然能为匹配提供较大增益效果，证明了其有效性。

综上，与四个基线模型的对比实验结果表明了 ACJM 模型引入的主题词扩充和能力注意力机制对课程能力项和岗位能力项的匹配有明显帮助，在本文任务上具备良好的有效性。

4.2.6 与领域先进模型的对比实验

本节设置对比实验探究 ACJM 模型与人岗匹配领域先进模型相比的有效性。本节选取两个人岗匹配模型作为对比模型，并在 4.3.2 节描述的数据集上进行实验。对比模型如下：

TAPJFNN(with BERT)[28]：TAPJFNN 是人岗匹配领域较为经典的匹配模型，其全称为基于技能感知的人岗匹配模型。TAPJFNN 针对用户简历文本和岗位需求文本建模，其首先使用词嵌入和 Bi-LSTM，将两段文本映射到潜在的语义空间中，进行词级别的语义表征编码，然后设置了四种层级注意力机制从两段文本中提取更高维度的语义表征，

中国知网 https://www.cnki.net

具体包括：岗位需求文本中每个词的重要程度、不同岗位需求文本之间的重要程度、个人简历文本中每个词对不同岗位需求的重要程度、不同个人简历文本之间的重要程度。经过四种注意力机制后，TAPJFNN 获得岗位需求文本和个人简历文本的综合表示，并将两者拼接计算匹配分数。考虑到本章任务是两条句子间的匹配，本节去除了 TAPJFNN 中的不同岗位需求文本之间的重要程度注意力和不同个人简历文本之间的重要程度注意力，并以课程能力项作为原先的个人简历文本，以岗位能力项作为原先的岗位需求文本输入模型。另外，由于 ACJM 模型采用 BERT 作为文本嵌入，而原始的 TAPJFNN 模型采用 word2vec 作为文本嵌入，为排除其影响，确保公平性，此处将 TAPJFNN 的文本嵌入层替换成 BERT。

TAPJFNN-Topic(with BERT)：由于 ACJM 模型引入了额外的主题词输入，为确保公平，这个对比模型在上文的 TAPJFNN(with BERT)基础上，添加主题填充层，加入与 ACJM 相同个数的主题词作为额外输入。

DGMN(with BERT)[27]：DGMN 是一种用于人岗匹配的深度全局匹配网络（Deep Global Match Network），作者同时基于这个网络做了领域迁移和自适应。本节主要使用其中的单领域深度全局匹配网络用作实验对比。DGMN 使用双向门控循环单元[57]（Bidirectional Gated Recurrent Unit，BiGRU）获得个人简历和岗位需求中每个句子的层次化表示，再使用注意力机制去刻画不同句子的重要性，最后使用卷积神经网络对得到的句子矩阵做全局匹配表示。考虑到本章任务是两条句子间的匹配，本节参照 DGMN 原文思路，将其最小单元由句改为字，即使用 BiGRU 获得两句能力项的字向量矩阵，再使用注意力机制刻画不同字间的重要性，最后使用卷积神经网络做全局匹配表示。另外，由于 ACJM 模型采用 BERT 作为文本嵌入，而原始的 DGMN 模型采用 word2vec 作为文本嵌入，为排除其影响，确保公平性，此处将 DGMN 的文本嵌入层替换成 BERT。

DGMN-Topic(with BERT)：由于 ACJM 模型引入了额外的主题词输入，为确保公平，这个对比模型在上文的 DGMN(with BERT)基础上，添加主题填充层，加入与 ACJM 相同个数的主题词作为额外输入。

表 4-6 展示了 ACJM 与人岗匹配先进模型的对比实验结果，从表中数据可以看出，ACJM 在各个评价指标上的结果均优于其它模型。

中国知网 https://www.cnki.net

表 4-6 与领域先进模型的对比实验结果(%)

模型	精确率(Precision)	召回率(Recall)	F1 值(F1-score)
TAPJFNN(with BERT)	80.96	79.72	80.33
TAPJFNN-Topic(with BERT)	82.38	80.30	81.33
DGMN(with BERT)	81.61	79.65	80.61
DGMN-Topic(with BERT)	82.77	80.68	81.71
ACJM	**84.46**	**82.43**	**83.43**

ACJM 相比 TAPJFNN，精确率高出 3.5%，召回率高出 2.71%，F1 值上高出 3.1%，说明 ACJM 相较于 TAPJFNN 添加的额外主题词、能力注意力和多粒度的交互式匹配对模型效果有明显增益。即使为 TAPJFNN 添加与 ACJM 相同的主题扩充层，ACJM 仍然在各指标上比 TAPJFNN-Topic 高出 2.1%左右，分析可知，TAPJFNN 使用自主感知的注意力机制，对文本中的关键词进行感知，存在不可控性，而 ACJM 引入了可控可靠的能力关键词库，并通过显式的交互注意力使得能力项表示更充分，因而效果更好。

ACJM 相比于 DGMN，精确率高出 2.85%，召回率高出 2.78%，F1 值上高出 2.82%，DGMN 与 ACJM 都获取了句子的字粒度矩阵表示并使用卷积神经网络提取特征，但 DGMN 只考虑了字粒度矩阵，损失了一定的匹配信息，而 ACJM 获取了原句在字、句、能力三个粒度上的表示矩阵，并引入了主题词作为额外信息，因此效果更佳。即使为 DGMN 添加与 ACJM 相同的主题扩充层，ACJM 仍然在各指标上比 DGMN-Topic 高出 1.7%左右，说明 ACJM 的能力注意力机制比 DGMN 的字粒度注意力效果更好。

综上所述，通过对比实验，本节证明了 ACJM 模型在本文任务上，比领域内先进的人岗匹配模型更具有效性。

4.2.7 消融实验

本节旨在设置对比实验，探究 ACJM 模型中的主要模块在文本匹配任务上的有效性。ACJM 模型通过主题填充层，添加主题词信息，为模型引入额外语义和上下文，使同类别的文本更紧密相关，并通过能力注意力层，聚焦文本中的能力关键词，使模型能从能力导向的视角作出匹配。由此，本节将完整的 ACJM 模型作为基线模型，通过三个消融模型来验证上述模块对本文匹配任务的影响，具体如下：

w/o topic and ability：该模型在完整的 ACJM 模型基础上，移除主题填充层、能力注意力层和多维匹配层中的能力交互匹配部分，即对于输入的课程能力项 c 和岗位能力项

中国知网 https://www.cnki.net

j，直接使用 BERT 进行嵌入表示，并在多维匹配层只进行词粒度和句粒度的匹配交互，再将得到的匹配矩阵输入至聚合层进行卷积池化操作，最后由输出层计算匹配结果。

w/o topic：该模型在完整的 ACJM 模型基础上，移除主题填充层，即对于输入的课程能力项 c 和岗位能力项 j，直接使用 BERT 进行嵌入表示，然后依次经过句子表示层、能力注意力层、聚合层和输出层计算匹配结果。

w/o ability：该模型在完整的 ACJM 模型基础上，移除能力注意力层和多维匹配层中的能力交互匹配部分，即对于输入的课程能力项 c 和岗位能力项 j，在文本表示层经过主题词扩充和 BERT 编码后直接输入至句子表示层，同时在多维匹配层仅进行词粒度和句粒度的匹配交互，再将得到的匹配矩阵输入至聚合层得到匹配向量，最后由输出层计算匹配结果。

表 4-7 展示了本模型与各个消融模型的对比实验结果，其中在各个评价指标上的最优表现已加粗表示。

表 4-7 消融实验的实验结果(%)

模型	精确率(Precision)	召回率(Recall)	F1 值(F1-score)
w/o topic and ability	80.05	77.83	78.93
w/o topic	82.38	80.40	81.38
w/o ability	81.60	78.95	80.25
ACJM	**84.46**	**82.43**	**83.43**

分析表中数据，在移除主题词填充模块后，w/o topic 模型的精确率比基线模型低 2.08%，召回率比基线模型低 2.03%，F1 值比基线模型低 2.05%，模型在文本匹配任务上的效果有小幅度的下降。结果表明，添加主题填充层和主题词有助于为 ACJM 模型提供额外的匹配信息，将语义上不相似但在隐含知识的维度相似的文本相似化，提高整体模型的匹配效果。

而在移除能力注意力层后，w/o ability 模型的精确率比基线模型低 2.86%，召回率比基线模型低 3.48%，F1 值比基线模型低 3.18%，整体匹配效果低于基线模型。结果表明，本文提出的能力注意力机制使模型能够提高对文本中能力信息特征匹配的关注，有利于提升整体文本匹配任务的效果。

在将主题填充层和能力注意力层都移除后，w/o topic and ability 模型的精确率比基线模型低 4.41%，召回率比基线模型低 4.6%，F1 值比基线模型低 4.5%，在文本匹配任务上的效果有较大下降。另外，将 w/o ability 模型、w/o topic 模型和 w/o topic and ability

中国知网 https://www.cnki.net

模型分别对比，可以看出能力注意力层对模型的增益效果要大于主题填充层，分析可知，主题填充层主要为模型匹配提供额外上下文，在移除主题词填充层后，模型也能从原始文本中获得大部分信息，但能力注意力层则是让模型借助能力关键词库额外关注原始文本中的能力词汇，而能力类词汇是学生与岗位匹配的核心内容，与最终匹配结果有较大联系。

4.3 本章小结

本章详细描述了 ACJM 模型的构建过程。ACJM 首先通过主题填充层获得原始能力项的扩充句子，然后经由文本嵌入层的 BERT 和句子表示层的 Bi-LSTM 分别获得能力项的字粒度表示矩阵和句粒度表示矩阵，紧接着，在能力注意力层，利用能力关键词库标注文本中的能力词位，并通过交互注意力机制得到文本的能力粒度新表示矩阵，之后在多维匹配层对两条能力项从字、句和能力三个特征粒度进行匹配交互，得到三个维度的匹配矩阵，最后在聚合层和全连接层做卷积池化，融合三个维度的匹配矩阵，输出最终的匹配结果，为后续的学生岗位推荐提供排名计算依据。此外，本章还对 ACJM 模型做了实验验证，通过超参数实验、与基线模型的对比实验、与人岗匹配领域先进模型的对比实验和消融实验证明了模型在课程能力项和岗位能力项匹配任务上的有效性。

在下一章，本文将对 SERCJM 模型的最后一部分，学生和岗位推荐计算做介绍，并验证 SERCJM 模型的有效性。

中国知网 https://www.cnki.net

第五章 基于能力导向和岗位匹配的学生就业推荐模型的验证

在上一章，本文介绍了基于 SERCJM 模型的第二部分 ACJM 模型的结构和流程，并对其有效性做了验证。本章首先将紧接着介绍 SERCJM 模型的最后一部分，学生与岗位推荐的流程和计算方法；然后将设计实验来验证 SERCJM 模型整体的可行性和有效性。

5.1 学生与岗位推荐计算

本节的目标是根据上述章节提供的岗位信息、匹配度集合等计算学生与岗位之间的匹配度矩阵，最终获得为岗位推荐的学生列表和为学生推荐的岗位列表。本节大致可以分为四个步骤，如图 5-1 所示：

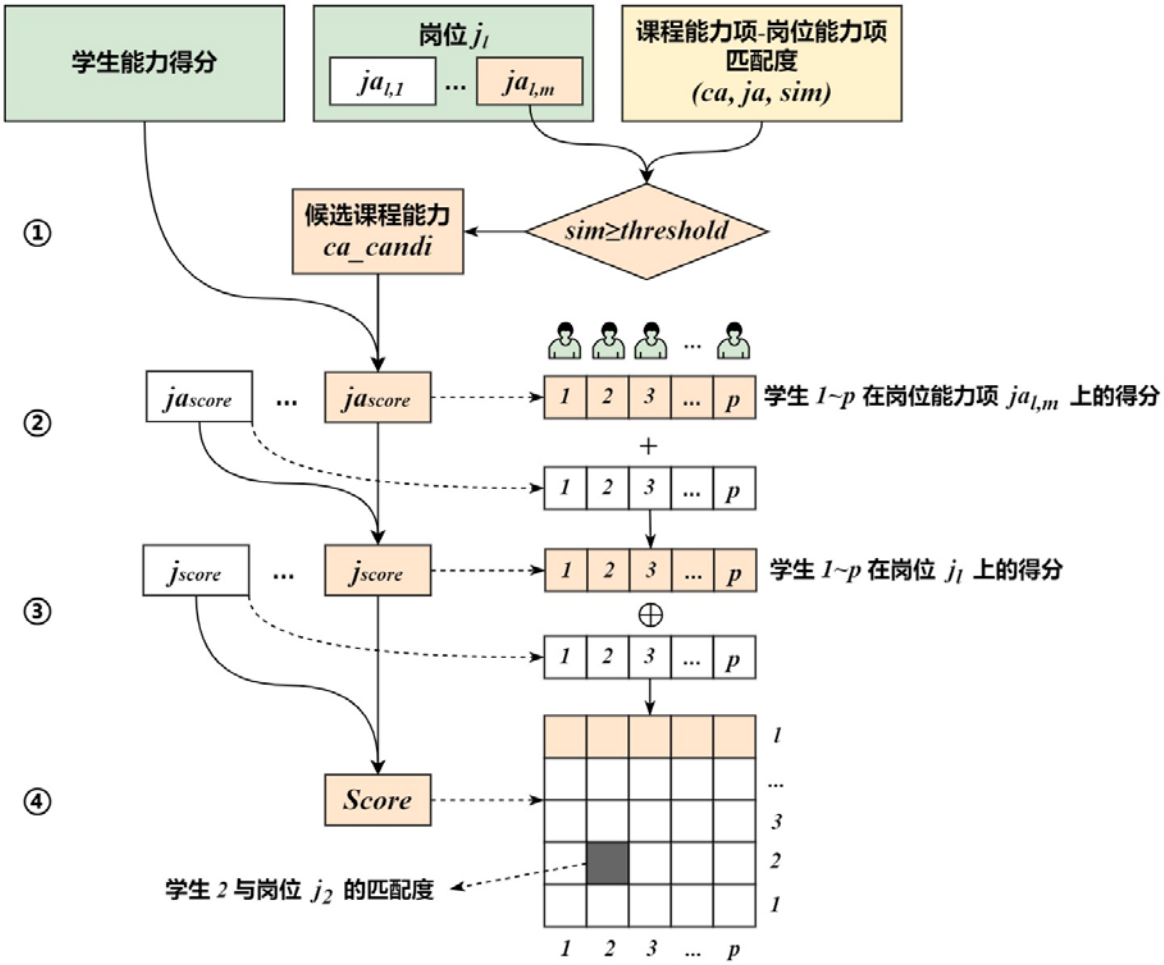

图 5-1 学生与岗位推荐计算的步骤

中国知网 https://www.cnki.net

首先，本节的输入是学生能力得分集合$S=\{s_1,s_1,\dots,s_p\}$、岗位集合$J=\{j_1,j_2,\dots,j_l\}$、能力项匹配度集合$Sim=\{(ca,ja,sim)_i\}_{i=1}^{N}$。其中：$s_p$表示第$p$位学生，$s_p=\{ss_{p,1},ss_{p,2},\dots,ss_{p,q}\}$，$ss_{p,q}$表示第$p$位学生的第$q$个课程能力项得分，例如学生 1 在“掌握总线的基本概念”上的得分是 4.5；j_l表示第l个岗位，$j_l=\{ja_{l,1},ja_{l,2},\dots,ja_{l,m}\}$，$ja_{l,m}$代表岗位$j_l$的第$m$条岗位能力项，例如“掌握 Python 编程语言”；$(ca,ja,sim)_i$包含课程能力项ca、岗位能力项ja以及它们之间的匹配度sim。

其次，计算学生-岗位匹配度矩阵。为便于理解，本节以图 5-1 中的岗位j_l为例：

（1） 从Sim中找出与岗位能力项$ja_{l,m}$匹配度超过阈值$threshold$的所有课程能力项ca，并放入课程能力候选集ca_candi中；

（2） 累加学生ca得分与匹配度sim的乘积，获得所有学生在$ja_{l,m}$上的匹配度得分；

（3） 按前两步累加岗位j_l所有能力项的学生得分，获得所有学生在岗位j_l上的匹配度得分；

（4） 按前三步计算所有岗位的学生匹配度得分，形成学生-岗位匹配度矩阵。

最后，本节根据学生-岗位匹配度矩阵排序，输出为岗位推荐的学生集R^S和为学生推荐的岗位集R^J。其中：$R^S=\{r^S{}_1,r^S{}_2,\dots,r^S{}_l\}$，包括$l$个岗位-学生列表，$r^S{}_l$表示为第$l$个岗位推荐的学生列表；$R^J=\{r^J{}_1,r^J{}_2,\dots,r^J{}_p\}$，包括$p$项学生-岗位列表，$r^J{}_p$表示为第$p$个学生推荐的岗位列表。以上流程的具体算法如表 5-1 所示。

表 5-1 学生与岗位推荐的计算流程

输入：	岗位集J; 学生集S; 匹配度集合Sim; 匹配度阈值$threshold$; 推荐个数k;
输出：	为岗位推荐的学生集R^S; 为学生推荐的岗位集R^J;
1:	$N_J=len(J)$; $N_S=len(S)$; $N_{Sim}=len(Sim)$; $R^S=[\,]$; $R^J=[\,]$; $Score=[\,]$;
2:	***for*** $l=1$ ***to*** N_J ***do*** 遍历每个岗位
3:	$N_{ja}=len(j_l)$; $j_{score}=[\,]$;
4:	***for*** $m=1$ ***to*** N_{ja} ***do*** 遍历该岗位的每个岗位能力
5:	搜索包含岗位能力ja_{lm}的匹配度集合$Sim_{lm}=\{(ca,ja_{lm},sim)_i\}_{i=1}^{N}$;
6:	根据(ca,ja_{lm},sim)的sim降序排序$sort(Sim_{lm})$;
7:	$N_{Sim_{lm}}=len(Sim_{lm})$; $ca_candi=[\,]$; $ja_{score}=[\,]$;
8:	***for*** $n=1$ ***to*** $N_{Sim_{lm}}$ ***do***
9:	获得$(ca,ja_{lm},sim)_n$;
10:	***if*** $sim\geq threshold$ ***then***
11:	添加$(ca,ja_{lm},sim)_n$到ca_candi;
12:	***end***

中国知网 https://www.cnki.net

表 5-1 学生与岗位推荐的计算流程（续）

```
            end
            for p = 1 to N_S do 遍历每个学生
                N_ca = len(s_p); s_p是第p个学生的课程能力列表
                for q = 1 to N_ca do
                    if 第q个课程能力 in ca_candi then
                        ja_score[p] = ja_score[p] + ss_{p,q} × sim;
                    end
                end
            end
            j_score[m] = ja_score;
        end
        Score[l] = Σ_{m=1}^{N_ja} j_score; r^S_l = Top(k, sort(Score[l]));
        r^S_l添加至R^S;
    end
    for p = 1 to N_S do 遍历每个学生
        JobScore = [ ];
        for l = 1 to N_J do 遍历每个岗位
            JobScore[l] = Score[l][p]; 获得第p个学生在第l个岗位的得分
        end
        r^J_p = Top(k, sort(JobScore));
        将r^J_p添加至R^J;
    end
    return R^S, R^J;
```

5.2 SERCJM 模型的验证

5.2.1 评价指标

为验证 SERCJM 模型的有效性，本章选取了平均倒数排名(Mean Reciprocal Rank, MRR)和召回率(Recall@k)作为方案的评价指标。

MRR 反映的是模型向被推荐人推荐的项目是否处于更靠前的顺序和位置，其具体计算公式如式 5-1，其中N表示被推荐人的个数或推荐次数，p_i表示被推荐人真实选择的目标项目在推荐列表中的顺序位置，如果目标项目不存在于推荐序列中，则p_i为无穷大，$\frac{1}{p_i}$为 0。由于人才推荐和岗位推荐任务中，标注的目标项目一般有多个，因此本节对公式做出微调：假设目标项目有k个，那么在一次推荐中，对命中的项目都计算其位置得分

中国知网 https://www.cnki.net

$\frac{1}{p_i}$，最后取均值，若一次推荐中少于k个命中项目，则缺少的次数得分计 0。

$$MRR = \frac{1}{N}\sum_{i=1}^{N}\frac{1}{p_i} \tag{5-1}$$

Recall@k 反映的是模型向被推荐人推荐的项目是否处于某个可接受的范围内，其具体公式如 5-2 所示，其中N表示被推荐人的个数或推荐次数，Rel_u表示被推荐人选择出的目标项目集合，Rec_k表示模型向被推荐人推荐的前k个项目，$|Rel_u \cap Rec_k|$表示在推荐列表的前k项里，包含被推荐人所选择的真实项目的个数，$|Rel_u|$表示被推荐人所选择的真实项目的个数。

$$Recall@k = \frac{1}{N}\sum_{i=1}^{N}\frac{|Rel_u \cap Rec_k|}{|Rel_u|} \tag{5-2}$$

5.2.2 数据准备

本节选取了 H 高校 2021 届软件工程专业一个班级的毕业生的课程和成绩数据，Z 公司提供的若干岗位数据作为验证方案可行性的原始数据。数据的基本情况如下（结果保留两位小数）：

表 5-2 验证方案的数据基本情况

数据含义	数值
学生人数	30
专业课程总数	71
专业课程目标总数	316
平均一门课程涵盖的课程目标数	4.45
平均一个学生修读的课程数	63.20
平均一个学生具备的课程目标数	279.76
岗位数	30
岗位要求总数	137
平均一个岗位的岗位要求数	4.57

其中，由于学生在选修课上的选择不一，学生所具备的课程数及课程目标数也不完全相同，也存在一些学生在某个特定课程目标上无成绩（未选修该课程）的情况，这种情况下，本章将其分数计为 0。为验证方案在企业视角的效果，本文将每个学生的能力得分由高至低排序，并邀请了 Z 公司研发专家和人力资源专家，为每个岗位选取了 3 位最符合要求的候选学生。同时，本文还邀请了若干软件工程专业在读的学生，根据毕业

中国知网 https://www.cnki.net

生的能力表现，为每个毕业生选择了 3 个最契合的岗位。

5.2.3 有效性实验

本节将本文提出的基于能力导向和岗位匹配的学生就业推荐模型在学生推荐和岗位推荐两个任务上，与基线模型和两个领域内的先进模型作对比，并分析它们的效果表现。实验使用到的对比方案有以下几种：

基线方案：参照传统做法，直接以学生成绩排名作为推荐标准。由于课程目标的达成度来自于课程中各个考核任务的得分及支撑关系，而学生的课程成绩同样来源于对考核任务的成绩按比例求和，两者本质上并无区别。因此，本文对每个学生的所有课程能力得分，也就是课程目标达成度取平均值，作为学生成绩代表，再取前 10 名学生作为推荐人选。

TAPJFNN(with BERT)[28]：使用第四章提到的 TAPJFNN 模型，将其文本嵌入替换成 BERT，来计算课程能力项和岗位能力项的匹配度，并使用本章的推荐计算方法获取推荐列表。

DGMN(with BERT)[27]：使用第四章提到的 DGMN 模型，将其文本嵌入替换成 BERT，来计算课程能力项和岗位能力项的匹配度，并使用本章的推荐计算方法获取推荐列表。

本节实验中，设置匹配度阈值$threshold$为 0.8，设置推荐个数k为 10，即每次推荐 10 个岗位或学生。表 5-3 展示了四种方案在学生推荐和岗位推荐两个任务上的实验结果。由于数据标注的目标学生和目标岗位只有 3 位，这里的$R_{10}@1$指标最高得分只有 0.333，$R_{10}@2$指标最高得分为 0.667，$R_{10}@5$指标的最高得分为 1。另外，由于基线方案只考虑了以成绩为标准对学生进行排序，而无法获得岗位的排序，因而此处没有基线方案在岗位推荐任务上的实验结果。

表 5-3 SERCJM 与其他推荐方法的对比

方案	学生推荐				岗位推荐			
	MRR	$R_{10}@1$	$R_{10}@2$	$R_{10}@5$	MRR	$R_{10}@1$	$R_{10}@2$	$R_{10}@5$
基线方案	0.265	0.056	0.167	0.611	—	—	—	—
TAPJFNN(with BERT)	0.351	0.156	0.244	0.711	0.341	0.144	0.233	0.689
DGMN(with BERT)	0.383	0.167	0.300	0.733	0.380	0.167	0.278	0.722
SERCJM	**0.405**	**0.200**	**0.356**	**0.800**	**0.399**	**0.189**	**0.322**	**0.778**

在学生推荐任务上，基线方案的MRR得分是 0.265，相当于将目标学生平均排在了

中国知网 https://www.cnki.net

10 位推荐名单中的第 3.7 位，而 TAPJFNN 和 DGMN 的MRR分数分别是 0.351 和 0.383，说明分别将目标学生平均排在了 2.8 位和 2.6 位，SERCJM 模型的MRR得分则达到了 0.405，说明其将目标学生平均排在了 2.4 位。再看$Recall@k$指标，基线方案的三个召回率指标分数分别是 0.056、0.167 和 0.611，意味着在 30 次学生推荐中，约有 1.6 次将目标学生放在了前一位，5 次将目标学生放在了前两位，18.3 次将目标学生放在了前 5 位，表现较差；TAPJFNN 在三个召回率指标上的分数分别是 0.156、0.244、0.711，意味着 30 次推荐中约有 4.6 次将目标学生放在了推荐列表的第一位，7.3 次将目标学生放在前两位，21.3 次将目标学生放在前五位，而 DGMN 在 30 次推荐中将目标学生放在第一位、前两位、前五位的次数约为 5 次、9 次和 22 次。SERCJM 的三指标召回率得分则分别达到了 0.200、0.356 和 0.800，相当于 30 次推荐中将目标学生放在第一位、前两位、前五位的次数约为 6 次、11 次和 24 次，换一个说法，相当于每次推荐都至少能将 0.60 个目标学生放在第一位，1.07 个目标学生纳入前两位，2.40 个目标学生纳入前五位。

在岗位推荐任务上，TAPJFNN 和 DGMN 的MRR得分是 0.341 和 0.380，意味着它们分别将目标岗位平均排在了 2.9 位和 2.6 位，而 SERCJM 的MRR得分是 0.399，将目标岗位平均排在 2.5 位。在$Recall@k$指标的表现上，TAPJFNN 的三个召回率指标分数分别是 0.144、0.233、0.689，意味着在 30 次岗位推荐中，约有 4.3 次将目标岗位放在了第一位，7 次将目标岗位放在了前两位，20.7 次将目标岗位放在了前五位，换一种说法，平均每次推荐有 0.43 个目标岗位排在第一位，有 0.69 个目标岗位排在前两位，有 2.07 个目标岗位排在前五位；DGMN 对应的表现则是，30 次推荐中约有 5 次、8.3 次、21.7 次将目标岗位放在第一位、前两位和前五位，平均每次推荐有 0.50、0.83 和 2.17 个目标岗位排在第一位、前两位和前五位；而 SERCJM 在 30 次推荐里约有 5.7 次、9.7 次和 23.3 次将目标岗位排在第一位、前两位和前五位，平均每次推荐有 0.57、0.97 和 2.33 个目标岗位在第一位、前两位和前五位。

上述实验结果表示，SERCJM 能够将目标学生或岗位排在更靠前的位置，同时能基本保证目标学生和岗位所在的位置处于能接受的范围内，说明其在识别候选人与岗位的重要性上相较其他方法更优。分析原因，首先，基线方案使用学生的总成绩来排序，将成绩排名前 10 的学生推荐出来，也就是说不论岗位如何，推荐名单都是相同的 10 个学生，当成绩前茅的学生的能力恰巧契合岗位要求时，就会得到较好的结果，但其一味地

中国知网 https://www.cnki.net

将成绩等同于能力，没有更细粒度地考虑学生的能力表现以及其与岗位要求的适配性，因此整体的效果并不如其他几种模型好；而 TAPJFNN 与 DGMN 两者的模型架构相似，都使用了字嵌入、句嵌入结合 Attention 的结构，因此效果表现也相差不大，但 DGMN 比起 TAPJFNN 增加了卷积池化层，因此提取表征的效果更好一些，相对地实验表现也更好。而本文方案相较前两个模型，引入了上下文信息，对短文本匹配做了优化，并且通过能力关键词库显式的增加了能力方面注意力，因此效果也更好。

5.3 本章小结

本章首先详细介绍了学生与岗位推荐的计算流程和算法，然后设计了对比实验，将 SERCJM 模型与传统方法和两种先进的人岗匹配模型做了效果对比，分别验证了 SERCJM 在学生推荐和岗位推荐任务上的有效性。

中国知网 https://www.cnki.net

总结与展望

近年来，我国高校毕业生规模不断扩大，“就业难”问题日渐严重，并且越来越受到社会关注。而学生就业推荐研究有助于校企对接和人才输送，对解决应届生就业问题具有重大意义。

本文旨在充分利用和挖掘工程教育专业认证背景下的教学评价数据，以能力为引线串联学生、高校、企业三方，构建一个能力导向的学生就业推荐模型，对学生和企业岗位进行双向匹配和推荐，以降低高校就业指导、学生求职和企业人才筛选的成本。本文主要的研究内容和工作如下：

针对现有学生就业推荐研究忽略了学生能力水平和岗位招聘要求的匹配，进而导致推荐不准确的问题，本文提出了一个基于注意力的课程能力与岗位能力匹配模型（ACJM），计算课程能力项和岗位能力项的匹配度，并作为后续推荐的依据。具体地，ACJM 以教学数据中的课程目标表示学生在校期间已经具备的能力，即课程能力，以岗位招聘要求代表学生未来任职时应当具备的能力，即岗位能力，并通过一种能力注意力机制对两个句子中的能力关键词给予更多关注，最后结合了表征式和交互式文本匹配的方法，综合考虑了两者的字、句和能力粒度语义，进行多粒度交互匹配。在第四章，本文将 ACJM 与 BERT、MV-LSTM 等基线模型，TAPJFNN、DGMN 等人岗匹配领域的先进模型进行了对比，均取得了一定的效果提升，此外，本文还探讨了 ACJM 模型中主题填充层和能力注意力层的对模型的影响，并设计了消融实验证明了它们的有效性。

针对课程目标与岗位要求匹配时，因短文本缺乏上下文而带来的匹配困难问题，本文引入了预训练主题模型来提取文本主题词，为课程目标和岗位要求增添上下文语义和额外信息，帮助 ACJM 模型更好地匹配。在第三章，本文将选取的预训练主题模型 BERTopic 与传统主题模型 LDA、神经主题模型 NVDM-GSM 进行了对比，验证了其在本文任务上的有效性，并对提取的主题进行了可视化展示和分析；在第四章，本文通过消融实验证明了主题词在 ACJM 模型中的有效性，并探讨了主题词个数对 ACJM 模型效果的影响，最终确定了两个局部主题词和两个全局主题词的配置。

针对现有研究没有使用客观数据评价学生，导致推荐结果存在主观性的问题，本文充分利用工程教育认证背景下的客观教学数据，构建了一个能力关键词库用于 ACJM 的

中国知网 https://www.cnki.net

匹配，并整合上述工作，提出了一个基于能力导向和岗位匹配的学生就业推荐模型（SERCJM），SERCJM 是一个端到端的整体方案，其输入是一批课程、岗位和学生成绩，输出是学生与岗位的双向推荐结果。具体地，SERCJM 首先通过预训练主题模型为课程目标和岗位要求增加额外语义，然后通过 ACJM 模型计算所有课程目标和岗位要求之间的匹配度，组成一个匹配度集合，最后通过匹配度集合与学生的课程目标得分综合计算学生与岗位之间的匹配度矩阵，并依此为学生推荐岗位，为岗位推荐学生。在第五章，本文对提出的 SERCJM 模型进行了有效性验证，与传统推荐做法、基于 TAPJFNN 的推荐方案、基于 DGMN 的推荐方案做了效果对比，本文的方案在其中取得了最优表现。

最后，本章针对本文研究的不足之处，对未来的研究工作提出以下几点展望：

（1）主题模型的表现很大程度上取决于领域词库与句嵌入模型。好的领域词库可以精准抽取文本中的专有词汇，而适应领域的句子嵌入模型则会更好的刻画各词的语义。本文在领域词库上做了人工校验，但仍然需要随着时间推移的补充和更新词库，而本文使用的模型是通用中文句嵌入模型，如果能够针对特定领域数据训练一个专用的模型，效果会更好。

（2）主题词提取目前仅仅基于原始语料去获取额外的上下文信息，没有引入更多的外部知识。在这个方向上，已经有上游研究将知识图谱技术与 BERT 等预训练模型结合起来，如百度的 ERNIE，因此，本文后续可以考虑构建领域特定的知识图谱，再与预训练模型结合，为句子提供上下位词等实体关系。

（3）ACJM 模型目前仅考虑了学生与岗位在能力方面的适配，而实际上就业过程除了能力这项基本要求，还有更多上层影响因素，如工作地点意向、薪资水平、工作内容兴趣等，后续应该从更多的角度综合分析设计。此外，模型的运行速度还不够快，若落地到实际的高校就业推荐系统中，运行耗时过长可能给用户带来不好体验，未来可以考虑通过知识蒸馏等技术提高运行速度，降低时延。

中国知网 https://www.cnki.net

参考文献

[1] 中华人民共和国教育部. 教育部 人力资源社会保障部共同部署做好 2022 届全国普通高校毕业生就业创业工作[EB/OL]. http://www.moe.gov.cn/jyb_zzjg/huodong/202111/t20211119_581164.html, 2021-11-19/2022-09-02.

[2] International Engineering Alliance. Washington Accord[EB/OL]. https://www.ieagreements.org/accords/washington/signatories, 2021-09-23/2022-09-02.

[3] 中华人民共和国教育部. 中国全票获《华盛顿协议》正式成员资格[EB/OL]. http://www.moe.gov.cn/jyb_xwfb/s5147/201606/t20160603_248172.html, 2016-06-03/2022-09-02.

[4] 李志义, 赵卫兵. 我国工程教育认证的最新进展[J]. 高等工程教育研究, 2021, 2021(05): 39-43.

[5] 李志义, 朱泓, 刘志军, 等. 用成果导向教育理念引导高等工程教育教学改革[J]. 高等工程教育研究, 2014, 2014(02): 29-34+70.

[6] 黄立威, 江碧涛, 吕守业, 等. 基于深度学习的推荐系统研究综述[J]. 计算机学报, 2018, 41(07): 1619-1647.

[7] Breese J S, Heckerman D, Kadie C. Empirical analysis of predictive algorithms for collaborative filtering[C]//Proceedings of the Fourteenth conference on Uncertainty in artificial intelligence. 1998: 43-52.

[8] Mooney R J, Roy L. Content-based book recommending using learning for text categorization[C]//Proceedings of the fifth ACM conference on Digital libraries. 2000: 195-204.

[9] Balabanović M, Shoham Y. Fab: Content-based, collaborative recommendation[J]. Communications of the ACM, 1997, 40(3): 66-72.

[10] Diaby M, Viennet E, Launay T. Toward the next generation of recruitment tools: an online social network-based job recommender system[C]//Proceedings of the 2013 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining. 2013: 821-828.

中国知网 https://www.cnki.net

[11] Gupta A, Garg D. Applying data mining techniques in job recommender system for considering candidate job preferences[C]//2014 International Conference on Advances in Computing, Communications and Informatics (ICACCI). IEEE, 2014: 1458-1465.

[12] Hossain M S, Arefin M S. Development of an Intelligent Job Recommender System for Freelancers using Client's Feedback Classification and Association Rule Mining Techniques[J]. J. Softw., 2019, 14(7): 312-339.

[13] Zhang Y, Yang C, Niu Z. A research of job recommendation system based on collaborative filtering[C]//2014 seventh international symposium on computational intelligence and design. IEEE, 2014, 1: 533-538.

[14] Yang S, Korayem M, AlJadda K, et al. Combining content-based and collaborative filtering for job recommendation system: A cost-sensitive Statistical Relational Learning approach[J]. Knowledge-Based Systems, 2017, 136: 37-45.

[15] 徐孟奇，熊熙，李斌勇，等.基于知识图谱的人岗推荐系统构建[J]. 计算机应用研究, 2022, 39(01): 194-198.

[16] Martinez-Gil J, Freudenthaler B, Natschläger T. Recommendation of job offers using random forests and support vector machines[C]//Proceedings of the of the EDBT/ICDT joint conference. 2018: 22-27.

[17] 金连旭，王洪国，丁艳辉，等. 基于兴趣敏感度的高校毕业生就业推荐算法[J]. 计算机与数字工程, 2017, 45(02): 201-205+253.

[18] Zhou Q, Liao F, Ge L, et al. Personalized preference collaborative filtering: job recommendation for graduates[C]//2019 IEEE SmartWorld, Ubiquitous Intelligence & Computing, Advanced & Trusted Computing, Scalable Computing & Communications, Cloud & Big Data Computing, Internet of People and Smart City Innovation (SmartWorld/SCALCOM/UIC/ATC/CBDCom/IOP/SCI). IEEE, 2019: 1055-1062.

[19] Zhou Q, Liao F, Chen C, et al. Job recommendation algorithm for graduates based on personalized preference[J]. CCF Transactions on Pervasive Computing and Interaction, 2019, 1: 260-274.

[20] Edwards J R. Person-job fit: A conceptual integration, literature review, and

中国知网 https://www.cnki.net

methodological critique[M]. John Wiley & Sons, 1991.

[21] Malinowski J, Keim T, Wendt O, et al. Matching people and jobs: A bilateral recommendation approach[C]//Proceedings of the 39th Annual Hawaii International Conference on System Sciences (HICSS'06). IEEE, 2006, 6: 137c-137c.

[22] Bansal S, Srivastava A, Arora A. Topic modeling driven content based jobs recommendation engine for recruitment industry[J]. Procedia computer science, 2017, 122: 865-872.

[23] Zhang X X, Zhou Y, Ma Y, et al. Glmix: Generalized linear mixed models for large-scale response prediction[C]//Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining. 2016: 363-372.

[24] Yin Z, Xu T, Zhu H, et al. Matching of social events and users: a two-way selection perspective[J]. World Wide Web, 2020, 23: 853-871.

[25] Ye Y, Zhu H, Xu T, et al. Identifying high potential talent: A neural network based dynamic social profiling approach[C]//2019 IEEE International Conference on Data Mining (ICDM). IEEE, 2019: 718-727.

[26] Hou Y, Pan X, Zhao W X, et al. Leveraging Search History for Improving Person-Job Fit[C]//Database Systems for Advanced Applications: 27th International Conference, DASFAA 2022, Virtual Event, April 11–14, 2022, Proceedings, Part I. Cham: Springer International Publishing, 2022: 38-54.

[27] Bian S, Zhao W X, Song Y, et al. Domain adaptation for person-job fit with transferable deep global match network[C]//Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP). 2019: 4810-4820.

[28] Qin C, Zhu H, Xu T, et al. An enhanced neural network approach to person-job fit in talent recruitment[J]. ACM Transactions on Information Systems (TOIS), 2020, 38(2): 1-33.

[29] Reiter-Haas M, Wittenbrink D, Lacic E. On the heterogeneous information needs in the job domain: A unified platform for student career[C]//Proceedings of the 14th ACM

中国知网 https://www.cnki.net

Conference on Recommender Systems. 2020: 573-574.

[30] Lacic E, Reiter-Haas M, Kowald D, et al. Using autoencoders for session-based job recommendations[J]. User Modeling and User-Adapted Interaction, 2020, 30: 617-658.

[31] Mathur P N, Dixit A, Ramanathan S. Career recommender: a novel approach to suggest jobs and post-graduation streams. Asian Journal of Pharmaceutical and Clinical Research, 2017, 10: 365-368.

[32] Razak T R, Hashim M A, Noor N M, et al. Career path recommendation system for UiTM Perlis students using fuzzy logic[C]//2014 5th International Conference on Intelligent and Advanced Systems (ICIAS). IEEE, 2014: 1-5.

[33] Huang P S, He X, Gao J, et al. Learning deep structured semantic models for web search using clickthrough data[C]//Proceedings of the 22nd ACM international conference on Information & Knowledge Management. 2013: 2333-2338.

[34] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013.

[35] Nickel M, Rosasco L, Poggio T. Holographic embeddings of knowledge graphs[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2016, 30(1).

[36] Peters M E, Neumann M, Iyyer M, et al. Deep contextualized word representations[C]//Proceedings of NAACL-HLT. 2018: 2227-2237.

[37] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[38] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.

[39] Reimers N, Gurevych I. Sentence-bert: Sentence embeddings using siamese bert-networks[J]. arXiv preprint arXiv:1908.10084, 2019.

[40] Li B, Zhou H, He J, et al. On the sentence embeddings from pre-trained language models[J]. arXiv preprint arXiv:2011.05864, 2020.

[41] Su J, Cao J, Liu W, et al. Whitening sentence representations for better semantics and faster retrieval[J]. arXiv preprint arXiv:2103.15316, 2021.

中国知网 https://www.cnki.net

[42] Gao T, Yao X, Chen D. Simcse: Simple contrastive learning of sentence embeddings[J]. arXiv preprint arXiv:2104.08821, 2021.

[43] Zhang Y, Zhu H, Wang Y, et al. A contrastive framework for learning sentence representations from pairwise and triple-wise perspective in angular space[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2022: 4892-4903.

[44] Lee S, Lee D, Jang S, et al. Toward interpretable semantic textual similarity via optimal transport-based contrastive sentence learning[J]. arXiv preprint arXiv:2202.13196, 2022.

[45] Jiang T, Jiao J, Huang S, et al. Promptbert: Improving bert sentence embeddings with prompts[J]. arXiv preprint arXiv:2201.04337, 2022.

[46] Parikh A P, Täckström O, Das D, et al. A decomposable attention model for natural language inference[J]. arXiv preprint arXiv:1606.01933, 2016.

[47] Pang L, Lan Y, Guo J, et al. Text matching as image recognition[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2016, 30(1).

[48] Chen Q, Zhu X, Ling Z, et al. Enhanced LSTM for natural language inference[J]. arXiv preprint arXiv:1609.06038, 2016.

[49] Rao J, Liu L, Tay Y, et al. Bridging the gap between relevance matching and semantic matching for short text similarity modeling[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2019: 5370-5381.

[50] Yang R, Zhang J, Gao X, et al. Simple and effective text matching with richer alignment features[J]. arXiv preprint arXiv:1908.00300, 2019.

[51] Cao Q, Trivedi H, Balasubramanian A, et al. DeFormer: Decomposing pre-trained transformers for faster question answering[J]. arXiv preprint arXiv:2005.00697, 2020.

[52] Khattab O, Zaharia M. Colbert: Efficient and effective passage search via contextualized late interaction over bert[C]//Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval. 2020: 39-48.

中国知网 https://www.cnki.net

[53] Li D, Yang Y, Tang H, et al. VIRT: improving representation-based models for text matching through virtual interaction[J]. arXiv preprint arXiv:2112.04195, 2021.

[54] Lu Y, Liu Y, Liu J, et al. Ernie-search: Bridging cross-encoder with dual-encoder via self on-the-fly distillation for dense passage retrieval[J]. arXiv preprint arXiv:2205.09153, 2022.

[55] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.

[56] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.

[57] Chung J, Gulcehre C, Cho K H, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[J]. arXiv preprint arXiv:1412.3555, 2014.

[58] Schuster M, Paliwal K K. Bidirectional recurrent neural networks[J]. IEEE transactions on Signal Processing, 1997, 45(11): 2673-2681.

[59] Grootendorst M. BERTopic: Neural topic modeling with a class-based TF-IDF procedure[J]. arXiv preprint arXiv:2203.05794, 2022.

[60] Marcílio-Jr W E, Eler D M, Paulovich F V, et al. HUMAP: hierarchical uniform manifold approximation and projection[J]. arXiv preprint arXiv:2106.07718, 2021.

[61] McInnes L, Healy J, Astels S. hdbscan: Hierarchical density based clustering[J]. J. Open Source Softw., 2017, 2(11): 205.

[62] 中国工程教育专业认证协会. 工程教育认证标准[EB/OL]. https://www.ceeaa.org.cn/gcjyzyrzxh/rzcxjbz/gcjyrzbz/tybz/630662/index.html, 2022-07-15/2022-09-02.

[63] 徐芳. 研发团队胜任力模型的构建及其对团队绩效的影响[J]. 管理现代化, 2003, (2):4.

[64] Jiao Z, Sun S, Sun K. Chinese lexical analysis with deep bi-gru-crf network[J]. arXiv preprint arXiv:1807.01882, 2018.

[65] Han S, Zhang Y, Ma Y, et al. THUOCL: Tsinghua open Chinese lexicon[J]. Tsinghua University, 2016.

[66] Blei D M, Ng A Y, Jordan M I. Latent dirichlet allocation[J]. Journal of machine

中国知网 https://www.cnki.net

Learning research, 2003, 3(Jan): 993-1022.

[67] Miao Y, Grefenstette E, Blunsom P. Discovering discrete latent topics with neural variational inference[C]//International Conference on Machine Learning. PMLR, 2017: 2410-2419.

[68] Wan S, Lan Y, Guo J, et al. A deep architecture for semantic matching with multiple positional sentence representations[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2016, 30(1).

中国知网 https://www.cnki.net