ISSN 1009-3044
Computer Knowledge and Technology 电脑知识与技术
Vol.14, No.28, October. 2018

E-mail：wltx@dnzs.net.cn
http://www.dnzs.net.cn
Tel：+86-551-65690963 65690964

网络爬虫在采集岗位招聘数据方面的应用实践

汤义好

（安徽商贸职业技术学院 电子信息工程系，安徽 芜湖 241002）

摘要：现代教学设计理论认为优化教学过程，可以更好有效地达成教学目标，提高教学效率。文章阐述了在岗位分析系统中如何利用网络爬虫框架WebMagic不断地从网络采集岗位招聘数据，并保存到HBase数据库的一个过程。

关键词：大数据；岗位招聘；WebMagic

中图分类号：TP393　　文献标识码：A　　文章编号：1009-3044(2018)28-0008-02

DOI:10.14004/j.cnki.ckt.2018.3247

大学生最关心的莫过于就业，高校的数字化建设日渐成熟，大数据在就业方面的应用正处在积极探索阶段。可以说数据采集是大数据应用开发的一个重要环节，如果没有数据，处理分析也就无从谈起。下面我们就来讨论下如何进行数据采集。

1 数据采集的来源与工具

就业信息主要来自网络和学校招聘，主要的岗位数据源于网络，需要有一套采集软件也就是爬虫。爬虫有很多，综合考虑WebMagic是一个无序配置、便于二次开发的爬虫框架，其提供简单灵活的API，只需要少量代码既可以实现。数据抓取时序图如图1所示。

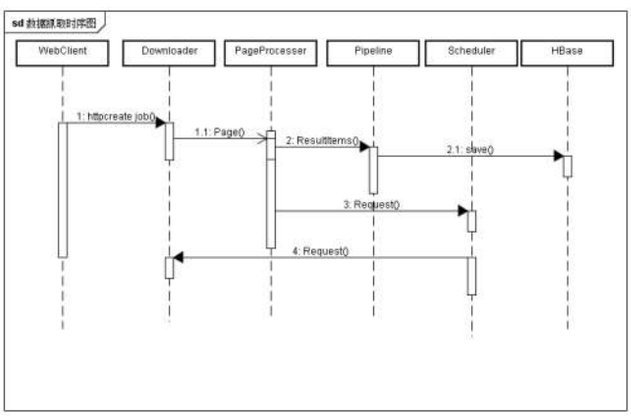

图1　数据抓取时序图

Downloader负责从互联网上下载页面，以便后续处理。WebMagic默认使用Apache HttpClient作为下载工具。PageProcessor负责解析页面，抽取有用的信息，以及发现新的链接。WebMagic使用Jsoup作为HTML解析工具，并基于其开发了解析XPath的工具Xsoup。PageProcessor对于每个站点每个页面的解析都不一样，是需要使用者定制的部分。Scheduler负责调度，一般无须自己定制。Pipeline负责抽取结果的处理，包括计算、持久化到文件、数据库等。默认提供了输出到控制台和保存到文件两种结果处理方案。

2 如何实施爬取任务

（1）解析岗位列表源代码

定制基于Java的WebMagic爬虫框架抓取招聘网站上根据岗位的关键词如“大数据”搜索出的岗位结果。列出的关于关键词搜索出来的列表就是爬虫抓取的起始页。可以通过添加后续链接的URL至爬取队列，使得爬虫按照要求一步步循环下去。这里需要添加的链接便是岗位的信息页，以及后续列表分页。分析页面中的相同项，可以发现所需要的URL是一个唯一的超链接，记下标签的样式名称交给Xpath识别，并添加至抓取列，实现代码如下。

```
select = page.getHtml().xpath("//p[@class = 't1' ]");
urls = select.links().all();
page.addTargetRequests(urls);
```

需要注意的是，要防止添加空白搜索结果页的链接，否则将会把整个招聘网站的岗位全部抓取下来。所以需要添加提出队列的保护机制，代码如下：

```
Iteratror<String> it= urls.iterator();
while(it.hasNext()){
  String x = it.next();
  If(x.equals("http://...")){
    it.remove();
  }
}
page.addTargetRequest(urls);
```

（2）解析岗位信息页面

需要爬取的岗位信息包括职位名称、发布时间、是否洗数据、编号、工作地点、工作经验、薪资、招聘人数、学历、岗位描述、职能类别、公司名称、公司性质、公司行业、公司规模等。由于格式基本差不多可以json配置项的方式将某个点的正则保存在一起，方便调用。WebMagic框架可以根据获取的正则定位相关的内容。具体代码如下：

```
page.putField("jobname", page.getHtml().xpath("//div[@class='cn']/h1/text()").toString());
page. putField("name", page. getHtml(). xpath("//p[@class=
```

收稿日期：2018-05-25
基金项目：安徽商贸职业技术学院“三平台两基地”2018年应用研究项目(2018ZDX03)
作者简介：汤义好(1983—)，男，安徽芜湖人，安徽商贸职业技术学院助教，主要研究方向为软件技术与大数据分析。

中国知网 https://www.cnki.net

'cname']/a/text()").toString());

（3）根据条件保存抓取到的信息

根据条件筛选岗位信息，比如已经列出的一些培训机构的“公司黑名单”，保存在数组中，那么就可以使用简单的if语句来判断。对于发布日期，仅需要保留当天或本周发布的招聘信息。筛选完成便可以将抓取内容选择性的保存到本地的某个文件中。也可以将结果保存到HDFS和HBase数据库中，这样更有助于后面的大数据处理。

（4）运行主程序

WebMagic的核心组件为PageProcessor与Pipeline。用户可以自己定制这两个组件，而调用这两个核心组件是通过Spider类，其简单的代码如下：

```
Spider.create(new CrawlJob())
  .addUrl(URL_START)
  .addPipleline(new PipelineJob()).thread(5).run();
```

可以借助系统的定时服务来实现程序的定时爬取功能使用代码如下：

```
public ServiceState start() {
initializer = new InitializeService(this);
initializer.start();
services.add(initializer);
Service jobAnalyzer = new JobAnalysisService(this, initializer);
jobAnalyzer.start();
return ServiceState.STATE_RUNNING;
}
```

3 采集分析系统的实现

系统采用了服务端和客户端的方式分离了数据分析与应用展现，使得服务端系统可以实时采集数据，客户端可以灵活应对数据分析需求变化提供不同的数据表现形式。岗位分析系统分为两大子系统：

（1）在服务子系统及服务端，定时执行包括数据采集、数据清洗和数据分析的任务。Server端中的collect服务，从岗位列表网站（xueqing-web）之中爬取数据保存至HBase，再由server中的clean服务将无用信息进行删除，之后由server中的cluster服务将数据聚类保存至MongoDB中。（2）大数据客户端系统client将MongoDB中的数据通过ECharts和D3可视化展示在页面之中。

4 技术难点

（1）有些网络服务器反感爬虫，会对请求头做个简单判别，直接拒绝那些明显是由自动化程序发起的请求。就例如使用的默认请求头，浏览器访问时User-Agent值。为了避免自动化程序被拒绝，在请求时可以修改请求头，让自动化程序更像一个浏览器。

（2）在网页爬取时，可能会遇到内部网络不允许访问外网的情况，这时就需要设置代理IP: requests.get("https://guanjia.qq.com", proxies={“http”:”127.0.0.1:8087”})

（3）针对各网站特点给出不同的爬虫方式，可以应对大量场景的数据爬取。在实际工作中使用频率最多还是“静态页面”、“javascript动态页面”这两种。当然，若是页面包含验证码，那就需要结合图像识别工具做些事情了，这种情况相对也比较难处理，图像识别准确率受到图片内容影响。

5 结束语

网络爬虫在采集岗位数据方面发挥了重要作用，为将大数据技术应用在求职招聘方面提供了数据保证。由于网络爬虫需要不断的采集数据，而网站可能也在不断地变化，所以实际运用中需要灵活配置爬取策略避免遗漏某些网页，也要减小对网站服务器的负担。webmagic提供的xpath解析工具，不支持xpath2.0的一些高级特性，比如：查找父节点之类，解析时可以考虑引入其他一些第三方开源库，比如dom4j来处理。

参考文献：

[1] 张敏,张阳. 基于大数据的民族高校学生资助工作方案研究与设计[J]. 西南民族大学学报(自然科学版). 2016(01).

[2] 陆嘉恒.Hadoop实战[M]. 机械工业出版社,2012.

[3] 胡水星.大数据及其关键技术的教育应用实证分析[J].远程教育杂志, 2015, 33(5):46-53.

[4] 孙洪涛,郑勤华.教育大数据的核心技术、应用现状与发展趋势[J].远程教育杂志,2016(5) :41-49.

【通联编辑：代影】

中国知网 https://www.cnki.net