# 面向小样本的岗位模糊匹配推荐算法

刘琼雯[1],林 川[2]
(1.华北计算技术研究所 系统三部,北京 100083;2.华北计算技术研究所 总体部,北京 100083)

**摘要:**近年来,全民考编成为时代趋势,大量政府机构职位如公务员、军队文职等启动线上报考招聘工作。但大量繁杂的岗位信息也为求职者选岗带来了困难。针对选岗慢、选岗难等问题,基于少量人工标注的岗位文本信息,提出了一种新型的精准岗位推荐算法。通过特征构建,明确不同招考信息的匹配规则;通过基于文本分类的ERNIE-BiLSTM-CRF训练实体识别模型,实现长文本岗位描述信息的隐含条件抽取;提出改进的基于动态词向量的加权余弦相似度算法,解决文本相似度计算中无关信息噪音问题。在自标注的数据集上的实验结果表明,上述条件抽取模型的F1值较最优算法提升14.97%,相似度匹配命中率和DCG值分别提升20.5%和22.9%,可有效实现基于小样本的人岗模糊匹配,为求职者提供准确、鲁棒的文职岗位推荐服务。

**关键词:**小样本学习;文本相似度;人岗匹配;命名实体识别
**中图分类号:**TP391.1 **文献标识码:**A **文章编号:**1674-6236(2023)14-0051-06
DOI:10.14022/j.issn1674-6236.2023.14.010

## A novel post fuzzy matching recommendation algorithm based on few-shot learning

LIU Qiongwen[1], LIN Chuan[2]
(1.*Department of System* III,*North China Institute of Computing Technology*,*Beijing* 100083,*China*;
2.*Department of General*,*North China Institute of Computing Technology*,*Beijing* 100083,*China*)

**Abstract:** In recent years, looking for a public-sector job has become a such popular trend. Large number of national government agencies such as civil servants and military civilians has opened online recruitment channels. However, these massive and complicated job information also brings difficulties for job seekers to choose a job. Therefore, a new precise job recommendation method is proposed based on a small amount of manually labeled job text information to address the problems of large waste of time and choosing difficuty in job selection. Through feature construction, the matching rules of different recruitment information are clarified. Using a text-classification-based ERNIE-BiLSTM-CRF model to extract the implicit conditions in long job description text; what's more, an improved weighted cosine similarity algorithm based on dynamic word vector is proposed to solve the problem of irrelevant information noise in text similarity calculation process. The experimental results on our dataset show that, the condition extraction model has an F1 value increased by 14.97% than other algorithms, and the text similarity method has the hitting rate and DCG value increased by 20.5% and 22.9% respectively. The algorithm can effectively realize the fuzzy matching of person and post, providing accurate and robust job recommendation services for job seekers.

**Keywords:** few-shot learning; text similarity; person-post matching; named entity recognition

后疫情时代,全球整体经济下行,毕业生求职更倾向寻求收入稳定、福利健全的编制内工作。但随着岗位数量与报考人数逐年迅速增长,报考者与招

**收稿日期:**2022-11-07 **稿件编号:**202211039
**作者简介:**刘琼雯(1999—),女,河南洛阳人,硕士研究生。研究方向:知识图谱、数据挖掘与分析。



(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

聘单位双方正经历着由于信息不对称带来的逆向选择困难，利用人岗条件模糊匹配进行岗位推荐具有较强的现实意义。

随着自然语言处理技术的飞速发展，研究者已经开始尝试将深度学习算法应用于模糊匹配[1-3]，但相关研究仍存在以下难点：1)岗位招考条件类型多，需根据其数据特征设计合理准确的人岗相似度匹配算法；2)许多岗位招考条件以长文本形式表述，需要对其中的隐含条件进行条件实体抽取；3)目前还没有公开权威的岗位招考条件标注数据集供深度学习训练。针对上述问题，文中利用卷积神经网络(Convolutional Neural Network，CNN)对数据进行预分类，引入ERNIE(Enhanced Representation Through Knowledge Integration)预训练模型，结合BiLSTM(Bi-directional Long Short-Term Memory)与CRF(Conditional Random Field)构建ERNIE-BiLSTM-CRF模型，实现岗位条件抽取，并使用动态词向量和实体识别加权进行相似度计算，提升了人岗模糊匹配的精确度和鲁棒性。

## 1 算法流程描述

### 1.1 隐含条件抽取模型

文中使用的岗位数据包括多种类型的文本信息，如“用人单位”、“招考数量”、“职称要求”、“其他条件”等。其中，“其他条件”以长文本形式描述，隐含着多种未结构化的招考条件，如性别、户籍、工作经历等，需要将这些隐含条件采用实体抽取技术转化为结构化文本。该算法首先构建了一个基于CNN的ERNIE-BiLSTM-CRF条件抽取模型，分离长文本中不同类型的招考条件，模型的整体结构如图1所示。

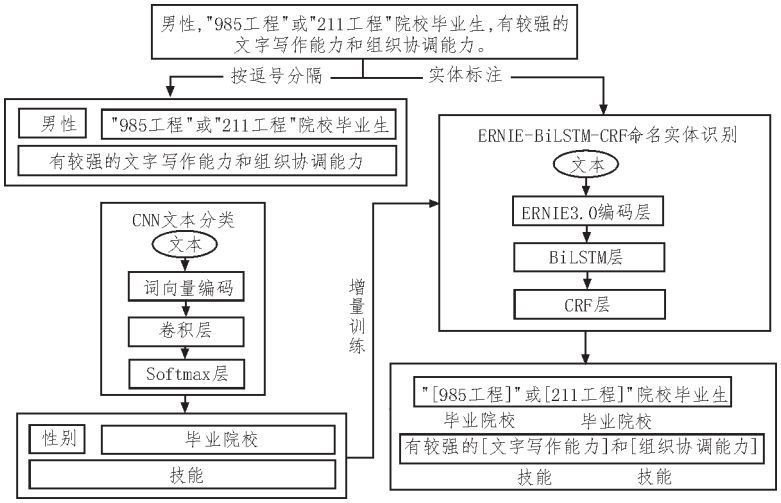


图1 条件抽取整体模型

ERNIE是一种基于掩码策略增强的BERT(Bidirectional Encoder Representations from Transformers)改进模型，模型将MASK分为字符级、实体级、短语级，进一步提升了模型的语义表示能力，能够更好地处理中文NLP任务[4]。与其他最近的BERT相关模型，如GAML-BERT模型[5]、ELECTRA[6]等相比，ERNIE的掩码机制更充分地考虑了中文文本的词法结构与语法结构。最新的ERNIE3.0版本与前两个版本相比，又融合了自回归网络与自编码网络，增强了模型对于语言的理解能力[7]。

文中考虑使用ERNIE3.0作为嵌入层，与BiLSTM-CRF模型[8]融合，进行条件实体的抽取。BiLSTM-CRF是一种常用的命名实体识别算法[9-12]，与预训练模型ERNIE结合，模型能够充分学习中文文本的上下文信息，提取全局最优序列。

但基于预训练模型的实体标注仍存在实体标注类型多、小样本训练效果不理想、特征提取不充分等情况，因此，文中将长文本按句读拆分，利用一个结构简单的CNN网络作为文本分类模型，分离如性别、户籍、政治面貌等较短的条件文本。在预分类后的文本中，使用ERNIE-BiLSTM-CRF模型进行实体识别，可实现更好的实体抽取效果。

### 1.2 人岗相似度匹配方法

根据招考条件的不同特征，可设立不同层次的文本匹配规则：①固定文本直接匹配；②数字文本比较匹配；③长文本相似度计算匹配。

固定文本直接匹配适用于属性值固定的特征，如来源类别、职称等，可通过直接的字符串匹配算法



(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

进行过滤，若匹配过程中某一属性值与用户输入的自身条件不符，则匹配值为0，过滤该岗位。

数字类型的岗位信息如工作年限，采用数字文本比较匹配规则。需要注意的是，一些文本类型如学历，虽然属性值较为固定，但其语义隐藏包含关系，如招收大专学历隐含招收本科学历。因此，需要对该类属性量化，转换为数字文本进行比较。

长文本如岗位技能要求、工作经历要求的描述通常较为多样化，需采用长文本相似度计算匹配方式。下文说明了一个基于实体抽取的加权余弦相似度计算方法，算法流程如图2所示。

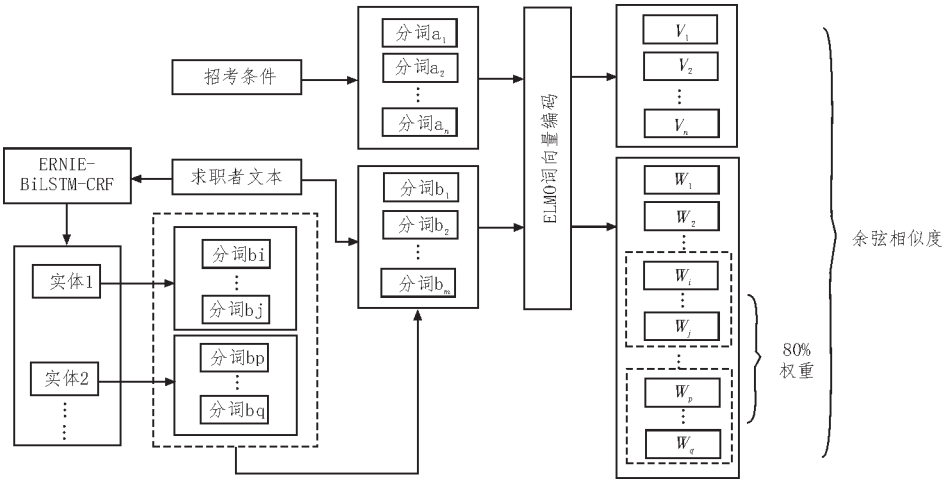


图2　改进的余弦相似度计算流程

在中文文本相似度计算领域，通常首先将待匹配文本通过jieba分词，再将文本词语编码为词向量，通过计算文本对应的词向量集合在向量空间中的度量衡量两个文本间差异的大小ELMO模型是一种基于预训练的动态词向量编码算法[13]。与Word2vec[14]、Doc2vec[15]等静态向量不同，ELMO使用多个BiLSTM层捕获句法语义关系，可以通过不同的语句对同一个单词训练出不同的词向量，充分解决了中文语境中一词多义的问题[16-17]。模型结构如图3所示。文中利用该模型生成文本的动态词向量嵌入，作为文本相似度计算的输入特征。

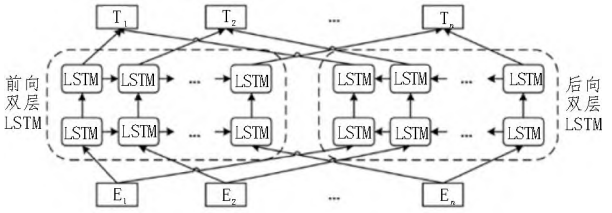


图3　ELMO模型结构

在传统算法中，给定文本分词的词向量集合为$V=\{V_1, V_2, \cdots, V_m\}$，其中$V_i$是$V$中第$i$个个体，$i=1,2,\cdots,m$。该文本的向量表示为分词词向量取平均值，如式(1)所示。

$$\bar{v}_j=\frac{1}{m}\sum_{i=1}^{m}v_{ij} \tag{1}$$

其中，$\bar{v}_j$表示文本向量的第$j$项，$j=1,2,\cdots,n$，$v_{ij}$表示词向量$V_i$的第$j$项。

但在实际匹配中，文本的分词并非具有相同的重要性。在数据规模较小的情况下，文本的无关信息会对相似度计算结果产生较大影响。因此，文中引入一种自定义的注意力模式，利用已训练的ERNIE-BiLSTM-CRF模型，在匹配前抽取待匹配的求职者文本中对应实体，为实体中涉及的分词赋予较高权重，其余词赋予较低权重。权重分配基于帕累托提出的二八定律，为实体分词列表中的词向量赋予80%的权重，其余词向量赋予20%权重，加权求和得到文本向量。

向量的相似性度量通常采用余弦相似度进行计算。相似度越高，则余弦值越趋近于1；值为负时，两向量负相关。余弦相似度的计算公式如式(2)所示。

$$\mathrm{sim}(i,j)=\cos(i,j)=\frac{i\cdot j}{\|i\|\|j\|} \tag{2}$$

进而，文本余弦相似度的计算方式可表示为：

$$\mathrm{sim}(\bar{V},\bar{W})=\frac{\sum_{j=1}^{n}\bar{v}_j\times\bar{w}_j}{\sqrt{\sum_{j=1}^{n}(\bar{v}_j)^2}\times\sqrt{\sum_{j=1}^{n}(\bar{w}_j)^2}} \tag{3}$$

其中，$\bar{V}$、$\bar{W}$分别表示求职者与岗位属性文本



(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

向量，$\bar{v}_j$、$\bar{w}_j$分别表示求职者与岗位属性文本向量的第$j$项分量。

计算得到的各特征文本相似度按式(4)加权相加，并按顺序排列得到推荐岗位。

$$\mathrm{sim}_{\mathrm{txt}}=w_1t_1\&w_2t_2\&\cdots w_it_i \tag{4}$$

其中，$t_i$表示该特征相似度计算得到的匹配度，$w_i$表示该特征的权重，反映了不同特征在匹配中的重要性。

综合各类型数据匹配结果，可得出岗位数据集中各岗位的推荐值如式(5)所示。

$$R=\mathrm{sim}_{\mathrm{fix}}\times\mathrm{sim}_{\mathrm{dig}}\times\mathrm{sim}_{\mathrm{txt}} \tag{5}$$

其中，$\mathrm{sim}_{\mathrm{fix}}$与$\mathrm{sim}_{\mathrm{fig}}$取值为布尔值，分别表示直接匹配与比较匹配的匹配结果。当且仅当求职者的所有直接匹配与比较匹配属性均成功匹配时，推荐该岗位，否则推荐值为0。$\mathrm{sim}_{\mathrm{txt}}$表示文本匹配的相似度，岗位推荐按照$R$大小进行排序。

## 2 实验结果与分析

### 2.1 数据获取与标注

文中数据来源于国防部公开发布的2021全军面向社会公开招考文职人员计划，包括22 265条岗位信息，挑选其中200条岗位招考信息的“其他条件”，利用开源文本标注工具doccano分别对其进行分类任务标注与实体识别任务标注，并将标注结果按比例分为训练集、验证集与测试集。其中，分类任务包含10类文本，按8∶1∶1划分训练集、验证集与测试集，实体识别任务包含10类实体，按6∶2∶2划分训练集、验证集与测试集。

### 2.2 隐含条件抽取

为验证所提条件抽取模型的性能，文中设计了多种对比实验。首先对比了在未经分类处理的原数据集上ERNIE-BiLSTM-CRF模型与基线模型的实体识别效果，证明了ERNIE对中文任务训练的有效性。其次测试加入分类预处理后识别效果的提升情况。实验采用准确率、精确率、召回率、F1值对模型性能进行评估。

#### 2.2.1 原始数据中各类实体识别模型性能指标对比

文中对比了在原始长文本数据集上，BiLSTM-CRF、BERT-BiLSTM-CRF、ERNIE-BiLSTM-CRF三种模型运行至收敛的识别效果。各类模型对10个类别识别的具体F1值如图4所示。实验证明，ERNIE-BiLSTM-CRF模型在各项指标中均优于最新的RoBERTa-BiLSTM-CRF模型，且ERNIE模型在各个类别预测的F1值均高于其他模型。ERNIE预训练模型采用的多级别掩码预测机制对于提升模型对语义信息的理解表达能力有明显的促进作用。

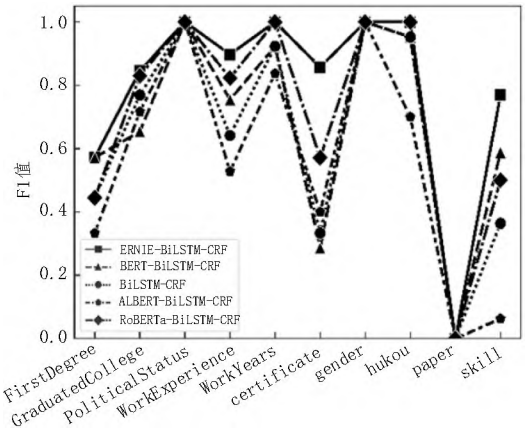


图4 各类模型对10类实体识别效果对比

#### 2.2.2 不同训练策略的实体识别模型性能指标对比

该实验首先训练了一个结构简单但高效的CNN模型用于文本分类，模型在测试集中达到了97.96%的平均准确率。

图5显示了该模型分别在10类文本上的精确率、召回率与F1值。由图5可知，CNN分类模型能够有效地从训练集中学习各类型文本的特征。由于分类模型在部分类别中的准确率已达100%，因此直接抽取岗位数据库中对应的四类条件实体(政治面貌、证书情况、性别、户口)，对余下短文本进行进一步实体识别。

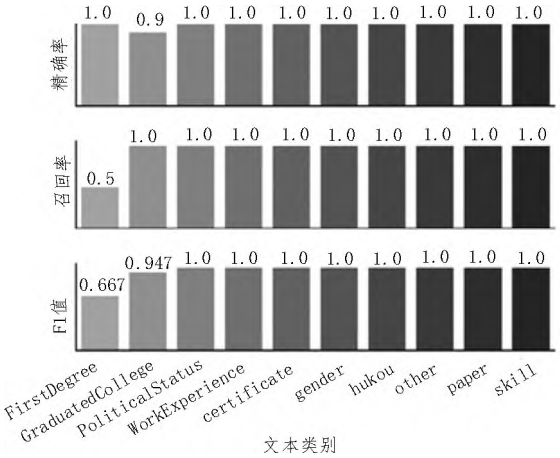


图5 CNN模型各类别分类结果

基于预分类所得结果，下面分别对比了ERNIE-BiLSTM-CRF模型采用三种训练策略：①利用原数据直接训练，②利用预分类文本直接训练，③利用预



(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

分类文本增量训练，在分类筛选后的测试集上识别F1值。实验结果表明，采用预分类文本进行增量训练的模型综合准确率达到了80%，F1值达到了75.02%，较直接使用原始数据训练分别提升了16%和14.97%。

模型在六类实体中的具体识别表现如图6所示。由图6可知，所提基于预分类和增量学习的训练策略在未增加额外标注任务的情况下，对各类实体的识别效果都有不同程度的提升。

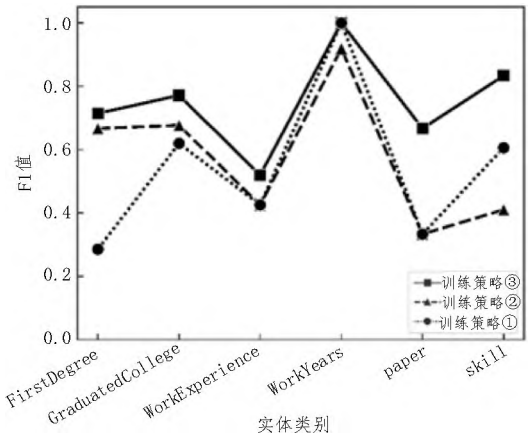


图6　训练策略对六类实体识别效果影响

因此，使用文中所提的融合分类模型的实体识别算法对全部招聘信息的“其他条件”进行条件抽取。模型输入共计22 265条招聘信息，分类后过滤其中政治面貌、证书、性别、户口类别文本，剩余13 529条短文本。对其进行实体抽取，共计识别出23 752个实体，平均每条短文本中抽取出1.76个实体，每个实体的具体数目如图7所示。

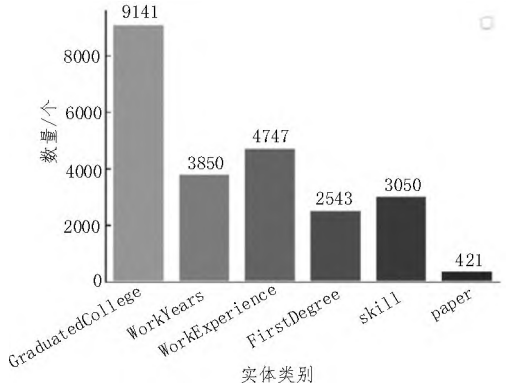


图7　实体抽取实验结果

## 2.3　文本相似度计算

文中提出了一种改进的余弦相似度算法，使用ELMO算法对用户输入和各岗位的技能、工作经历相关文本向量化，并利用上述基于预分类的ERNIE-BiLSTM-CRF模型对用户向量分词加权，与岗位向量进行相似度计算。

图8显示了文中所提算法与传统余弦相似度计算的核密度估计图（Kernel Density Estimation, KDE）对比（以输入求职者技能“具有较强的工程制图能力”为例，计算其与各岗位相似度）。由图8可知，改进的余弦相似度算法较余弦相似度算法具有更高的区分度。对于不相关的文本，改进的余弦相似度得到更低的相似度值；而相关文本得到的相似度更高。

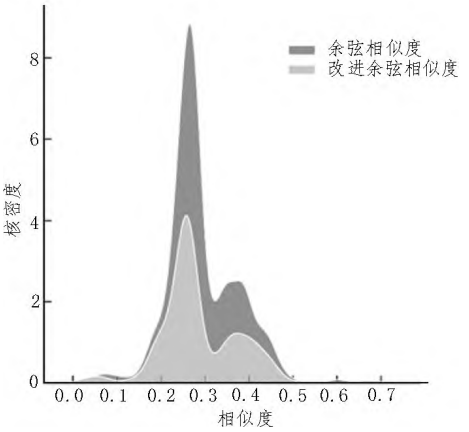


图8　不同相似度计算方法核密度估计图

为进一步说明该算法的有效性，文中制定了十组测试文本，分别对应工作技能与工作经历，计算其与各岗位相应条件的相似度，按相似度推荐排序。以在不同测试用例下TOP-$n$推荐岗位的命中数与折扣累计增益（Discounted Cumulative Gain，DCG）作为评估标准。

DCG值是一种常用的用来衡量推荐算法排序质量的指标，值越大表明算法的推荐质量越好[18]。对于长度为$n$的推荐列表，DCG计算式如下：

$$\mathrm{DCG}_n = \sum_{i=1}^{n} \frac{\mathrm{rel}(i)}{\mathrm{lb}(i+1)} \tag{6}$$

其中，$\mathrm{rel}(i)$表示第$i$条推荐的评分，在此例中，相关则评分为1，不相关则评分为0。

表1展示了部分常见的工作技能与工作经历采用不同相似度算法的性能对比。由表1可知，文中所提算法TOP-15推荐结果的命中数及DCG均在不同程度上优于传统的余弦相似度算法。总体命中数由49提升至63，效果提升约28.6%；平均DCG值由



(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

3.462提升至4.545，效果提升约31.3%。

表1 不同相似度算法评估结果对比

| 输入 | | 余弦相似度 | | 改进余弦相似度 | |
|---|---|---|---|---|---|
| | | 命中数 | DCG | 命中数 | DCG |
| 技能 | 计算机使用 | 8 | 2.8 | 13 | 5.14 |
| | 视频编辑 | 11 | 4.77 | 15 | 5.86 |
| | 工程制图 | 5 | 2.59 | 6 | 3.14 |
| 经历 | 档案整理 | 6 | 3.09 | 8 | 3.95 |
| | 财务管理 | 7 | 2.59 | 7 | 3.61 |
| | 新闻采编 | 12 | 4.93 | 14 | 5.57 |

## 3 结 论

文中提出了一个利用少量标注样本实现大规模数据信息抽取与匹配的岗位推荐算法，采用了多种策略以解决小样本训练集中实现人和岗位条件模糊匹配的问题。对于长文本的条件抽取，将长文本按逗号分割为短文本，使用分类算法与ERNIE-BiLSTM-CRF模型结合的方式对短文本进行信息提取，该方法能够更好地识别中文语义信息，缓解小样本条件下训练过拟合的问题；对于人和岗的条件匹配，提出了一种改进的余弦相似度算法，利用实体识别结果为求职者文本向量加权，减弱了无关信息对匹配结果的影响，增强了小样本训练结果的鲁棒性。

文中使用了多种评价指标对所提模型的性能进行了评估，从实验结果看，所提的方法在测试样本上取得了优于领域常用算法的表现。

由于缺少对应的数据集，所提方法并未将求职者对岗位的倾向，如意愿工作城市、从事工作纳入匹配考量，仅为求职者展示岗位信息，这是之后的研究工作中可以进一步关注的问题。但总体而言，文中所提方法具备高可行性、鲁棒性，具备推广到实际使用的应用潜力与应用价值。

**参考文献：**

[1] 施元鹏,单剑峰.基于文本相似度的简历匹配推荐算法研究[J].计算机仿真,2022,39(4):441-444,491.

[2] 王一博.基于知识图谱的计算机领域胜任力研究与应用[D].长春:吉林大学,2020.

[3] 张毅,高元荣,黄宗财,等.结合深度语义特征的人岗精准匹配算法[J].贵州大学学报(自然科学版),2021,38(1):65-70.

[4] Guo H,Chi C,Zhan X.ERNIE-BiLSTM based Chinese text sentiment classification method[C].Proceedings of the 2021 International Conference on Computer Engineering and Application(ICCEA). IEEE,2021: 84-88.

[5] Zhu W,Wang X L,Ni Y,et al.GAML-BERT:improving BERT early exiting by gradient aligned mutual learning[C].2021 Conference on Empirical Methods in Natural Language Processing(EMNLP 2021), 2021:3033-3044.

[6] Zhang T.Deep-learning-based automated scoring for the severity of toxic comments using electra[C]. Proceedings of the 2022 6th International Conference on Deep Learning Technologies,2022:14-19.

[7] Fan X,Pan W,Huang Q.Research on Chinese short text semantic matching based on lightweight ERNIE[C].Proceedings of the 2022 10th International Conference on Information Technology:IoT and Smart City,2023:22-28.

[8] 赵平,孙连英,万莹,等.基于BERT+BiLSTM+CRF的中文景点命名实体识别[J].计算机系统应用,2020,29(6):169-174.

[9] Ma K,Tan Y,Tian M,et al.Extraction of temporal information from social media messages using the BERT model[J].EARTH Science Informatics,2022, 15(1):573-584.

[10]Wang Z,Guan H.Research on Named Entity Recognition of Doctor-Patient Question Answering Community Based on BiLSTM-CRF Model[C]. 2020 IEEE International Conference on Bioinformatics and Biomedicine.IEEE,2020:1641-1644.

[11]Wang Z,Zhang B,Gao D,et al.Chinese named entity recognition for hazard and operability analysis text based on Albert[C].2020 Chinese Automation COngress(CAC 2020).IEEE,2020:5641-5645.

[12]Yang Q Y,Jiang J,Feng X Y,et al.Named Entity Recognition of Power Substation Knowledge Based on Transformer-BiLSTM-CRF Network[C].2020 International Conference on Smart Grids and Energy Systems(SGES 2020),2020:952-956.

[13]Gupta H,Patel M.Study of Extractive Text Summarizer Using The Elmo Embedding[C].proceedings of the 2020 Fourth International Conference on I-SMAC(IoT in Social, Mobile, Analytics and Cloud)

（下转第61页）



(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

断,具有较强的实用价值。

**参考文献:**

[1] 计浩浩,张诚,卿粼波,等.基于机器学习的城市空间品质大规模量化方法[J].计算机工程与设计,2021,42(4):1096-1102.

[2] 彭其渊,刘杰.城市轨道交通规划网络与城市规划的综合协调性量化分析[J].交通运输工程学报,2019,19(3):134-144.

[3] 高子为,孙伟伟,程朋根,等.融合高分辨率遥感影像和POI数据的多特征潜在语义信息用于识别城市功能区[J].遥感技术与应用,2021,36(3):618-626.

[4] 罗琼,舒红,徐亚瑾,等.移动轨迹数据支持下的城市居民通勤活动分析[J].武汉大学学报(信息科学版),2021,46(5):718-725.

[5] 邢汉发,孟媛,侯东阳.一种应用兴趣点数据进行地表覆盖分类的方法[J].武汉大学学报(信息科学版),2019,44(5):758-764.

[6] 彭俊利,谷雨,张震,等.融合单词贡献度与Word2vec词向量的文档表示[J].计算机工程,2021,47(4):62-67.

[7] 王伟,赵尔平,崔志远,等.基于HowNet义原和Word2vec词向量表示的多特征融合消歧方法[J].计算机应用,2021,41(8):2193-2198.

[8] 徐翔,靳菁.基于Word2vec的信息窄化测度及影响因素研究[J].吉林大学学报(信息科学版),2021,39(3):339-347.

[9] 张仕森,孙宪坤,尹玲,等.基于神经网络的文本标题生成原型系统设计[J].电子科技,2021,34(5):35-41.

[10] 廖文雄,曾碧,徐雅芸.结合一维扩展卷积与Attention机制的NLP模型[J].计算机工程与应用,2021,57(4):114-119.

[11] 李舟军,范宇,吴贤杰.面向自然语言处理的预训练技术研究综述[J].计算机科学,2020,47(3):162-173.

[12] 李峻屹.基于大数据的K-means聚类算法的网络安全检测应用研究[J].机械设计与制造工程,2021,50(9):115-118.

[13] 林丽,薛芳.基于逻辑回归函数的加权K-means聚类算法[J].集美大学学报(自然科学版),2021,26(2):139-145.

[14] 柴变芳,李有熠.基于Spark的主动重叠K-means聚类算法[J].微电子学与计算机,2021,38(1):70-76.

[15] 王艳娥,安健,梁艳,等.基于密度优化初始聚类中心的K-means算法[J].计算机技术与发展,2020,30(12):99-105.

[16] 王子龙,李进,宋亚飞.基于距离和权重改进的K-means算法[J].计算机工程与应用,2020,56(23):87-94.

(上接第56页)

(I-SMAC),2020:829-834.

[14] Wang R,Shi Y.Research on application of article recommendation algorithm based on Word2Vec and Tfidf[C].Proceedings of the 2022 IEEE International Conference on Electrical Engineering,Big Data and Algorithms(EEBDA),2022:454-457.

[15] Santillan M C,Azcarraga A P.Poem Generation using Transformers and Doc2Vec Embeddings [C].2020 International Joint Conference on Neural Networks(IJCNN),2020:1-7.

[16] 代佳洋,周栋.基于多任务学习的跨语言信息检索方法研究[J].广西师范大学学报(自然科学版),2022,40(6):69-81.

[17] 李培林,庞彦燕,贺巧琳,等.基于BERT与要素标注的适用法条推荐[J].四川师范大学学报(自然科学版),2023,46(1):134-142.

[18] 李征,金迪,黄雪原,等.基于隐式反馈的推荐研究综述[J].河南大学学报(自然科学版),2022,52(3):305-319.



(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net